

概率论 课堂笔记

原生生物

斗满人概，人满天概。——管子

目录

一 概率空间与独立性	3
§1.1 事件与概率	3
§1.2 条件概率与独立性	4
§1.3 概率模型	5
二 随机变量与分布函数	6
§2.1 随机变量	6
§2.2 随机向量	7
三 离散型随机变量	8
§3.1 分布列与独立性	8
§3.2 数学期望	9
§3.3 协方差	10
§3.4 条件分布与条件期望	11
§3.5 随机游走	12
§3.6 母函数	14
四 连续型随机变量	15
§4.1 独立性	15
§4.2 期望	16
§4.3 多元正态分布	18
五 中心极限定理	19
§5.1 一般随机变量的期望	19
§5.2 特征函数	20
§5.3 反转与连续性定理	22
§5.4 极限定理	23
六 几种收敛	25
§6.1 四种收敛方式	25
§6.2 重要结论	27
§6.3 强大数律	28

七 概率论外篇	28
§7.1 信息熵	28
§7.2 Linderberg替换理论	29
§7.3 随机矩阵	30

一 概率空间与独立性

§1.1 事件与概率

样本点-具体结果 样本空间 Ω -样本点的全体 事件 A -样本空间的子集

例 1.1 掷硬币 $\Omega = \{H, T\}, A = \{H\}$

电子自旋 $\Omega = \{\uparrow, \downarrow\}, A = \{\uparrow\}$

掷骰子 $\Omega = \{1, 2, 3, 4, 5, 6\}, A = \{2, 4, 6\}$

*上方的例子中，样本点均只有有限多个。

例 1.2 道琼斯指数 样本点-连续曲线 $x(t), t \in [0, T]$ 样本空间 $\Omega = \{x(t) \in C[0, T]\}$

事件运算 $\longleftrightarrow$ 集合运算

事件 A 发生 $\longleftrightarrow$ 试验结果 $\omega \in A$

$A = \emptyset$ 不可能事件 $A = \Omega$ 必然事件

事件交、并、余 $\longleftrightarrow A \cap B, A \cup B, A^c$

事件的交-两事件均发生 事件的并-两事件至少发生一个 事件的余-事件未发生

*可记 $A \cap B$ 为 AB

A 与 A^c 称对立事件。

A 发生则 B 亦发生 $\longleftrightarrow A \subset B$

$A \cap B = \emptyset$ 时称 A, B 不相容。

*由此亦可定义 $A_1, \dots, A_n, \dots$ 互不相容

问题：是否要将 Ω 的所有子集定义为随机事件？

*良好定义的随机事件为 Ω 的一个子集族，且至少要求对交、并、余三种运算封闭。

例 1.3 掷硬币第一次正面向上的时刻 $\Omega = \{1, 2, \dots\}$ 此时样本空间为无限集合，有限交并性质不足！

定义 1.1 $\mathcal{F}$ 为 Ω 某些子集构成的子集族，称其为事件域(σ 域)，若：

1. $\Omega \in \mathcal{F}$

2. $A \in \mathcal{F} \implies A^c \in \mathcal{F}$

3. $A_n \in \mathcal{F}, n \in \mathbb{N}^* \implies \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$

并称 $(\Omega, \mathcal{F})$ 为一个可测空间。

例 1.4 最大 σ 域， Ω 的幂集

最小 $\mathcal{F} = \{\Omega, \emptyset\}$

中间域，如 $A \neq \emptyset, \Omega$ 时 $\mathcal{F} = \{\Omega, \emptyset, A, A^c\}$

定义概率：直观想法-频率稳定性(重复试验后计数发生次数)

重复 N 次， A 发生 N_A 次，经验表明 $\lim_{N \rightarrow \infty} \frac{N_A}{N} = c$ ，记 c 为 $P(A)$ 。明显性质： $P(\emptyset) = 0, P(\Omega) = 1$ 。

若 $A \cap B = \emptyset, N_{A \cup B} = N_A + N_B \implies P(A \cup B) = P(A) + P(B)$

定义 1.2 $P: \mathcal{F} \rightarrow \mathbb{R}$ 为 $(\Omega, \mathcal{F})$ 上的概率测度，若：

1. 非负性 $P(A) \geq 0$

2. 规范性 $P(\Omega) = 1$

3. 可列可加性 若 $\{A_n\}$ 互不相容，则 $P\left(\bigcup_n A_n\right) = \sum_n P(A_n)$

并称 $(\Omega, \mathcal{F}, P)$ 为一个概率空间。

例 1.5 掷硬币 $\Omega = \{H, T\}, \mathcal{F} = 2^\Omega, P(\{H\}) = p, P(\{T\}) = q, p + q = 1$

例 1.6 $\Omega = \{1, 2, 3, 4, 5, 6\}, \mathcal{F} = 2^\Omega$ 假定公平, 则 $P(A) = \frac{|A|}{6}$

样本点有限, 且每个样本点等概率发生, 则称**古典概型**。

定理 1.1 概率测度基本性质

1. $P(A^c) = 1 - P(A)$
2. $A \subset B$ 时 $P(B) = P(B \setminus A) + P(A) \geq P(A)$
3. $P(A \cup B) = P(B) + P(A) - P(AB)$
4. *Jordan* 公式 $P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n \sum_{i_1 < \dots < i_k} (-1)^{k-1} P(A_{i_1} \dots A_{i_k})$

定理 1.2 概率测度连续性

1. 单调增事件列 $A_1 \subset \dots \subset A_n \subset \dots$, 记 $A = \bigcup_{i=1}^{\infty} A_i = \lim_{n \rightarrow \infty} A_n$, 则 $P(A) = \lim_{n \rightarrow \infty} P(A_n)$ 。
2. 单调减事件列 $B_1 \supset \dots \supset B_n \supset \dots$, 记 $B = \bigcap_{i=1}^{\infty} B_i = \lim_{n \rightarrow \infty} B_n$, 则 $P(B) = \lim_{n \rightarrow \infty} P(B_n)$ 。

证明: $A = A_1 \cup (A_2 \setminus A_1) \cup \dots \cup (A_n \setminus A_{n-1}) \cup \dots$ 。此处的并均为无交并, 因此可由定义与引理计算即得结果。对于 B , 取余即可化为 A 的情况。

§1.2 条件概率与独立性

直观想法-重复试验, B 发生 N_B 次, B 发生条件下 A 发生次数 N_{AB} , 次数足够多时**条件概率**可看作 $\frac{N_{AB}}{N_B}$ 。

定义 1.3 条件概率

设 $P(B) > 0$, B 发生条件下 A 的条件概率 $P(A|B) = \frac{P(AB)}{P(B)}$

变形有乘法公式 $P(AB) = P(B)P(A|B)$

* $B_1, \dots, B_n$ 为 Ω 的互不相容子集, 且 $\bigcup_i B_i = \Omega$, 则称其为 Ω 的一个划分。

定理 1.3 全概率公式

$B_1, \dots, B_n$ 为 Ω 的一个划分, $P(B_i) > 0$, 则 $A = A \cap \Omega = \bigcup_i (B_i \cap A) \Rightarrow P(A) = \sum_i P(B_i)P(A|B_i)$ 。

例 1.7 坛子里有 3 白 2 红共 5 个球, 每次无放回摸出一个球, $A = \{\text{第二次摸到白球}\}$, 按第一次抽到白或红划分可知 $P(A) = \frac{3}{5} \cdot \frac{1}{2} + \frac{2}{5} \cdot \frac{3}{4} = \frac{3}{5}$ (注意到, 在每个轮次抽出白球的概率一致)。

定理 1.4 贝叶斯公式

$A_1, \dots, A_n$ 为 Ω 的一个划分, $P(A_i) > 0$, 则 $P(B) > 0$ 时 $P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_j P(A_j)P(B|A_j)}$

例 1.8 发出 s 时, 收到 s 概率为 0.8, 收到 t 概率为 0.2; 发出 t 时, 收到 s 概率为 0.9, 收到 t 概率为 0.1。且发出 s 概率为 0.6, 发出 t 概率为 0.4。

收到 s 的情况下, 发出 s 的概率为: $\frac{0.6 \cdot 0.8}{0.6 \cdot 0.8 + 0.4 \cdot 0.1} = 0.923$

掷硬币, B 代表第一次正面, A 代表第二次正面, 则 $P(A|B) = P(A)$, 即 $P(AB) = P(A)P(B)$, 由此引出定义:

定义 1.4 独立性

称 A, B 独立, 若 $P(AB) = P(A)P(B)$

更一般, 称 $A_1, \dots, A_n$ 相互独立是指 $\forall 2 \leq k \leq n, i_1 < \dots < i_k, P(\prod_{j=1}^k A_{i_j}) = \prod_{j=1}^k P(A_{i_j})$;

两两独立是指只需 $k = 2$ 时满足。

两两独立与相互独立不同, 举例如下:

例 1.9 古典概型中, $\Omega = \{1, 2, 3, 4\}, A = \{1, 3\}, B = \{1, 2\}, C = \{1, 4\}$ 。

计算可知 A, B, C 两两独立, 但不相互独立。

定理 1.5 若 A, B 独立, 则 A 与 B^c , A^c 与 B , A^c 与 B^c 独立。更一般地, 若一些事件相互独立, 将其中部分改为其对立事件后仍然相互独立。

证明: 两事件时, 由对称, 只需证明 A 与 B^c 独立。由 $P(AB^c) + P(AB) = P(A)$ 可算出结果。多事件时类似两事件一个个调整即可。

例 1.10 “重复独立试验, 小概率事件必发生”

记事件为 A , $A_k = \{\text{第 } k \text{ 次试验中 } A \text{ 发生}\}$, 则 $\bigcup_{k=1}^n A_k$ 表示\{前 k 次试验中 A 发生\}。

$P(\bigcup_{k=1}^n A_k) = 1 - P(\bigcap_{k=1}^n A_k^c)$, 由独立性, 此式为 $1 - \prod_{k=1}^n (1 - P(A_k))$, 由此知结果。

§1.3 概率模型

例 1.11 对称随机游走

赌徒财富 k , 庄家 $N - k$, 掷均匀硬币, 正面则赌徒赢庄家1, 否则庄家赢赌徒1, 赌至一方输光, 问赌徒输光概率。

记赌徒初始为 k 且输光的事件为 A_k , B 为首局正面, 由此 $P(A_k) = P(B)P(A_k|B) + P(B^c)P(A_k|B^c) = \frac{P(A_{k-1}) + P(A_{k+1})}{2}$, 且 $P(A_0) = 1, P(A_N) = 0$, 由等差数列知 $P(A_k) = \frac{N-k}{N}$ 。

计数问题

例 1.12 坛子里有4白6红共10个球, 随机取4个, 求2白2红概率。

样本点数目 C_{10}^4 , 事件发生的样本点数目 $C_4^2 C_6^2$, 结果为 $\frac{3}{7}$ 。

*古典概型重要应用: 排列组合计算样本点数目

经典问题: n 个对象中选 m 个, 问选法种数(是否可重复? 是否考虑顺序?)。

有序不重复: A_n^m 无序不重复: C_n^m 有序可重复: n^m

无序可重复: 插板法, 看作 m 个小球 n 个盒子($n-1$ 个挡板), 知结果为 C_{n-1+m}^m

例 1.13 将 n 个小球投入到 $N \geq n$ 个盒子中, 投法等可能, 求前 n 个盒子中各一个球的概率(球是否可分辨? 盒子是否有容量限制?)。

(1) 球可区分, 盒子无限制(麦克斯韦-玻尔兹曼统计): 样本点个数 N^n , 合要求个数 $n!$, 概率 $\frac{n!}{N^n}$

(2) 球不可区分, 盒子无限制(玻色-爱因斯坦统计): 化为无序可重复, 样本点个数 C_{n+N-1}^n , 合要求个数1, 概率 $\frac{1}{C_{n+N-1}^n}$

(3) 球不可区分, 盒子容量一(费米-狄拉克统计): 样本点个数 C_N^n , 合要求个数1, 概率为 $\frac{1}{C_N^n}$

例 1.14 Polya模型

坛子里有一些球, b 黑 r 红, 先摸出一个记下颜色后放回, 并且再放入 c 个同色球。记 B_n 表示第 n 次抽到黑球, 求概率。

观察可发现, n 次抽取抽中 k 次黑球, 任意给定次序概率相同, 为 $D_k(b) = \frac{\prod_{i=0}^{k-1} (b+ic) \prod_{i=0}^{n-k-1} (r+ic)}{\prod_{i=0}^{n-1} b+r+ic}$,

有 $B_{n+1} = \sum_{k=0}^n C_n^k D_k(b) \frac{b+kc}{b+r+nc} = \frac{b}{b+r} \sum_{k=0}^n C_n^k D_k(b+r)$, 而由概率含义 $\sum_{k=0}^n C_n^k D_k(b+r)$ 构成整个样本

空间, 因此为1, 因此 $B_{n+1} = \frac{b}{b+r}$ 。

* $c = -1$ 即为无放回, $c = 0$ 即为有放回。

二 随机变量与分布函数

§2.1 随机变量

$\mathcal{F}_1, \mathcal{F}_2$ 为 Ω 上的 σ 域, 可验证其交亦为 σ 域。更一般地, 给定某指标集 I , $\mathcal{F}_i, i \in I$ 的交集亦为 σ 域。

$\mathbb{R}$ 上Borel域定义为包含所有 $(a, b], a, b \in \mathbb{R}$ 的最小 σ 域(最小定义: 所有包含的取交), 记为 $B(\mathbb{R})$ 。

$\{b\} = \bigcap_n \left(b - \frac{1}{n}, b \right] \in B(\mathbb{R})$, 类似知 $(a, b), [a, b], [a, b) \in B(\mathbb{R})$ 。

$\mathcal{B}(\mathbb{R}^n)$ 为包含所有左开右闭区间笛卡尔积形成的矩形的最小 σ 域, Borel域中的集合称Borel集。

定义 2.1 随机变量、概率分布函数

$(\Omega, \mathcal{F}, P)$ 中, 称 $X: \Omega \rightarrow \mathbb{R}$ 为一个随机变量, 若 $\forall x \in \mathbb{R}$, 有 $\{\omega \in \Omega: X(\omega) \leq x\} \in \mathcal{F}$ 。

此时记后方集合为 $\{X \leq x\}$, 称 $F(x) = P(\{X \leq x\})$ 为随机变量 X 的(概率)分布函数。

例 2.1 掷均匀硬币

$\Omega = \{H, T\}, X: \Omega \rightarrow \mathbb{R}, X(H) = 1, X(T) = -1$

$$P(\{X \leq x\}) = \begin{cases} 1 & x \geq 1 \\ 0.5 & -1 \leq x < 1 \\ 0 & x < -1 \end{cases}$$

定理 2.1 分布函数 $F(x)$ 性质

1. 单调增

2. 负无穷极限0, 正无穷极限1

3. 右连续 $\lim_{\sigma \rightarrow 0^+} F(x + \sigma) = F(x)$

证明:

1. 利用包含关系说明。

2. 取一列数趋向正/负无穷, 利用概率的极限等于极限的概率知结论。

3. 类似2, 取子列说明。

注:

(1) 若某函数这三条性质, 一定为某随机变量的概率分布函数, 因此, 一般将满足三条性质的函数称为分布函数。

(2) 另一种定义分布函数的方式: $G(x) = P(\{X < x\})$, 此时其具有左连续性, 一二两条不变。

(3) 分布函数丢失了关于样本空间的信息, 与样本空间无关。

例 2.2 若 $X = c$ 概率为1, 称 X 几乎处处常值, 则 $F(x) = \begin{cases} 1 & x \geq c \\ 0 & x < c \end{cases}$

例 2.3 Bernoulli 两点分布

若 $P(X=1)=p, P(X=0)=q, p+q=1$, 则 $F(x) = \begin{cases} 1 & x \geq 1 \\ q & 0 \leq x < 1 \\ 0 & x < 0 \end{cases}$

特别地, $A \in \mathcal{F}$, 示性函数 $I_A(\omega) = \begin{cases} 1 & \omega \in A \\ 0 & \omega \notin A \end{cases}$ 亦为随机变量, 满足 Bernoulli 两点分布, 且有 $P(I_A = 1) = P(A)$ 。

定理 2.2 随机变量性质

1. $P(X > x) = 1 - F(x)$
2. $P(x < X \leq y) = F(y) - F(x)$
3. $P(X = x) = F(x) - F(x^-)$

定理 2.3 设 X 为 $(\Omega, \mathcal{F}, P)$ 上随机变量, 则任意 Borel 集的原象为事件域中元素。

证明: 记 $\mathcal{A} = \{A \subset \mathbb{R} : X^{-1}(A) \in \mathcal{F}\}$, 由于 $X^{-1}(A^c) = X^{-1}(A)^c, X^{-1}\left(\bigcup_n A_n\right) = \bigcup_n X^{-1}(A_n)$ 分别验证三条性质可知 $\mathcal{A}$ 为 $\mathbb{R}$ 上 σ 域。因此, $(a, b] = (-\infty, b] - (-\infty, a] \in \mathcal{A}$, 进一步可知 $B(\mathbb{R}) \subset \mathcal{A}$, 即可得证。

*随机变量相加后仍为随机变量

证明: 令 r_n 为一切有理数的一个排列, 证出 $\{X+Y \leq x\} = \bigcap_{n=1}^{\infty} (\{X \leq r_n\} \cup \{Y \leq x-r_n\})$ 即可说明结论。

右包含左易证, 故只需证明 ω 不属于左侧时亦不属于右侧。若其不属于左侧, 取 m 使 $X(\omega) > r_m > Y(\omega)$ 即发现其不属于右侧。

§2.2 随机向量**定义 2.2** 离散型随机变量

随机变量 X 取值至多可列个 $x_1, x_2, \dots$, 则称 X 为离散型随机变量。

记 $p_k = P(X = x_k)$, 则 $\{p_k\}$ 为 X 的分布列, 此时分布函数 $F(x) = \sum_{k: x_k \leq x} p_k$ 在 x_k 处跳跃, 又称原子分布。

定义 2.3 连续型随机变量

若随机变量 X 的分布函数 $F(x) = \int_{-\infty}^x f(u)du$, 其中 f 非负可积, 则称 X 为连续型随机变量, 称 f 为 X 的密度函数。

注:

- (1) 密度函数含义: 当 $x = x_0$ 为 f 连续点时, $\Delta x \rightarrow 0$, 则 $P(x_0 < X \leq x_0 + \Delta x) = f(x_0)\Delta x$ 。
- (2) 密度函数改变有限多个值仍为密度函数。
- (3) $P(X = a) \leq \int_{a-1/n}^a f(u)du \rightarrow 0$, 因此 X 在任意有限多个点取值概率为 0。
- (4) 若 F 连续且除去有限多个点外 $F'(x)$ 存在且连续, 则 X 为连续型随机变量, 且 F' 可作为一个密度函数。
- (5) X 为连续型随机变量, 则 F 绝对连续。

例 2.4 钟表指针

$\Omega = [0, 2\pi), \mathcal{F} = B(\mathbb{R}) \cap \Omega, P(A) = \frac{|A|}{2\pi}$, $|A|$ 指勒贝格测度。

令 $X(\omega) = \omega, Y(\omega) = \omega^2$, 则

$$F_X(x) = \begin{cases} x < 0 & 0 \\ \frac{x}{2\pi} & x \in (0, 2\pi] \\ x \geq 2\pi & 1 \end{cases}, F_Y(x) = \begin{cases} x < 0 & 0 \\ \frac{\sqrt{y}}{2\pi} & x \in (0, 4\pi^2] \\ x \geq 4\pi^2 & 1 \end{cases}, \text{求导知 } f_X, f_Y.$$

分布函数 F 性质:

(1) 单调 $\rightarrow$ 不连续点至多可数

(2) 勒贝格分解 $F = c_1 F_d + c_2 F_c + c_3 F_s$ 其中 $c_i \leq 0$, $\sum_i c_i = 1$, F_d 为离散型随机变量的分布函数, F_c 为连续型随机变量的分布函数, F_s 为奇异的。

定义 2.4 随机向量

$X_1, \dots, X_n$ 为 $(\Omega, \mathcal{F}, P)$ 上的随机变量, 称 $\vec{X} = (X_1, \dots, X_n)$ 为 n 维随机向量, $F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$ 为 $\vec{X}$ 的联合分布函数。

离散型: $\vec{X}$ 取值至多可列多个, 联合分布列 $f(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$ 。

连续型: $F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(u_1, \dots, u_n) du_1 \cdots du_n$, f 非负可积, 称 f 为 X 的联合密度函数。

定理 2.4 考虑二维随机向量的联合分布函数 $F(x, y)$:

1. $F(x, y)$ 关于 x, y 均单调增。
2. $F(x, y)$ 关于 x, y 均右连续。
3. $F(x, y)$ 在 x, y 趋近负无穷时极限均为 0, x, y 均趋近正无穷时极限为 1。
4. $x_1 \leq x_2, y_1 \leq y_2$ 时 $F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) = P(X \in (x_1, x_2], Y \in (y_1, y_2]) \geq 0$

注:

(1) 取极限可发现蕴含 1, 反之不然(举例: $F(x) = \begin{cases} 1 & x + y \geq 0 \\ 0 & x + y < 0 \end{cases}$ 满足 1, 2, 3 但不满足 4)。

(2) 若某二元函数满足 2, 3, 4 三条性质, 一定为某随机向量的联合分布函数。

$F_X(x) = P(X \leq x) = \lim_{y \rightarrow +\infty} F(x, y)$ 称为边缘分布。

连续型随机变量 $F_X(x) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(u, v) dv du$, $f_X(x) = \int_{-\infty}^{+\infty} f(x, v) dv$ 称为边缘密度。

例 2.5 三项分布

$\Omega = \{H, T, E\}$, 均匀“三面硬币”, 设扔 n 次后三种次数分别为 H_n, T_n, E_n , 有 $H_n + E_n + T_n = n$, 则 $P((H_n, T_n, E_n) = (h, t, e)) = \frac{n!}{h!t!e!} \frac{1}{3^n}$

例 2.6 $G \subset \mathbb{R}^n$ 为有限区域, 则联合密度函数 $f(x_1, \dots, x_n) = \frac{1}{|G|}, \vec{x} \in G$

特别地, $G = [0, 1]^2$ 时, $f(x, y) = \begin{cases} 1 & (x, y) \in G \\ 0 & (x, y) \notin G \end{cases}$

三 离散型随机变量

§3.1 分布列与独立性

回顾: 离散型随机变量 X 取值至多可列个 $x_1, x_2, \dots$, 记 $p_k = P(X = x_k)$, 则 $\{p_k\}$ 为 X 的分布列。

例 3.1 二项分布

$P(x = k) = C_n^k p^k q^{n-k}$, $p + q = 1$ 时称 X 符合二项分布, 记为 $X \sim B(n, p)$ 。

背景: 抛 n 次硬币, X 为正面向上次数,

例 3.2 几何分布

$P(X = k) = q^{k-1} p$, $p + q = 1$ 时称 X 符合几何分布, 此时 $P(X > k) = q^k$ 。

背景：抛 n 次硬币， X 为第一次正面向上时抛的次数。

几何分布具有**无记忆性**： $P(X - m = k | X > m) = P(X = k)$ 。反之，若取值为 $\mathbb{N}^*$ 的某随机变量满足无记忆性，即对任意 m, k 符合上式，则必须服从几何分布。

例 3.3 泊松分布

$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$, $\lambda > 0$ 时称 X 符合泊松分布，记为 $X \sim P(\lambda)$ 。

背景：网站访问量、百科新词条

*放射性粒子数：体积为 V 的小物块分为 n 等份，每一小块 $\Delta v = \frac{V}{n}$ ，假设每一小块在7.5s内放出1个 α 粒子的概率为 $p = \mu \cdot \Delta v$ ，放出更多概率为0，且各小块放出与否相互独立。

分析： n 块共放出 k 个概率符合二项分布，令 $\lambda = \mu V$ ，则

$P(X = k) = C_n^k p^k (1-p)^{n-k} = \frac{n \cdots (n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$ ，固定 k ，令 n 趋向无穷，此式极限即为 $\frac{\lambda^k}{k!} e^{-\lambda}$ 。由此可知，二项分布可以逼近泊松分布。

定义 3.1 独立性

若 $\forall x, y \in \mathbb{R}, P(X = x, Y = y) = P(X = x)P(Y = y)$ ，则称离散型随机变量 X, Y 独立。

更一般，称 $X_1, \dots, X_n$ 相互独立，若 $\forall x_i \in \mathbb{R}, P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n)$ 。

定理 3.1 离散型随机变量 X, Y 独立，当且仅当 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y) \Leftrightarrow F(x, y) = F_X(x)F_Y(y)$ 。

证明：利用分布列 $f(x, y)$ 与分布函数 $F(x, y)$ 关系，利用求和可证明仅当，利用左极限可证明当。

例 3.4 泊松翻转

抛均匀硬币1次，记 X, Y 为正反出现的次数，计算容易发现不独立。

抛 N 枚均匀硬币， $N \sim P(\lambda)$ ，计算 $f(x, y) = P(X = x, Y = y, N = x + y) = \frac{\lambda^{x+y}}{(x+y)!} e^{-\lambda} \frac{C_{x+y}^x}{2^{x+y}}$
 $= \left(\frac{\lambda}{2}\right)^x \frac{e^{-\lambda/2}}{x!} \left(\frac{\lambda}{2}\right)^y \frac{e^{-\lambda/2}}{y!}$ ，注意到 $f_X(x) = \sum_y f(x, y) = \left(\frac{\lambda}{2}\right)^x \frac{e^{-\lambda/2}}{x!}$ ，由此知 X, Y 独立。

定理 3.2 离散型随机变量 X, Y 独立， g, h 是 $\mathbb{R}$ 上的Borel可测函数，则 $g(X), h(Y)$ 独立。

证明： $P(g(X) = a, h(Y) = b) = P\left(\bigcup_{g(x)=a} \{X = x\}, \bigcup_{h(y)=b} \{Y = y\}\right)$ 分解求和。

§3.2 数学期望

定义 3.2 数学期望

离散型随机变量 X 对应分布列 f ， $\sum_{x: f(x)>0} xf(x)$ 若**绝对收敛**，则称为 X 的数学期望，记为 $E[X]$ 。

* $E[x] = \sum_k x_k p_k$ (原则上 x_i 互不相同，事实上相同不会影响计算)

定理 3.3 佚名统计学家公式

g 为 $\mathbb{R}$ 上函数， $Y = g(X)$ ， X 分布列为 f ，则 $E[Y] = \sum_x g(x)f(x)$ (假定右侧绝对收敛)。

证明：考虑 Y 分布列即可。

定义 3.3 数字特征

离散型随机变量 X 的 k 阶矩为 $m_k = E[X^k]$, k 阶中心矩 $\sigma_k = E[(X - m_1)^k]$ 。

方差 $\text{Var}(X)$ 为二阶中心矩, $\text{Var}(X) = \sum_x (x - m_1)^2 f(x) = E[X^2] - 2m_1 E[X] + m_1^2 = E[X^2] - E^2[X]$ 。

标准差定义为 $\sqrt{\text{Var}(X)}$

例 3.5 Bernoulli分布

$$P(X=1)=p, P(X=0)=q, p+q=1 \Rightarrow E[X]=p, \text{Var}(X)=p-p^2=pq$$

例 3.6 二项分 $X \sim B(n, p)$

$$E[X] = \sum_{k=0}^n k C_n^k p^k q^{n-k} = np \sum_{k=0}^{n-1} C_{n-1}^k p^k q^{n-1-k} = np$$

$$E[X(X-1)] = \sum_{k=0}^n k(k-1) C_n^k p^k q^{n-k} = n(n-1)p^2$$

$$E[X^2] = np(np+q), \text{Var}(X) = npq$$

定理 3.4 数学期望性质

1. 非负性: $X \geq 0 \Rightarrow E[X] \geq 0$

2. 归一性: $E[1] = 1$

3. 线性性: $E[aX + bY] = aE[X] + bE[Y]$

由此, E 可以看作一个期望算子。

线性性证明: 令示性函数 $A_x = \{X = x\}$, 则 $X = \sum_x x I_{A_x}$, $E[X] = \sum_x x P(A_x)$, 对 Y 用 B_y 类似处理,

$$\text{则 } aX + bY = \sum_x x I_{A_x} + \sum_y y I_{B_y} = \sum_{Ax+By} I_{A_x} I_{B_y}.$$

*观点: 扩展至量子物理、非线性期望

定理 3.5 X, Y 独立且期望存在, $E[XY] = E[X]E[Y]$ 。

$$\text{证明: } E[X] = \sum_x x I_{A_x}, E[Y] = \sum_y y I_{B_y} \Rightarrow E[X]E[Y] = \sum_{x,y} xy I_{A_x B_y}.$$

定理 3.6 方差性质

1. $\text{Var}(aX + b) = a^2 \text{Var}(X)$

2. $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2(E(XY) - E(X)E(Y))$, X, Y 独立时即可加。

例 3.7 期望不存在的例子

$$P(X = x_k) = \frac{1}{2^k}, x_k = (-1)^k \frac{2^k}{k}, \text{ 不绝对收敛, } \sum_k x_k p_k = -\ln 2, \text{ 而期望不存在。}$$

若 $P(X = x_k) = 2^{k-1}$, 可发现期望趋向于无穷。

§3.3 协方差

例 3.8 考虑一个随机的 n 元置换 π , 记不动点 $\pi(x) = x$ 的个数为 N , 求分布列 $P(N=r), r=0, 1, \dots, n$ 。

记 $A_k = \{k \text{ 为不动点}\}$, 对应的示性函数为 I_k , 令 $X = \sum_{i_1 < \dots < i_r} I_{i_1} I_{i_2} \dots I_{i_r} (1 - I_{i_{r+1}}) \dots (1 - I_{i_n})$, 其中 i_k 为1到 n 的排列, 则 $X = I_{\{N=r\}}$ 。

$$E[X] = C_n^r E[I_1 \dots I_r (1 - I_{r+1}) \dots (1 - I_n)] = C_n^r \sum_{s=0}^{n-r} (-1)^s C_{n-r}^s \frac{(n-r+s)!}{n!} = \frac{1}{r!} \sum_{s=0}^{n-r} \frac{(-1)^s}{s!}$$

例 3.9 不计算分布列, 求上例中的期望与方差。

$N = I_1 + I_2 + \cdots + I_n$ 。则 $E[N] = nE[I_1] = n \frac{(n-1)!}{n!} = 1, E[N^2] = \sum_{i,j=1}^n E[I_i I_j] = nE[I_1^2] + n(n-1)E[I_1 I_2] = 1 + 1 = 2, \text{Var}(N) = 1$ 。

例 3.10 Erdos 概率方法: 正 17 边形染红 5 个顶点, 证明存在 7 个相邻顶点中至少有 3 个红点。

建立模型, 17 个点中等概率随机取一个, 令 I_k 为 k 为红色的示性函数, 再令 $X(k) = I_{k+1} + \cdots + I_{k+7}$, 则 $E[X] = \frac{35}{17} > 2$, 由此 $P(X > 2) > 0$, 得证。

类似随机变量的情况, 对随机向量有结论: $f(x, y)$ 为 (X, Y) 的联合分布列, $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 的 Borel 可测函数, 则 $E[g(X, Y)] = \sum_{x,y} g(x, y)f(x, y)$ (假定右侧绝对收敛)。

定义 3.4 协方差与相关系数

协方差 $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$

相关系数 $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$, 为 0 时称两变量不相关。

*对 n 维随机向量 $\vec{X} = (X_1, \dots, X_n)$, 协方差矩阵 $\Sigma = (\sigma_{ij}), \sigma_{ij} = \text{Cov}(X_i, X_j)$

性质: 协方差矩阵对称且非负定。

非负定性证明: $\sum_{i,j} t_i t_j \sigma_{ij} = \sum_{i,j} t_i t_j E[(X_i - E[X_i])(X_j - E[X_j])] = E \left[\left(\sum_i t_i (X_i - E[X_i]) \right)^2 \right] \geq 0$

定理 3.7 相关系数性质

1. $|\rho| \leq 1$
2. X, Y 独立或不相关 $\Leftrightarrow \rho = 0$
3. $\rho = \pm 1 \Leftrightarrow P(Y = aX + b) = 1$

定理 3.8 Cauchy 不等式

$(E[XY])^2 \leq E[X^2]E[Y^2]$, 等号成立当且仅当存在不全为 0 实数 a, b 使得 $P(aX = bY) = 1$ 。

证明: 先利用佚名统计学家公式说明 $E[X^2] = 0$ 时可推出 $P(X = 0) = 1$, 从而计算得 $E[XY] = 0$; 若 $E[X^2] > 0$, $E[(Y - tX)^2] = t^2 E[X^2] - 2tE[XY] + E[Y^2] \geq 0$, 利用判别式得证, 取等时再利用 $E[X^2] = 0$ 的条件即可。

例 3.11 多项分布

$\vec{X} = (X_1, \dots, X_r), P(X_1 = k_1, \dots, X_r = k_r) = \frac{n!}{k_1! \cdots k_r!} p_1^{k_1} \cdots p_r^{k_r}$, 其中 $\sum_i p_i = 1, \sum_i k_i = n$ 。

计算 $\text{Cov}(X_i, X_j), \rho(X_i, X_j)$ 。

$i \neq j$ 时 $X_i \sim B(n, p_i), X_i + X_j \sim B(n, p_i + p_j)$, 由此 $E[X_i] = np_i, \text{Var}(X_i) = np_i(1 - p_i), \text{Var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j)$, 利用定理 3.6 可知 $\text{Cov}(X, Y) = \frac{1}{2}(\text{Var}(X + Y) - \text{Var}(X) - \text{Var}(Y)) = -np_i p_j$, 相关系数为 $-\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}}$ 。

§3.4 条件分布与条件期望

定义 3.5 条件分布

(X, Y) 为离散型随机向量, 给定 $X = x$, 且 $P(X = x) > 0$, Y 的条件分布列 $f_{Y|X}(y|x) = P(Y = y|X = x)$, 对应条件分布函数 $F_{Y|X}(y|x) = P(Y \leq y|X = x)$

注: $\sum_y f_{Y|X}(y|x) = 1$, 其亦为一个分布函数。

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}, f_X(x) > 0$$

定义 3.6 条件期望

给定 $X = x$ 下, Y 的条件期望 $\psi(x) = E[Y|X = x] = \sum_y y f_{Y|X}(y|x)$ (假设其绝对收敛), 并称 $\psi(X)$ 为 Y 关于 X 的条件期望, 记为 $E[Y|X]$ 。

定理 3.9 全期望公式

$$E[E[Y|X]] = E[Y] \quad \text{*另一种形式: } E[Y] = \sum_x f_X(x) E[Y|X = x]$$

证明: $E[\psi(X)] = \sum_x \psi(x) f_X(x) = \sum_x f_X(x) \sum_y y f_{Y|X}(y|x) = \sum_{x,y} y f(x, y) = \sum_y y f_Y(y)$, 注意步骤中交换次序要求绝对收敛。

*类似可定义关于事件的条件期望 $E[X|A] = E[X|I_A = 1]$ 。

例 3.12 多项分布的条件期望 $i \neq j, E[X_j|X_i > 0]$

利用全期望公式 $E[X_j] = P(X_i = 0)E[X_j|X_i = 0] + P(X_i > 0)E[X_j|X_i > 0]$ 。又由于 $P(X_j = k|X_i = 0) = \frac{P(X_j = k, X_i = 0)}{P(X_i = 0)} = C_n^k \left(\frac{p_j}{1-p_1}\right)^k \left(1 - \frac{p_j}{1-p_1}\right)^{n-k}$, 因此 $E[X_j|X_i = 0] = \frac{np_j}{1-p_i}$, 进而算出 $E[X_j|X_i > 0] = \frac{np_j(1 - (1-p_i)^{n-1})}{(1 - (1-p_i)^n)}$ 。

例 3.13 鸟下 N 枚蛋, $N \sim P(\lambda)$, 每颗蛋独立以概率 p 变为小鸟, 记 K 为小鸟数, 计算 $E[K|N]$ 、 $E[K]$ 、 $E[N|K]$ 。

记 $q = 1 - p$, 由于 $f_{K|N}(k|n) = C_n^k p^k q^{n-k}$, 因此 $E[K|N = n] = np$, 即 $E[K|N] = np$, 进而 $E[K] = E[E[K|N]] = pE[N] = p\lambda$ 。

而 $f_{N|K}(n|k) = \frac{P(N = n, K = k)}{P(K = k)} = \frac{P(K = k|N = n)P(N = n)}{\sum_m P(K = k|N = m)P(N = m)} = \frac{(\lambda q)^{n-k} e^{-\lambda q}}{(n-k)!}$, 由此 $E[N|K = k] = \sum_{n \geq k} n \frac{(\lambda q)^{n-k} e^{-\lambda q}}{(n-k)!} = \sum_{n \geq 0} (n+k) \frac{(\lambda q)^n e^{-\lambda q}}{n!} = \lambda q + k$, 即 $E[N|K] = \lambda q + K$ 。

定理 3.10 记 $\psi(X) = E[Y|X]$, g 保证所述期望均存在, 则 $E[\psi(X)g(X)] = E[Yg(X)]$ 。

§3.5 随机游走

$S_0 = a, S_n = S_{n-1} + X_n = S_0 + \sum_{i=1}^n X_i$, $\{X_i\}$ 相互独立且同分布, 取值为 ± 1 , $P(X_i = 1) = p, P(X_i = -1) = q, p + q = 1$ 。

*直线上简单随机游走, 当 $p = \frac{1}{2}$ 时称为对称的。

例 3.14 自由随机游走, $S_0 = a$, 求 $P(S_n = b)$, 已知 $2|a+b+n$ 。

设向右游走次数为 r , 向左游走次数为 l , 则 $\begin{cases} r+l=n \\ r-l=b-a \end{cases} \Rightarrow r = \frac{n+b-a}{2}$, 因此 $P(S_n = b) = C_n^{(n+b-a)/2} p^{(n+b-a)/2} q^{(n-b+a)/2}$ 。

定理 3.11 简单随机游走性质

1. 空间齐性 $P(S_n = j+b|S_0 = a+b) = P(S_n = j|S_0 = a)$
2. 时间齐性 $P(S_{n+m} = j|S_m = a) = P(S_n = j|S_0 = a)$
3. 马氏性 $P(S_{m+n} = j|S_0 = j_0, \dots, S_m = j_m) = P(S_{m+n} = j|S_m = j_m)$

*要求等式两边有意义

证明：利用 $P(S_n = j | S_0 = a) = P(\sum_{i=1}^n X_i = j - a | S_0 = a)$ 转化即可计算得出结果。

*轨道计数

平面表示 $\{(n, S_n) : n = 0, 1, \dots\}$

记 $N_n(a, b)$ 为 $(0, a) \rightarrow (n, b)$ 轨道个数, $N_n^\circ(a, b)$ 为 $(0, a) \rightarrow (n, b)$ 且访问 x 轴至少一次的轨道个数。

定理 3.12 反射原理

若 $a, b > 0$, 则 $N_n^\circ(a, b) = N_n(-a, b)$ 。

证明：寻找第一个交点, 利用一一对应。

定理 3.13 $N_n(a, b) = C_n^{(n+b-a)/2}$

*关心问题：返回出发点、游走最远距离、首次击中某点

定理 3.14 投票定理

$b > 0$, 则 $(0, 0) \rightarrow (n, b)$ 不再过 x 轴的轨道个数为 $(1, 1) \rightarrow (n, b)$ 不过 x 轴的轨道个数, 即 $N_{n-1}(1, b) - N_{n-1}^\circ(1, b) = \frac{b}{n} N_n(0, b)$ 。

例 3.15 A 得票 a , B 得票 $b < a$, 求 A 得票始终大于 B 的概率。

问题可化为 $(0, 0)$ 到 $(a+b, a-b)$ 轨道中不再过 x 轴轨道数与总数之比, 为 $\frac{a-b}{a+b}$ 。

定理 3.15 不返回出发点

$S_0 = 0, n \neq 1$, 则 $P(S_1 \dots S_n \neq 0, S_n = b) = \frac{|b|}{n} P(S_n = b)$ 。

由此可推得 $P(S_1 \dots S_n \neq 0) = \frac{E[|S_n|]}{n}$

证明：利用投票定理计算即可。

*记最到达的最右端 $M_n = \max\{S_i : 0 \leq i \leq n\}$, $S_0 = 0 \Rightarrow M_n \geq 0$

定理 3.16 最右端

$$P(M_n \geq r, S_n = b) = \begin{cases} P(S_n = b) & b \geq r \\ \left(\frac{q}{p}\right)^{r-b} P(S_n = 2r - b) & b < r \end{cases}$$

证明：考虑第一次到达 r 的点, 反射其后的部分, 即可与 $S_n = 2r - b$ 的轨道数量一一对应, 而反射产生的概率差别为 $\left(\frac{q}{p}\right)^{r-b}$ 。

*推论： $p = q$ 时可以计算出 $P(M_n \geq r) = P(S_n = r) + 2P(S_n \geq r + 1)$ 。

定理 3.17 首中时定理

$S_0 = 0$, 时刻 n 首次击中 b 概率为 $f_b(n) = \frac{|b|}{n} P(S_n = b)$ 。

证明：不妨设 $b > 0$, 注意条件等价于 $M_{n-1} = S_{n-1} = b - 1, S_n = b$ 即可算出结果。

定理 3.18 反正弦律

对称随机游走, $S_0 = 0$, 记 $T_{2n} = \max\{0 \leq i \leq 2n : S_i = 0\}$, 则 $P(T_{2n} = 2k) = P(S_{2k} = 0)P(S_{2n-2k} = 0)$

证明: 利用 $P(S_{2k+1} \dots S_{2n} \neq 0 | S_{2k} = 0) = P(S_1 \dots S_{2n-2k} \neq 0 | S_0 = 0)$ 。此外 $P(S_1 \dots S_{2m} \neq 0) = P(S_2 \dots S_{2m} \neq 0 | S_1 = 1) = P(\text{第 } 2m \text{ 次后首次击中 } -1)$, 由此可计算出结论。

*此分布称为反正弦律

利用 Stirling 公式可计算 $P(T_n \leq 2xn) \sim \frac{1}{n} \sum_{\frac{k}{n} < x} \frac{1}{\pi \sqrt{\frac{k}{n}(1-\frac{k}{n})}} \sim \int_0^x \frac{1}{\pi \sqrt{u(1-u)}} du = \frac{2}{\pi} \arcsin \sqrt{x}$, $\frac{T_{2n}}{2n}$ 渐近分布 $\frac{2}{\pi} \arcsin \sqrt{x}$ 。

$\mathbb{Z}^d$ 上的随机游走: $S_n = S_{n-1} + X_n = S_0 + \sum_{i=1}^n X_i$, 向量 $\{X_i\}$ 相互独立且同分布, 仅有一个不为 0 且取值为 ± 1 的分量。

例 3.16 平面上对称随机游走, 求 $P(S_{2n} = 0)$ 。

考虑上下左右次数知结果为 $\sum_{k=0}^n \frac{(2n)!}{k!k!(n-k)!(n-k)!} \frac{1}{4^{2n}} = C_{2n}^n \frac{1}{4^{2n}} \sum_{k=0}^n (C_n^k)^2 = \frac{1}{4^{2n}} (C_{2n}^n)^2$ 。

§3.6 母函数

*数列的母函数: $\{a_i, i \in \mathbb{N}\}$, 母函数 $G_a(s) = \sum_{i=0}^{\infty} a_i s^i$, 如 C_n^i 对应 $(1+s)^n$

卷积: $c_n = \sum_{k=0}^n a_k b_{n-k}$, 记为 $c = a * b$, 验证有 $G_c(s) = G_a(s)G_b(s)$ 。

例 3.17 随机游走 $S_0 = 0$, 求 $S_{2n} = 0, S_i \geq 0$ 的轨道个数 C_n 。

设首次返回原点为 $2k$ 时, 则考虑第一步后可知从 0 到 $2k$ 的轨道个数为 C_{k-1} , 因此有 $C_n = \sum_{k=0}^{n-1} C_{k-1} C_{n-k}$,

于是 $G(s) - 1 = sG^2(s)$, 考虑合理解知 $G(s) = \frac{1 - \sqrt{1-4s}}{2s}$, 展开可得 $C_n = \frac{(2n)!}{n!(n+1)!}$ (卡特兰数)。

定义 3.7 非负整值随机变量的母函数

$$G_X(s) = E[S^X] = \sum_{i=1}^{\infty} s^i P(X=i) = \sum_{i=1}^{\infty} f(i)s^i$$

*其收敛半径 $R \geq 1$, 在收敛域内可微

* $G(0) = P(X=0), G(1) = 1, f(i) = \frac{G^{(i)}(0)}{i!}$

*只要系数非负, $G(1) = 1$, 即可看作概率母函数

1. 二项分布 $B(n, p)$ 母函数 $(ps + q)^n$

2. 几何分布 $P(X=i) = pq^{i-1}$ 母函数 $\frac{ps}{1-qs}$

3. 泊松分布 $P(\lambda)$ 母函数 $e^{\lambda(s-1)}$

定理 3.19 母函数与数字特征矩

1. $E[X] = G'(1)$

2. $E[x(x-1)\dots(x-k+1)] = G^{(k)}(1)$

3. $\text{Var}(X) = G''(1) - G'(1)(1 - G'(1))$

此处 $G^{(k)}(1)$ 指 $\lim_{x \rightarrow 1^-} G^{(k)}(x)$, 由阿贝尔定理此定义合理。

证明: 直接求导即可说明。

定理 3.20 随机变量卷积

设非负整值随机变量 $X_1, \dots, X_n$ 互相独立, $Y = \sum_{k=1}^n X_k$, 则 $G_Y = \prod_{k=1}^n G_{X_k}$ 。

证明: 利用卷积归纳即可。

定理 3.21 复合分布

设 X_i 独立同分布, 母函数 G_X , N 与 X_i 独立, 母函数 G_N , $Y = \sum_{k=1}^N X_k$ 母函数为 $G_N(G_X)$ 。

证明: 利用全概率公式分解计算。

定义 3.8 联合母函数

X, Y 联合母函数 $G(s, t) = E[s^x t^y] = \sum_{i,j} s^i t^j P(X=i, Y=j)$ 。

定理 3.22 X, Y 独立等价于 $G(s, t) = G_X(s)G_Y(t)$

证明: 比较系数。

例 3.18 掷三颗均匀骰子, 求点数和分布。

设每个骰子点数 X_i , 和为 Y , 则 $G_Y(s) = G_X^3(s) = \frac{s^3(1-s^6)^3}{6^3(1-s)^3}$, 考虑每项系数即为分布。

*二项分布再生性: 独立变量 $X_1 \sim B(n_1, p), X_2 \sim B(n_2, p)$, 考虑母函数可发现 $X_1 + X_2 \sim B(n_1 + n_2, p)$ 。

泊松分布也有再生性: X_1, X_2 独立泊松分布 $P(\lambda_1), P(\lambda_2)$, 其和分布为 $P(\lambda_1 + \lambda_2)$ 。

*离散随机变量的母函数是否可以定义为 $G(s) = \sum_i s^{x_i} P(X = x_i)$? 其他类型随机变量呢? (第五章内容)

四 连续型随机变量

§4.1 独立性

X 连续型随机变量, 有密度函数 f , 非负且在实轴上积分为1, 分布函数 $F(x) = \int_{-\infty}^x f(u)du$ 。

* $P(X=x)=0, P(a < X < b) = \int_a^b f(u)du$

*均匀分布 $X \sim U[a, b]$

$f(x) = \frac{1}{b-a}, x \in [a, b]$

*指数分布 $X \sim \text{Exp}(\lambda)$

$f(x) = \lambda e^{-\lambda x}, F(x) = 1 - e^{-\lambda x}$

背景: $P(t \leq X \leq t + \Delta t | X > t) = \lambda \Delta t$ 微分方程(如半衰期等)

也具有无记忆性

*正态分布 $X \sim N(\mu, \sigma^2)$

$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right)$

μ 为对称轴且为最大值点

$\mu \pm \sigma$ 为拐点

背景: 随机误差分布

Wigner 半圆律

$f(x) = \frac{1}{2\pi\sigma^2} \sqrt{4\sigma^2 - x^2}$

背景: 随机矩阵、自由概率论(和正态分布同地位)

例 4.1 半圆律中 $P(X \in (0, \sigma))$

积分可得结果为 $\frac{1}{6} + \frac{\sqrt{3}}{4\pi}$

例 4.2 $X \sim N(0, 1)$, 求 $Y = X^2$ 密度函数

$P(Y \leq y) = P(-\sqrt{y} < X < \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$, 求导得密度函数为 $\frac{e^{-y/2}}{\sqrt{2y\pi}}$ 。

*正态分布常用 $\phi(x)$ 表示密度函数, $\Phi(x) = \int_{-\infty}^x \phi(u) du$, $N(0, 1)$ 称标准正态分布。

* $X \sim U(0, 1)$, 计算可得 $Y = \Phi^{-1}(X) \sim N(0, 1)$

定义 4.1 一般随机变量的独立性

$X_1, \dots, X_n$ 满足 $P(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{k=1}^n P(X_k \leq x_k)$, 则称随机变量相互独立。

定理 4.1 等价刻画 $X_1, \dots, X_n$ 相互独立等价于 $\forall B_1, \dots, B_n \in \mathcal{B}(\mathbb{R}), P(\forall i, X_i \in B_i) = \prod_{k=1}^n P(X_k \in B_k)$

(证明须更多测度论知识)

定理 4.2 设 $g_1, \dots, g_n$ 均 Borel 可测, $X_1, \dots, X_n$ 独立, 则 $g_1(X_1), \dots, g_n(X_n)$ 独立。

证明: 利用 Borel 集原像为 Borel 集可由上一定理说明。

定理 4.3 连续型随机变量的独立

$X_1, \dots, X_n$ 密度函数 $f_1, \dots, f_n$, 独立等价于 $f_1 \dots f_n$ 为联合密度函数。

证明: 利用多重积分性质计算。

*卷积: X, Y 独立时, 称 $Z = X + Y$ 为其卷积, $f_Z = f_X * f_Y$

定理 4.4 (X, Y) 密度函数为 $f(x, y)$, 则 $f_{X+Y}(x) = \int_{\mathbb{R}} f(x, z-x) dx = \int_{\mathbb{R}} f(z-y, y) dy$

证明: 利用二重积分变量代换公式计算。

* X, Y 独立时, $f(x, y) = f_X(x)f_Y(y)$, 由此 $X + Y$ 密度函数成为两函数卷积

例 4.3 X, Y 独立标准正态分布, 求 $X + Y$ 分布函数。

利用定理计算积分得 $X + Y \sim N(0, 2)$ 。

§4.2 期望

定义 4.2 连续型随机变量的期望

当 $\int_{\mathbb{R}} xf(x) dx$ 绝对收敛, 定义其为 X 的数学期望 $E[X]$ 。

定理 4.5 X 有密度函数 f , 期望存在, 则 $E[X] = \int_0^\infty (1 - F_X(x)) dx - \int_{-\infty}^0 F_X(x) dx$ 。

证明: 利用分部积分公式计算。

定理 4.6 复合的期望

g 为 Borel 可测函数, X 与 $g(X)$ 均为连续型随机变量, 则 $E[g(X)] = \int_{\mathbb{R}} g(x)f_X(x) dx$

证明: 利用上一定理由 F 推导计算。

定理 4.7 连续型随机向量情形

g 是二元 Borel 可测函数, X, Y 联合分布 $f(x, y)$, $g(X, Y)$ 为连续型随机向量且期望存在, 则 $E[g(X, Y)] = \int_{\mathbb{R}^2} g(x, y) f(x, y) dx dy$ 。特别地, 当 $g = ax + by$ 时代入可发现 $E[aX + bY] = aE[X] + bE[Y]$ 。

*可用于计算协方差

矩 $m_k = E[X^k]$, 方差 $\text{Var}(X) = E[X^2] - E^2[X]$

协方差 $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$, 相关系数 $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$

定理 4.8 柯西不等式

(X, Y) 连续型随机向量, 且 $E[X^2], E[Y^2]$ 存在, 则 $(E[XY])^2 \leq E[X^2]E[Y^2]$

证明: 与离散情形相同构造。

*由此知 $|\rho| \leq 1$, 当 $P(Y = aX) = 1$ 时可取等。

例 4.4 正态分布

积分计算期望: $\int_{\mathbb{R}} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx = \int_{\mathbb{R}} (x-\mu) \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx + \mu$
 $= \int_{\mathbb{R}} x \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}x^2\right) dx + \mu = \mu$ 。
 同样直接代入计算可知方差为 σ^2 。

例 4.5 柯西分布

$f(x) = \frac{1}{\pi(1+x^2)}$, 积分可知期望不存在。

例 4.6 二元正态分布

$f(x, y) = \frac{1}{\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right), \rho \in (-1, 1)$

计算可知 $f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$, 因此 $X \sim N(0, 1)$, 由对称性知 Y 亦如此, $E[X] = E[Y] = 0$ 。

$\text{Cov}(X, Y) = E[XY] = \int_{\mathbb{R}^2} xy f(x, y) dx dy$ 将 xy 写为 $x(y - \rho x) + \rho x^2$, 可发现左侧项积分为 0, 考虑右侧按先 y 后 x 积分得 ρ 。

此时 ρ 即为相关系数, $\rho = 0 \Leftrightarrow X, Y$ 独立。

条件期望: 直观上考虑 $P(Y \leq y | x < X \leq x + \Delta x), \Delta x \rightarrow 0$, 可得 $\frac{\int_{-\infty}^y f(x, u) du}{f_X(x)}$

定义 4.3 设 (X, Y) 联合密度函数 $f(x, y)$, X 分布为 $f_X(x)$

条件密度 $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$ 关于 y 构成密度函数。

$F_{Y|X}(y|x) = \frac{\int_{-\infty}^y f(x, u) du}{f_X(x)}$

条件期望 $E[Y|X=x] = \int_{\mathbb{R}} y f_{Y|X}(y|x) dy$, 由此有随机变量 $E[Y|X]$ 。

定理 4.9 期望形式的全概率公式

$E[E[Y|X]] = Y$

例 4.7 二元正态分布的条件期望

关于 y 的分布为 $N(\rho x, 1 - \rho^2)$, 由此 $E[Y|X] = \rho X$ 。

§4.3 多元正态分布

一般分析结论: 随机向量 (X_1, X_2) 密度函数 $f(x_1, x_2)$, 映射 $T: (X_1, X_2) \rightarrow (Y_1, Y_2)$, T 为将 $D \subset \mathbb{R}^2$ 映射到 $R \subset \mathbb{R}^2$ 的一一映射, $T: (x_1, x_2) \rightarrow (y_1(x_1, x_2), y_2(x_1, x_2))$, 设其逆映射 $(x_1(y_1, y_2), x_2(y_1, y_2))$ 有连续偏导数。则 $f_{Y_1, Y_2}(y_1, y_2) = f(x_1, x_2)|J|I_{T(D)}$, 其中 J 是 (x_1, x_2) 的Jacobi行列式。

*证明: 利用变量替换, 考虑 (Y_1, Y_2) 取在Borel集 $(-\infty, y_1] \times (-\infty, y_2]$ 中的概率。

(若在 $P(x_1, x_2 \in D_0) = 1, D_0 \subset D$ 上一一映射, 结论仍成立)

例 4.8 X, Y 独立 $\sim N(0, 1)$, $X = R \cos \Theta, Y = R \sin \Theta, R \geq 0, \Theta \in [0, 2\pi]$, 求 R, Θ 分布。

$f_{X, Y}(x, y) = \frac{1}{2\pi} e^{-x^2/2 - y^2/2}$, 由此 $f_{R, \Theta}(r, \theta) = \frac{1}{2\pi} r e^{-r^2/2}, r \geq 0, \theta \in (0, 2\pi]$, 有 $f_{\Theta}(\theta) = \frac{1}{2\pi}, f_R(r) = r e^{-r^2/2}$ 。

* U_1, U_2 独立 $\sim U(0, 1)$, 则 $X = \sqrt{-2 \ln U_1} \cos(2\pi U_2), Y = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$ 为独立标准正态分布。

一元正态分布 $N(\mu, \sigma^2)$, 密度函数 $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$

二元正态分布 $f(x, y) = \frac{1}{\sqrt{2\pi(1-\rho^2)}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right)$

一般情况: $C_n e^{-Q(x_1, \dots, x_n)}$ 二次型 $Q = \sum_{i,j} x_i x_j A_{ij}, A^T = A$, 需加条件

定义 4.4 多元正态分布

$\vec{X} = (X_1, \dots, X_n)$ 密度函数 $f(\vec{x}) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp(-\frac{1}{2}(\vec{x} - \vec{\mu})\Sigma^{-1}(\vec{x} - \vec{\mu})^T)$, $\Sigma = (\sigma_{ij})$ 正定, 则记 $\vec{X} \sim N(\vec{\mu}, \Sigma)$

* $n = 2$ 时可简化表达

定理 4.10 参数性质

设 $\vec{X} \sim N(\vec{\mu}, \Sigma)$, 则

1. $E[\vec{X}] = \vec{\mu}$

2. $E[(\vec{X} - \vec{\mu})^T(\vec{X} - \vec{\mu})] = \Sigma$, 即 $\sigma_{ij} = \text{Cov}(X_i, X_j)$

证明: 设 $\Sigma = B^T \Lambda B$ 为正交相似对角化, 分析计算。

定理 4.11 线性变换下不变性

$\vec{X} \sim N(\vec{\mu}, \Sigma)$, D 为 n 阶可逆方阵, 则 $\vec{X}D \sim N(\vec{\mu}D, D^T \Sigma D)$ 。

证明: 对分量分别计算可知结论。

定理 4.12 $\vec{X} \sim N(\vec{\mu}, \Sigma)$, $\Sigma = \text{diag}(\Sigma_1, \Sigma_2)$, 两分块均为方阵, 将向量与期望对应拆分为 $\vec{X}_1, \vec{X}_2$ 与 $\vec{\mu}_1, \vec{\mu}_2$, 则 $\vec{X}_1 \sim N(\vec{\mu}_1, \Sigma_1), \vec{X}_2 \sim N(\vec{\mu}_2, \Sigma_2)$ 。

证明: 分离变量得结果。

定理 4.13 $\vec{X} \sim N(\vec{\mu}, \Sigma)$, $\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$, 将随机向量与期望对应拆分为 $\vec{X}_1, \vec{X}_2$ 与 $\vec{\mu}_1, \vec{\mu}_2$, 则 $\vec{X}_1 \sim N(\vec{\mu}_1, \Sigma_{11}), \vec{X}_2 \sim N(\vec{\mu}_2, \Sigma_{22})$ 。

证明: 对角化后利用分部积分计算。

定理 4.14 更广泛的线性变换下不变性

$\vec{X} \sim N(\vec{\mu}, \Sigma)$, D 为 $n \times m$ 阶列满秩方阵, 则 $\vec{X}D \sim N(\vec{\mu}D, D^T \Sigma D)$ 。

证明: 与之前类似, 拆分计算。

定理 4.15 独立性

$\Sigma = \text{diag}(\Sigma_1, \Sigma_2)$, 各分量相互独立当且仅当协方差矩阵对角。

证明: 分离变量得结果。

$$* \text{定义均值 } \bar{X} = \frac{X_1 + \cdots + X_n}{n}, \text{ 方差 } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

定义 4.5 卡方分布

当密度函数 $f(x) = \frac{1}{2^{d/2}\Gamma(d/2)} x^{d/2-1} e^{-x/2}, x > 0$, 称 X 服从 d 个自由度卡方分布, 记为 $X \sim \chi^2(d)$ 。

定理 4.16 卡方分布性质

$Y_1, \dots, Y_d$ 独立同分布 $N(0, 1)$, 则 $\sum_{i=1}^d Y_i^2 \sim \chi^2(d)$ 。

证明: 利用极坐标换元计算。

定理 4.17 均值、方差性质

设 X_i 独立同分布 $N(\mu, \sigma^2)$, 则:

1. $\bar{X} \sim N(\mu, \sigma^2/n)$
2. $(n-1)/\sigma^2 S^2 \sim \chi^2(n-1)$
3. $\bar{X}, S^2$ 独立

复平面二维随机向量: $Z = X + Yi$

$$E[Z] = E[X] + iE[Y]$$

复高斯分布: $N_{\mathbb{C}}(\mu, \sigma^2), \mu \in \mathbb{C}, \sigma > 0$, 联合密度 $f(z) = \frac{1}{\pi\sigma^2} \exp\left(-\frac{1}{\sigma^2}|z - \mu|^2\right)$ 。

$$\text{结论: } Z \sim N_{\mathbb{C}}(0, 1) \Rightarrow E[Z^k \bar{Z}^l] = \begin{cases} k! & k = l \\ 0 & k \neq l \end{cases}$$

五 中心极限定理

§5.1 一般随机变量的期望

1. 记号准备

对随机变量 X 与分布函数 F , 离散型/连续型具有分布列/分布函数 f , 从而对 $xf(x)$ 求和/积分可得期望。而由于 dF 分别为 $F(x) - F(x^-)/f(x)dx$, 期望可统一写为 $E[X] = \int_{\mathbb{R}} x dF$, 佚名统计学家公式也可写为 $E[g(X)] = \int_{\mathbb{R}} g(x) dF$ 。

2. 抽象积分

对一般 $(\Omega, \mathcal{F}, P)$, 随机变量 X 与分布函数 F , 如何定义 $E[X]$?

STEP 1 对简单(取有限个值)随机变量

可记为 $X = \sum_{i=1}^n x_i I_{A_i}$, $A_1, \dots, A_n$ 为 Ω 的划分, 则 $E[X] = \sum_{i=1}^n x_i P(A_i)$ 。

STEP 2 对非负随机变量

存在单调增的简单随机变量列, 收敛到此随机变量: 记 $X_n = nI_{A_n} + \sum_{j=1}^{n2^n} \frac{j-1}{2^n} I_{A_{nj}}$, 其中 $A_{nj} = \{\frac{j-1}{2^n} \leq X < \frac{j}{2^n}\}$, $A_n = \{X \geq n\}$ 。

再说明若简单随机变量序列 X_n, Y_n 均单调增收敛至 X ，则期望的极限相同(此处相同包含正无穷，由此可由期望的极限定义 X 的期望)。

STEP 3 对一般随机变量

将一般随机变量 X 写为 $X^+ - X^-$, $X^+ = \max\{X, 0\}$, $X^- = -\max\{-X, 0\}$ ，当 $E[X^+], E[X^-]$ 至少一个有限时，可定义 $E[X] = E[X^+] - E[X^-]$ 。特别地，若两者都有限，则称 X 的数学期望存在。

*统一记号为 $E[X] = \int_{\Omega} X dP$ 或 $\int_{\Omega} X(\omega)P(d\omega)$

3 期望性质

非负性： $X \geq 0 \Rightarrow E[X] \geq 0$ (由定义过程知成立)

规范性： $c \in \mathbb{R} \Rightarrow E[c] = c$

线性性： $E[aX + bY] = aE[X] + bE[Y]$

“连续性”： X_n 趋向 X (或偏移的概率为0)，只要满足以下条件之一即有期望亦有极限：

1. 单调收敛： X_n 单调
2. 控制收敛： $|X_n| \leq Y, E[Y] < \infty$
3. 有界收敛： $|X_n| \leq c, c \in \mathbb{R}$

4 Lebesgue-Stieltjes积分

对随机变量 X 与分布函数 F ，引入 $(\mathbb{R}, R(\mathbb{R}))$ 上概率测度 $\mu_F((a, b]) = F(b) - F(a)$ ，则 $(\mathbb{R}, R(\mathbb{R}), \mu_F)$ 构成概率空间。对Borel可测函数 g ，有抽象积分 $\int g dF$ ，称为Lebesgue-Stieltjes积分。

有结论： $E[g(X)] = \int g dF$ 。

证明：回到三步的定义方式逐步证明。

*此结论对多元也成立

***Fatou引理**： X_i 非负随机变量，则 $E[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} E[X_n]$

5 独立随机变量乘积期望与期望乘积相同

定理 5.1 X, Y 为独立随机变量，且期望与乘积的均存在，则 $E[XY] = E[X]E[Y]$

证明：

对简单随机变量：直接拆分计算即可。

对非负随机变量：注意到可取出两列递增的独立简单随机变量趋向 X_n 与 Y_n ，由此得证。

对一般随机变量：利用线性性拆分计算即可。

§5.2 特征函数

*非负整值母函数定义： $G_X(s) = \sum_{k=0}^{\infty} P(X = k) s^k = E[s^X]$

当 $s = e^t$ ，有矩母函数 $M_X(t) = E[e^{tX}]$

* “好”的情形：存在0的邻域使矩母函数存在

* 不好的例子： $f(x) = \frac{1}{\pi(1+x^2)}$

定义 5.1 X, Y 为 $(\Omega, \mathcal{F}, P)$ 上随机变量，称 $Z = X + Yi$ 为复随机变量。

(1) 实质为二维随机向量

(2) Z_1, Z_2 独立, 指 (X_1, Y_1) 与 (X_2, Y_2) 独立, 即 $P(X_1 \leq x_1, Y_1 \leq y_1, X_2 \leq x_2, Y_2 \leq y_2) = P(X_1 \leq x_1, Y_1 \leq y_1)P(X_2 \leq x_2, Y_2 \leq y_2)$ 。

(3) $E[Z] = E[X] + iE[Y]$

(4) Z_i 相互独立时, $E[Z_1 \dots Z_n] = E[Z_1] \dots E[Z_n]$ 。

定义 5.2 特征函数

$\phi(t) = E[e^{itX}]$, 有时用 $\phi_X(t)$ 表示。

(1) $\phi(t) = E[\cos(tX)] + iE[\sin(tX)]$

(2) 由于 $|e^{itx}| = 1$, $\phi(t)$ 总存在。

(3) $\phi(t) = \int_{\mathbb{R}} e^{itx} dF(x)$, 有分布函数时可写为 $\int_{\mathbb{R}} e^{itx} f(x) dx$ 。

定理 5.2 基本性质

1. $\phi(0) = 1, |\phi(t)| \leq 1, \overline{\phi(t)} = \phi(-t)$

2. ϕ 在 $\mathbb{R}$ 上一致连续。

3. 非负定性: $t_i \in \mathbb{R}, z_i \in \mathbb{C}$, 有 $\sum_{j,k=1}^n \phi(t_j - t_k) z_j \overline{z_k} \leq 0$ 。

证明:

2. $|\phi(t+h) - \phi(t)| \leq \int_{\mathbb{R}} |e^{itx}(e^{ihx} - 1)| dF \leq \int_{\mathbb{R}} |e^{ihx} - 1| dF$, 有界收敛定理可知一致趋于 0。

3. 原式 = $E\left[\left|\sum_j z_j e^{it_j x}\right|^2\right] \leq 0$ 。

*满足定理 5.2 三条性质的函数必为某随机变量的特征函数

定理 5.3 $E[|X|^k] < \infty$, 则 $\forall j < k, \phi^{(j)}(0) = i^j E[X^j]$, 进而 $\phi(t) = \sum_{j=0}^k \frac{(it)^j}{j!} E[X^j] + o(t^k)$ 。

证明: 由题 6.5.4 知 $E[|X|^j] < \infty$, 由此积分与求导可交换, 再由求导结果可知成立。

定理 5.4 两变量特征函数关系

1. $Y = aX + b$ 时 $\phi_Y(t) = e^{ibt} \phi_X(at)$ 。

2. X, Y 独立时 $\phi_{X+Y}(t) = \phi_X(t) \phi_Y(t)$ 。

证明: 直接计算即可。

定义 5.3 多元特征函数

$\vec{X} = (X_1, \dots, X_n)$ 的特征函数为 $\phi_{\vec{X}}(\vec{t}) = E[e^{i \sum_j t_j X_j}]$ 。

定理 5.5 独立性

X, Y 独立当且仅当 $\phi_{X,Y}(s, t) = \phi_X(s) \phi_Y(t)$ 。

证明: 左推右可直接计算, 右推左需要反转公式(见下节)。

例 5.1 Bernoulli 分布

$\phi(t) = pe^{it} + q$

由此亦可知二项分布母函数为 $(pe^{it} + q)^n$

*对非负整值随机变量, 母函数 G , 则 $G(e^{it})$ 即为特征函数。

例 5.2 指数分布

$$f(x) = \lambda e^{\lambda x}, x > 0$$

$$\phi(t) = \frac{\lambda}{\lambda - it}$$

证明：可分别计算实部虚部积分，亦可通过复分析直接计算。

例 5.3 标准正态分布 $N(0, 1)$

$$\phi(t) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} e^{itx - x^2/2} dx = e^{-t^2/2}$$

证明：“物理方法”假设 it 为实数，再解析延拓；“数学方法”计算导数说明。

* $N(\mu, \sigma^2)$ 的分布函数为 $e^{i\mu t - \sigma^2 t^2/2}$

例 5.4 多元正态分布 $N(\vec{\mu}, \Sigma)$

$$\phi(\vec{t}) = \exp(i\vec{\mu}\vec{t}^T - \vec{t}^T \Sigma \vec{t}^T)$$

证明：设 $Y = \vec{X} \cdot \vec{t}^T$ ，将其化为一元正态分布的情况。

例 5.5 均匀分布 $U(-1, 1)$

$$\phi(t) = \frac{\sin t}{t}$$

§5.3 反转与连续性定理**定理 5.6** 反转公式

$$-\infty < a < b < \infty, \frac{F(b) + F(b^-)}{2} - \frac{F(a) + F(a^-)}{2} = \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{2\pi it} \phi(t) dt$$

理解：类似傅里叶反变换

证明：记极限中的积分为 I_T ， $I_T = \int_{-T}^T \frac{e^{-iat} - e^{-ibt}}{2\pi it} \int_{\mathbb{R}} e^{itx} dF dt$ ，由 Fubini 定理积分符号可交换，由

积分区域对称可转化为 $\int_{\mathbb{R}} g_T(x) dF$ ， $g_T(x) = \frac{1}{\pi} \int_0^T \left(\frac{\sin t(x-a)}{t} - \frac{\sin t(x-b)}{t} \right) dt$ 。由于 $\int_0^{+\infty} \frac{\sin tx}{\pi t} =$

$$\begin{cases} 1/2 & x > 0 \\ 0 & x = 0, \quad g_T(x) \text{ 有界, 由控制收敛定理其极限为} \\ -1/2 & x < 0 \end{cases} \begin{cases} 1 & x \in (a, b) \\ 1/2 & x = a, b \\ 0 & \text{其他} \end{cases}, \text{ 因此结果为 } P(X \in (a, b)) +$$

$\frac{P(X=a) + P(X=b)}{2}$ ，即为左侧。

*推论：特征函数相同即可知同分布

证明：记 C_F 为 F 连续点， $\mathbb{R} \setminus C_F$ 至多可数。让 $a, b \in C_F, a \rightarrow -\infty$ ，可唯一确定 $F(b)$ ，由此连续点已唯一确定。再用连续点从右侧逼近可唯一确定不连续点处。

定理 5.7 假设随机向量对任何长方体，落入其表面概率为 0，则有：

$$P(a_j < X_j \leq b_j, j = 1, \dots, n) = \lim_{T_i \rightarrow \infty} \int_{-T_n}^{T_n} \dots \int_{-T_1}^{T_1} \prod_{j=1}^n \frac{e^{-ia_j t} - e^{-ib_j t}}{2\pi i t_j} \phi(t_1, \dots, t_n) dt_1 \dots dt_n$$

*由此即可说明特征函数可分离变量时随机变量独立

例 5.6 求 $\cos t$ 对应的分布函数。

可构造出 $P(X=1) = P(X=-1) = \frac{1}{2}$ ，由此分布函数即为结果。

*对随机变量 X_n ，分布函数 F_n ，特征函数 ϕ_n ， F_n, ϕ_n 收敛性关系？

例 5.7 $X_n = \frac{1}{n}$, 分布函数的极限为 $\begin{cases} 1 & x > 0 \\ 0 & x \leq 0 \end{cases}$, 不满足右连续性。

定义 5.4 分布函数的收敛

F, F_n 为分布函数, 称 F_n 弱收敛至 F , 若对 F 的任意连续点 x , $\lim_{n \rightarrow \infty} F_n(x) = F(x)$, 记作 $F_n \xrightarrow{W} F$ 。

定理 5.8 Lévy-Cramér 连续性定理

假设 F_n 为分布函数, 对应特征函数 ϕ_n

1. 若 $F_n \xrightarrow{W} F$, F 为分布函数, 对应特征函数 ϕ , 则 ϕ_n 内闭一致收敛到 ϕ 。
2. 若 ϕ_n 逐点收敛到 ϕ , ϕ 在 $t = 0$ 处连续, 则 $\phi(t)$ 为特征函数, 其对应分布函数 F , 且 $F_n \xrightarrow{W} F$ 。

例 5.8 $X \sim U(-n, n)$, 则 $\phi_n(t) = \frac{\sin nt}{nt}$, 特征函数极限为 $\begin{cases} 0 & t \neq 0 \\ 1 & t = 0 \end{cases}$, 不满足连续性。

§5.4 极限定理

1. 问题: 研究 $T_n = \frac{1}{B_n} \sum_{i=1}^n (X_i - a_i)$ 的极限性质

* X_k 性质-独立同分布

* $a_k = E[X_k], B_n = c\sqrt{n}$

* 研究不同收敛意义下极限

2. 大数定律(LLN)、中心极限定理(CLT)

定义 5.5 弱收敛

若 $F_{X_n} \xrightarrow{W} F_X$, 则称 X_n 依分布收敛(弱收敛)到 X , 记为 $X_n \xrightarrow{D} X$ 。

定理 5.9 大数定律

X_i 独立同分布, 期望 $\mu = E[X_i]$ 存在, 令 $S_n = \sum_{k=1}^n X_k$, 则 $\frac{S_n}{n} \xrightarrow{D} \mu$, 即 $\frac{S_n}{n} - \mu \xrightarrow{D} 0$ 。

证明: 运用连续性定理, 由 $\phi'_X(0) = \mu i$ 将 X_i 的分布函数在 0 处展开一次项即可计算得结果。

* $\frac{S_n}{n} - \mu$ 的无穷小阶数可推测为 $\frac{1}{\sqrt{n}}$, 这是由于 $\text{Var}(S_n) = n \text{Var}(X_1)$, 具体定理为:

定理 5.10 中心极限定理

X_i 独立同分布, 期望 $\mu = E[X_i]$, 方差 $\sigma^2 = \text{Var}(X_i), \sigma > 0$ 存在, 则 $\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{D} N(0, 1)$ 。

证明: 通过平移放缩可不妨设 $\mu = 0, \sigma = 1$, 再对 $\frac{S_n}{\sqrt{n}}$ 展开估算。

例 5.9 各次测量值独立同分布, 方差为 4, 欲以 95% 把握保证测量精度达 ± 0.5 , 求最低测量次数。

$Z_n = \frac{S_n - n\mu}{2\sqrt{n}} \xrightarrow{D} N(0, 1)$, $P\left(\frac{S_n}{n} - \mu\right) \leq 0.5 = P\left(|Z_n| \leq \frac{\sqrt{n}}{4}\right)$, 将 Z_n 视为正态分布, 查表得至少需要 $n = 62$ 。

3. Lindeberg 条件(处理独立但未必同分布)

设 $a_k = E[X_k], b_k^2 = \text{Var}(X_k), B_n^2 = \sum_{k=1}^n b_k^2$, F_k 为 X_k 分布函数。

L 条件: $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} (x-a_k)^2 dF_k = 0$

定理 5.11 Lindeberg - Feller CLT

X_i 相互独立, 满足 L 条件, 则 $\frac{\sum_{k=1}^n (X_k - a_k)}{B_n} \xrightarrow{D} N(0, 1)$, 且 $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

特别地, X_i 相互独立, $a_i = 0$, $E[|X_i|^3] < \infty$, 且 $\frac{1}{B_n^3} \sum_{k=1}^n E[|X_k|^3] \rightarrow 0$, 则 $\frac{\sum_{k=1}^n X_k}{B_n} \xrightarrow{D} N(0, 1)$ 。

*由 $\int_{|x| > \varepsilon B_n} x^2 dF_k \leq \frac{1}{\varepsilon B_n} \int_{|x| > \varepsilon B_n} |x|^3 dF_k$ 即可验证特殊情况。

注:

(1) L 条件的概率意义:

$$\begin{aligned} \sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} \frac{(x-a_k)^2}{B_n^2} dF_k &\geq \varepsilon^2 \sum_{k=1}^n P\left(\frac{|X_k - a_k|}{B_n} > \varepsilon\right) \geq \varepsilon^2 P\left(\bigcup_{k=1}^n \left\{\frac{|X_k - a_k|}{B_n} > \varepsilon\right\}\right) \\ &= \varepsilon^2 P\left(\frac{\max_k |X_k - a_k|}{B_n} > \varepsilon\right), \text{ 由此 L 条件可推出 } P\left(\frac{\max_k |X_k - a_k|}{B_n} > \varepsilon\right) \rightarrow 0. \end{aligned}$$

(2) X_i 相互独立时, L 条件增加 $B_n \rightarrow \infty$, $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ (Feller 条件) 即为 CLT 的必要条件。

(3) Lyapunov 条件: $\exists \delta > 0, E[|X_i - a_i|^{2+\delta}] < \infty$, 且 $\frac{1}{B_n^{2+\delta}} \sum_{k=1}^n E[|X_k - a_k|^{2+\delta}] \rightarrow 0$

类似特殊情况的推导知 Lyapunov 条件可推出 L 条件, 从而推出 CLT。

(4) 利用 $b_k^2 = \int_{\mathbb{R}} (x - a_k)^2 dF_k$ 可拆分为两段, 放缩知 $\frac{b_k^2}{B_n^2}$ 在极限时一致 $\leq \varepsilon^2$, 从而 $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

4. 局部极限定理 (LLT)

*二项分布的正态逼近

取 X_i 独立同分布 $B(1, p)$, 由再生性知 $S_n \sim B(n, p)$, 由此可进行估计:

定理 5.12 二项分布的局部极限定理

$p \in (0, 1), q = 1 - p, x_k = \frac{k - np}{\sqrt{npq}}$, 对 $|x_k| \leq A$, $n \rightarrow \infty$ 时一致地有 $C_n^k p^k q^{n-k} \sim \frac{1}{\sqrt{2\pi npq}} e^{-x_k^2/2}$ 。

证明: 利用 Stirling 公式估算系数。

定理 5.13 积分形式 LLT

$S_n \sim B(n, p)$, 则 $P\left(a < \frac{S_n - np}{\sqrt{npq}} \leq b\right) \rightarrow \frac{1}{\sqrt{2\pi}} \int_a^b e^{-x^2/2} dx$

证明: 取上一定理中 x_k , 有:

$$\text{左} = \sum_{k: x_k \in (a, b]} C_n^k p^k q^{n-k} \sim \sum_{k: x_k \in (a, b]} \frac{e^{-x_k^2/2}}{\sqrt{2\pi npq}} = \sum_{k: x_k \in (a, b]} \frac{e^{-x_k^2/2}}{\sqrt{2\pi}} (x_{k+1} - x_k) \rightarrow \text{右}, \text{ 最后一步是由于黎曼和极限为积分。}$$

* n 固定时, x_k 与 k 一一对应, 形成等距分划

5. 矩方法

$$\gamma_k = \int_{\mathbb{R}} x^k \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx = \begin{cases} 0 & 2 \nmid k \\ (k-1)!! & 2 \mid k \end{cases}, \text{ 可看作 } 1, 2, \dots, k \text{ 两两配对的方式数。}$$

定理 5.14 X_i 独立, 且期望均为 0, 方差均为 1, $\forall m \geq 3, C_m = \sup_k E[|X_k|^m] < \infty$ (一致有界高阶矩),

则 $S_n = \sum_{i=1}^n X_i$ 有 $E\left[\left(\frac{S_n}{\sqrt{n}}\right)^k\right] \rightarrow \gamma_k$, 进而 $\frac{S_n}{\sqrt{n}} \xrightarrow{D} N(0, 1)$ 。

证明: $E\left[\left(\frac{S_n}{\sqrt{n}}\right)^k\right] = n^{-k/2} \sum_{i_1, \dots, i_k} E[X_{i_1} \dots X_{i_k}]$, 其中非零项每个随机变量次数必至少为2。由于高阶矩一致有界, 若选出的项小于 $k/2$ 个, 会在极限中趋于0, 由此只有 $k = 2m$ 时可两两配对 $i_1, \dots, i_{2m}$ 得出项, 再由每种配对方式对应极限为1可算出结果。

*由矩的极限推出依分布收敛:

定理 5.15 矩收敛定理

条件:

1. $k \in \mathbb{N}, \gamma_{k,n} = \int x^k dF_n$ 存在

2. $\forall k, \lim_{n \rightarrow \infty} \gamma_{k,n} = \gamma_k$

3. $\gamma_k = \int x^k dF$, 且满足 **Carleman条件** $\sum_{k=1}^{\infty} (\gamma_{2k})^{-1/(2k)} = \infty$

则 $F_n \xrightarrow{W} F$ 。

六 几种收敛

§6.1 四种收敛方式

定义 6.1 假设 X, X_n 为 $\{\Omega, \mathcal{F}, P\}$ 上的随机变量, 则:

1. **几乎处处收敛** (以概率1收敛):

$$P(\{\omega \in \Omega : X_n(\omega) - X(\omega) \rightarrow 0\}) = 1,$$

记作 $X_n \xrightarrow{a.s.} X$ 。

2. **r阶收敛**:

$$r \in \mathbb{N}^*, \forall n, E[|X_n|^r] < \infty, \text{ 且 } E[|X_n - X|^r] \rightarrow 0,$$

记作 $X_n \xrightarrow{r} X$ 。 $r = 1$ 时称**平均收敛**, $r = 2$ 时称**均方收敛**。

3. **依概率收敛**:

$$\forall \varepsilon > 0, P(|X_n - X| > \varepsilon) \rightarrow 0,$$

记作 $X_n \xrightarrow{P} X$ 。

4. **依分布收敛**:

$$F_X \text{ 的连续点处 } P(X_n \leq x) \rightarrow P(X \leq x),$$

记作 $X_n \xrightarrow{D} X$ 。

*依分布收敛与样本空间选择无关, 具有特殊性

定理 6.1 四种收敛的关系

$$X_n \xrightarrow{a.s.} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$$

$$r > s, X_n \xrightarrow{r} X \Rightarrow X_n \xrightarrow{s} X \Rightarrow X_n \xrightarrow{P} X$$

且反方向均无法推出, 由此强弱有**严格性**。

定理证明拆分为以下:

1. $X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{D} X$

$F_n(x) = P(X_n \leq x, X \leq x + \varepsilon) + P(X_n \leq x, X > x + \varepsilon) \leq F(x + \varepsilon) + P(|X - X_n| > \varepsilon)$, 同理 $F(x - \varepsilon) \leq F_n(x) + P(|X - X_n| > \varepsilon)$, 连续点处考虑 $F_n(x)$ 上下极限可知结果。

例 6.1 $X_n \xrightarrow{D} X \not\Rightarrow X_n \xrightarrow{P} X$

$P(X=0) = P(X=1) = \frac{1}{2}, Y=1-X, X_n=X$, 则 $X_n \xrightarrow{D} Y$, 但其他三种收敛均不成立。

2. $r > s, X_n \xrightarrow{r} X \Rightarrow X_n \xrightarrow{s} X$

利用问题14.4.28(可由Hölder不等式证明)有 $E[|X_n - X|^s]^{1/s} \leq E[|X_n - X|^r]^{1/r}$, 由此得结论。

3. $X_n \xrightarrow{1} X \Rightarrow X_n \xrightarrow{P} X$

考虑概率测度在 $|X| \geq a$ 部分的积分得Markov不等式: $a > 0, P(|X| > a) \leq \frac{E[|X|]}{a}$, 由此取 $a = \varepsilon$ 知结论。

*Chebyshev不等式: $a > 0, P(|X - E[X]| > a) \leq \frac{\text{Var}(X)}{a^2}$

例 6.2 $X_n \xrightarrow{P} X \not\Rightarrow X_n \xrightarrow{r} X$

$\Omega = (0, 1], P$ 为 Lebesgue 测度, $X_n(\omega) = \begin{cases} n^{1/r} & \omega \in \left(0, \frac{1}{n}\right] \\ 0 & \omega \in \left(\frac{1}{n}, 1\right] \end{cases}, X=0$, 计算可验证依概率收敛但不 r 阶收敛。

4. $X_n \xrightarrow{a.s.} X \Rightarrow X_n \xrightarrow{P} X$

分析得 $\{\omega \in \Omega : X_n(\omega) - X(\omega) \rightarrow 0\} = \bigcap_{k=1}^{\infty} \bigcup_{m=1}^{\infty} \bigcap_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| \leq \frac{1}{k}\}$, 由此

知 $X_n \xrightarrow{a.s.} X \Leftrightarrow P\left(\bigcup_{k=1}^{\infty} \bigcap_{m=1}^{\infty} \bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \frac{1}{k}\}\right) = 0$, 类似分析得其等价于 $\forall \varepsilon > 0, \lim_{m \rightarrow \infty} P\left(\bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) = 0$, 由此得结论。

例 6.3 $X_n \xrightarrow{r} X \not\Rightarrow X_n \xrightarrow{a.s.} X$, 由此 $X_n \xrightarrow{P} X \not\Rightarrow X_n \xrightarrow{a.s.} X$

X_i 相互独立, $X_n \sim B(1, \frac{1}{n})$, 可验证任意 r 阶均收敛, 但 $P\left(\bigcup_{n=m}^{\infty} \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}\right) = 1$, 故不几乎处处收敛。

定理 6.2 反向的成立条件

1. 若 $X_n \xrightarrow{D} c \in \mathbb{R}$, 则 $X_n \xrightarrow{P} c$ 。

2. 若 $\exists k, P(|X_n| \leq k) = 1, X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{r} X$ 。

3. 若 $\forall \varepsilon > 0, \sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty$, 则 $X_n \xrightarrow{a.s.} X$ 。

证明:

1. 利用 $P(|X_n - c| > \varepsilon) = P(X_n > c + \varepsilon) + P(X_n < c - \varepsilon)$, 利用分布函数估计知结果。

2. 先拆分 X 为 $|X - X_n| + |X_n|$ 估计出 X 有同样的界, 再将差的期望拆分为 $|X_n - X| \leq \varepsilon$ 与 $|X_n - X| > \varepsilon$ 的部分可知期望的极限。

3. 利用并的概率小于等于概率的和直接估算。

定理 6.3 弱大数律

X_i 独立同分布, 期望 $\mu = E[X_i]$ 存在, 令 $S_n = \sum_{k=1}^n X_k$, 则 $\frac{S_n}{n} \xrightarrow{P} \mu$ 。

证明: 由大数定律与收敛于常随机变量得出。

定理 6.4 Skorokhod表示定理

设 $X_n \xrightarrow{D} X$, 则存在 $(\Omega, \mathcal{F}, P)$, 其上的 Y_n, Y 满足 Y_n 与 X_n , Y 与 X 同分布, $Y_n \xrightarrow{a.s.} Y$ 。

定理 6.5 弱收敛性质

$X_n \xrightarrow{D} X \Leftrightarrow \forall g \in C_b(\mathbb{R})$ (有界连续函数), $E[g(X_n)] \rightarrow E[g(X)]$ 。

证明: 左推右由表示定理将 X_n, X 替换为 Y_n, Y 利用控制收敛定理可说明 $E[g(Y_n)] \rightarrow E[g(Y)]$; 右推左利用 $P(X_n \leq x) = E[I_{(-\infty, x]}(X_n)]$, 以有界连续函数逼近知结论。

§6.2 重要结论**1. 不等式**

*记 $\|X\|_p = E[|X|^p]^{1/p}, p \geq 1$

Hölder不等式: $\frac{1}{p} + \frac{1}{q} = 1, E[|XY|] \leq \|X\|_p \|Y\|_q$

Minkowski不等式: $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$

Markov不等式: $a > 0, aP(|X| > a) \leq E[|X|]$

Chebyshev不等式: $a > 0, a^2 P(|X - E[X]| > a) \leq \text{Var}(X)$

例 6.4 $\exists r > 0, E[|X|^r] = 0 \Rightarrow P(X = 0) = 1$

由 Markov 不等式, $\forall \varepsilon, P(|X| \geq \varepsilon) \leq \frac{E[|X|^r]}{\varepsilon^r} = 0$, 由此 $P(|X| < \varepsilon) = 1 \Rightarrow P(|X| \leq 2\varepsilon) = 1$, 利用右连续性有结论。

2. 收敛

定理 6.6 记 $\square$ 为 *a.s.* 或 *r* 或 *P*, 有:

1. $X_n \xrightarrow{\square} X, X_n \xrightarrow{\square} Y \Rightarrow P(X = Y) = 1$

2. $X_n \xrightarrow{\square} X, Y_n \xrightarrow{\square} Y \Rightarrow X_n + Y_n \xrightarrow{\square} X + Y$

3. 前两条对依分布收敛一般不成立, 但 1. 可以改为 X, Y 同分布

证明: 利用拆分与不等式放缩可验证成立, 对依分布收敛, 取 $P(X = 1) = P(X = -1) = \frac{1}{2}, Y_n = X_n = Y = -X$ 即为前两条的反例, 利用连续点处相等与单调右连续可知同分布。

3. Borel - Cantelli引理

事件列的上下极限:

A_n 的上限事件: $\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{m=n}^{\infty} A_m$ (A_n 中发生无穷多次的样本点),

A_n 的下限事件: $\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{m=n}^{\infty} A_m$ (A_n 中至多有限多次不发生的样本点)

* A_n 的上限事件记为 $\{A_n \text{ i.o.}\}$ 。

定理 6.7 Borel - Cantelli引理

1. $\sum_{n=1}^{\infty} P(A_n) < \infty \Rightarrow P(A_n \text{ i.o.}) = 0$

2. $\sum_{n=1}^{\infty} P(A_n) = \infty, A_i \text{ 独立} \Rightarrow P(A_n \text{ i.o.}) = 1$

证明: 利用交、并、独立与概率的连续性放缩。

*由此可发现, 若 A_i 独立, $P(A_n \text{ i.o.})$ 只能为 0 或 1 (零一律)。

例 6.5 $X_i \sim \text{Exp}(1)$ 独立同分布, 则 $P\left(\limsup_{n \rightarrow \infty} \frac{X_n}{\ln n} = 1\right) = 1$ 。

令 $A_n = \left\{ \frac{X_n}{\ln n} \geq 1 + a \right\}$, 则 $P(A_n) = \frac{1}{n^{1+a}}$ 且相互独立。

可发现 $a \in (-1, 0]$ 时 $P(A_n \text{ i.o.}) = 1$ (A_n 几乎处处发生无穷多次), $a > 0$ 时 $P(A_n \text{ i.o.}) = 0$ (A_n 几乎处处只发生有限多次), 由此知结论。

§6.3 强大数律

弱大数律: X_i 独立同分布, 期望 $\mu = E[X_i]$ 存在, 令 $S_n = \sum_{k=1}^n X_k$, 则 $\frac{S_n}{n} \xrightarrow{P} \mu$ 。

定理 6.8 强大数律

X_i 独立同分布, 期望 $\mu = E[X_i]$ 存在, $E[X_i^2]$ 存在, 令 $S_n = \sum_{k=1}^n X_k$, 则 $\frac{S_n}{n} \xrightarrow{2} \mu$, $\frac{S_n}{n} \xrightarrow{a.s.} \mu$ 。

证明: 对均方收敛, 可由独立性直接计算 $E\left[\left(\frac{S_n}{n} - \mu\right)^2\right] = \frac{\text{Var}(X_1)}{n} \rightarrow 0$ 。

对几乎处处收敛, 先找几乎处处收敛的子列, 再证明对非负的 X_k 成立, 最后推至一般。

定理 6.9 柯尔莫哥洛夫强大数律

X_i 独立同分布, 则, $\frac{X_1 + \cdots + X_n}{n} \xrightarrow{a.s.} \mu \Leftrightarrow E[|X_1|]$ 存在且为 μ 。

左推右证明: 由于可拆分为两部分, 不妨设随机变量均非负。

STEP 1 截尾: 取 $Y_n = X_n I_{X_n < n}$, 拆分估计可知 $\sum_{n=1}^{\infty} P(X_n \neq Y_n) = \sum_{n=1}^{\infty} P(X_n \geq n) < \infty$, 因此 $P(X_n \neq Y_n \text{ i.o.}) = 0$, 因此 $\frac{\sum_{k=1}^n (X_k - Y_k)}{n} \xrightarrow{a.s.} 0$, 由此只需证结论对各阶矩存在的 Y_n 成立。

STEP 2 几乎处处收敛子列: 对 $\alpha > 1$, 令 $\beta_k = \lceil \alpha^k \rceil$, 则 $\frac{\beta_{k+1}}{\beta_k} \rightarrow \alpha$, 且存在 A 使 $\forall m, \sum_{k=m}^{\infty} \frac{1}{\beta_k^2} \leq \frac{A}{\beta_m^2}$ 。
记 $S'_n = \sum_{i=1}^n Y_i$, 利用二阶矩估计知 $\sum_{n=1}^{\infty} P\left(\left|\frac{S'_{\beta_n} - E[S'_{\beta_n}]}{\beta_n}\right| > \varepsilon\right) < \infty$, 由此 $\left|\frac{S'_{\beta_n} - E[S'_{\beta_n}]}{\beta_n}\right| > \varepsilon \xrightarrow{a.s.} 0$, 进而 $\frac{S'_{\beta_n}}{\beta_n} \xrightarrow{a.s.} \mu$ 。

STEP 3 收敛: 由于 S'_n 单调增, $\beta_m \leq n < \beta_{m+1}$ 有 $\frac{\beta_m}{n} \cdot \frac{S'_{\beta_m}}{\beta_m} < \frac{S'_n}{n} < \frac{\beta_{m+1}}{n} \cdot \frac{S'_{\beta_{m+1}}}{\beta_{m+1}}$, 取上下极限可估计得结论成立。

*推论(Borel强大数律): 试验中事件 A 发生概率 p , S_n 为 n 次独立重复试验中 A 发生次数, 则 $\frac{S_n}{n} \xrightarrow{a.s.} p$ 。

定理 6.10 重对数律

X_i 独立同分布, 期望 0, 方差 1, 则:

$$P\left(\limsup_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \ln \ln n}} = 1\right) = 1$$

$$P\left(\liminf_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \ln \ln n}} = -1\right) = 1$$

*意味着 CLK 不能加强到更强的收敛

七 概率论外篇

§7.1 信息熵

记事件 E 发生概率 $p = P(E)$, 定义“惊奇程度” $S(p)$, 基本要求: $S(1) = 0$ 、 $S(p)$ 严格单调减、关于 p 连续、 $S(pq) = S(p) + S(q)$ (直观理解: 独立事件引起惊奇程度为分别发生之和)。这些要求可确定:

定理 7.1 $S(p) = -c \ln p, c > 0$ 。

证明：先考虑 $p_0^{m/n}$ ，再由连续推到一切 p 。

定义 7.1 Shannon熵

离散型随机变量 X ，取不同点概率为 $p_1, \dots, p_n, \dots$ ，定义 $H(X) = -\sum_k p_k \ln p_k$ 。

联合熵： $H(x, y) = -\sum_{i,j} P(x_i, y_j) \ln P(x_i, y_j)$ 。

相对熵： $H_Y(X) = \sum_j H_{Y=y_j}(X) P_Y(y_j)$ ，其中 $H_{Y=y_j}(X) = -\sum_i P(x_i|y_j) \ln P(x_i|y_j)$ 。

注： $H_Y(X) = -\sum_{i,j} P(x_i, y_j) \ln \frac{P(x_i, y_j)}{P_Y(y_j)}$

定理 7.2 $H(X, Y) = H(Y) + H_Y(X)$

证明：直接计算知结论。

定理 7.3 $H_Y(X) - H(X) \leq 0$

证明：由 $\ln x \leq x - 1$ 估计知结论。

*由凸性可知 $P(X = x_i) = p_i, i = 1, 2, \dots, n, p_1 = \dots = p_n = \frac{1}{n}$ 时 $H(X) = \ln n$ 最大，即熵可代表不确定程度的大小。

定义 7.2 连续型随机变量的熵 X 连续，密度函数 $f(x)$ ，则 $H(X) = -\int_{\mathbb{R}} f(x) \ln f(x) dx$ 。

联合熵： $H(X, Y) = -\int_{\mathbb{R}^2} f(x, y) \ln f(x, y) dx dy$ 。

***Gibbs不等式**(利用分析知识可证明)： $u - u \ln u \leq v - u \ln v$ ，积分得 $\int_{\mathbb{R}} f(1 - \ln f) dx \leq \int_{\mathbb{R}} g(1 - \ln g) dx$ ，

再利用密度函数在实轴积分为1知 $\int_{\mathbb{R}} -f \ln f dx \leq \int_{\mathbb{R}} -f \ln g dx$ 。

定理 7.4 熵最大的条件

令 $D = \{x \in \mathbb{R} : f(x) \neq 0\}$ ，则：

1. $D = \mathbb{R}, E[X] = 0, \text{Var}(X) = 1$ 时，正态分布 $N(0, 1)$ 熵最大，为 $\ln \sqrt{2\pi e}$ 。

2. $D = (0, \infty), E[X] = \frac{1}{\lambda}$ 时，指数分布 $\text{Exp}(\lambda)$ 熵最大，为 $\ln \frac{e}{\lambda}$ 。

3. $D = [0, a]$ 时，均匀分布 $U(0, a)$ 熵最大，为 $\ln a$ 。

证明：分别取 g 为三种分布的密度函数，利用Gibbs不等式估算即可。

***Boltzmann熵**： $S = k \ln \Omega$ ， $k = k_B$ 为玻尔兹曼常数， Ω 为微观状态数(类似离散型均匀分布时的情况)。

§7.2 Linderberg替换理论

*L条件形式CLK:

设 $a_k = E[X_k], b_k^2 = \text{Var}(X_k), B_n^2 = \sum_{k=1}^n b_k^2$ ， F_k 为 X_k 分布函数。

$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \int_{|x-a_k| > \varepsilon B_n} (x-a_k)^2 dF_k = 0$ ，则 $\frac{\sum_{k=1}^n (X_k - a_k)}{B_n} \xrightarrow{D} N(0, 1)$ ，且 $\frac{\max_k b_k^2}{B_n^2} \rightarrow 0$ 。

定理 7.5 $X_n \xrightarrow{D} X$ 等价于下列条件之一:

1. $\forall g \in C_b(\mathbb{R})$ (有界连续函数), $E[g(X_n)] \rightarrow E[g(X)]$ 。
2. 任意有界一致连续 g , $E[g(X_n)] \rightarrow E[g(X)]$ 。
3. 给定 $m \in \mathbb{N}$, $\forall g \in C_b(\mathbb{R}), g', g'', \dots, g^{(m)} \in C_b(\mathbb{R})$, $E[g(X_n)] \rightarrow E[g(X)]$ 。
4. $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$ (逐点收敛)。

Linderberg思想: 取至三阶导均有界连续的 g , 独立随机变量列 $Y_n \sim N(0, b_n^2)$, 与 X_n 亦独立。

定义 $\zeta_{nk} = \sum_{1 \leq i < k} X_k + \sum_{k < i \leq n} Y_i$, 则 $\zeta_{nn} + X_n = S_n, \zeta_{n1} + Y_1 = B_n \cdot N(0, 1)$, $\zeta_{nk} + X_k = \zeta_{n,k+1} + Y_{k+1}$, 利用逐项相消, 可将 X_i 替换为 Y_i :

$$E \left[g \left(\frac{S_n}{B_n} \right) \right] - E[g(Y)] = \sum_{k=1}^n \left(E \left[g \left(\frac{\zeta_{nk} + X_k}{B_n} \right) \right] - E \left[g \left(\frac{\zeta_{nk} + Y_k}{B_n} \right) \right] \right)$$

再利用 ζ_{nk}, X_k, Y_k 独立泰勒展开估算 $h(t) = \sup_x \{g(x+t) - g(x) - g'(x)t - \frac{1}{2}g''(x)t^2\}$, 拆分证明。

§7.3 随机矩阵

1. 起源

统计(样本协方差阵):

$X_k = (X_{1k} \ \cdots \ X_{pk})^T, X = (X_1 \ \cdots \ X_n)$ 为 $p \times n$ 矩阵。

当 X_{ij} 独立同 $N(0, 1)$ 时, X 的联合密度 $f(X) = \frac{1}{\sqrt{2\pi}^m} \exp \left(-\frac{1}{2} \text{tr}(XX^T) \right)$

物理: 波函数、随机矩阵模拟

2. 高斯正交系综(Gaussian Orthogonal Ensemble)

$X_n: \Omega \rightarrow M_{n \times n}(\mathbb{R}), X_n(\omega) = (x_{ij}(\omega))_{i,j=1}^n$

x_{ij} 独立同 $N(0, \sigma^2)$, 记 $A_n = \frac{X_n + X_n^T}{2}$, 计算可发现 $a_{ii} \sim N(0, \sigma^2), a_{ij} \sim N\left(0, \frac{\sigma^2}{2}\right) (i \neq j)$, 且 A_n 的上三角部分独立, 由此直接计算乘积可知 A_n (上半三角) 的分布:

$$f(A_n) = 2^{-n/2} (\pi \sigma^2)^{-n(n+1)/4} \exp \left(-\frac{1}{2\sigma^2} \text{tr} A_n^2 \right), \text{ 记为 } A_n \sim \text{GOE}_n(\sigma)$$

*正交变换下不变性: Q 为正交阵, $B_n = Q^T A_n Q$, 则 $B_n \sim \text{GOE}_n(\sigma)$

3. 半圆律

X 分布函数 $\omega(x) = \frac{1}{2\pi} \sqrt{4-x^2}$, 记 $\gamma_k = E[X^k]$, 计算知其为 $\begin{cases} 0 & k = 2m+1 \\ \frac{1}{m+1} C_{2m}^m & k = 2m \end{cases}$ 。

实Wigner矩阵: $A_n = (a_{ij})$ 为实对称阵, a_{ii} 独立与 Y 同分布, $a_{ij} (i > j)$ 独立与 z 同分布, $E[Y] = E[Z] = 1, \text{Var}(Z) = 1, \text{Var}(Y) < \infty, |Y|, |Z|$ 各高阶矩存在。

定理 7.6 $k \in \mathbb{N}, \frac{1}{n} E \left[\text{tr} \left(\frac{A_n}{\sqrt{n}} \right)^k \right] \rightarrow \gamma_k$

证明: 左 = $n^{-1-k/2} \sum_{i_1, \dots, i_k} E[a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_k i_1}]$, 类似定理5.14可证明不消失的项中必然每个不同的 a_{ij} 出现两次, 进而说明 $i_1, \dots, i_k$ 选取方法与 $1, 2, \dots, k$ 不相交 (对任何 $a < b < c < d$, 不存在配对 $(a, c), (b, d)$) 的两两配对数 ($k = 2m$ 时即为卡特兰数 C_m) 一一对应, 再利用组合计算知结论。

4. Wishart矩阵模型

$X = (x_{ij})_{i,j=1}^n$, 矩阵元独立同 $N(0, 1)$, 设 $n - p = \alpha$ 固定, 则 $\frac{1}{p} E \left[\text{tr} \left(\frac{1}{p} X X^T \right)^m \right] \rightarrow C_m$ 。