

# 第三章 统计模式识别中的 概率分类法

1、已知两个一维模式类别的类概率密度函数为

$$p(x|\omega_1) = \begin{cases} x & 0 \leq x < 1 \\ 2 - x & 1 \leq x \leq 2 \\ 0 & \text{其他} \end{cases}$$

$$p(x|\omega_2) = \begin{cases} x - 1 & 1 \leq x < 2 \\ 3 - x & 2 \leq x \leq 3 \\ 0 & \text{其他} \end{cases}$$

先验概率分别为  $p(\omega_1) = 0.6$   $p(\omega_2) = 0.4$ 。试求最大后验概率判决函数以及总的分类错误概率  $P(e)$ 。

# Bayes法则—最大后验概率准则

对于两类 $\omega_1$ ,  $\omega_2$ 问题, 直观地, 可以根据后验概率做判决:

若  $p(\omega_1|\vec{x}) > p(\omega_2|\vec{x})$  则  $\vec{x} \in \omega_1$

若  $p(\omega_1|\vec{x}) < p(\omega_2|\vec{x})$  则  $\vec{x} \in \omega_2$

根据Bayes公式, 后验概率 $p(\omega_i / \vec{x})$ 可由类 $\omega_i$ 的先验概率 $P(\omega_i)$ 和条件概率密度 $p(\vec{x} / \omega_i)$ 来表示, 即

$$p(\omega_i | \vec{x}) = \frac{p(\vec{x} | \omega_i)P(\omega_i)}{p(\vec{x})} = \frac{p(\vec{x} | \omega_i)P(\omega_i)}{\sum_{i=1}^2 p(\vec{x} | \omega_i)P(\omega_i)}$$

式中,  $p(x|\omega_i)$  又称**似然函数** (likelihood function of class  $\omega_i$ ), 可由已知样本求得。

将 $P(\omega_i|\mathbf{x})$ 代入判别式，判别规则可表示为

若  $p(\vec{x}|\omega_1)P(\omega_1) > p(\vec{x}|\omega_2)P(\omega_2)$  则  $\vec{x} \in \omega_1$

若  $p(\vec{x}|\omega_1)P(\omega_1) < p(\vec{x}|\omega_2)P(\omega_2)$  则  $\vec{x} \in \omega_2$

或改写为

$$l_{12} = \frac{p(\vec{x} | \omega_1)}{p(\vec{x} | \omega_2)} > \frac{P(\omega_2)}{P(\omega_1)} = \theta_{12} \quad \text{则 } \vec{x} \in \omega_1$$

$$l_{12} = \frac{p(\vec{x} | \omega_1)}{p(\vec{x} | \omega_2)} < \frac{P(\omega_2)}{P(\omega_1)} = \theta_{12} \quad \text{则 } \vec{x} \in \omega_2$$

$l_{12}$ 称为似然比 (likelihood ratio)， $\theta_{12}$ 称为似然比的判决阈值。

原则：要确定 $\mathbf{x}$ 是属于 $\omega_1$ 类还是 $\omega_2$ 类，要看 $\mathbf{x}$ 是来自于 $\omega_1$ 类的概率大还是来自 $\omega_2$ 类的概率大。

1、已知两个一维模式类别的类概率密度函数为

$$p(x|\omega_1) = \begin{cases} x & 0 \leq x < 1 \\ 2 - x & 1 \leq x \leq 2 \\ 0 & \text{其他} \end{cases}$$

$$p(x|\omega_2) = \begin{cases} x - 1 & 1 \leq x < 2 \\ 3 - x & 2 \leq x \leq 3 \\ 0 & \text{其他} \end{cases}$$

先验概率分别为  $p(\omega_1) = 0.6$   $p(\omega_2) = 0.4$ 。试求最大后验概率判决函数以及总的分类错误概率  $P(e)$ 。

解： 最大后验概率判决规则为

$$\begin{cases} p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2) & \Rightarrow x \in \omega_1 \\ p(x|\omega_2)P(\omega_2) > p(x|\omega_1)P(\omega_1) & \Rightarrow x \in \omega_2 \end{cases}$$




图 1: 最大后验概率判决示意图

对应的图像如图1所示。左侧区域应判决为  $\omega_1$ ，右侧区域应判决为  $\omega_2$ ，分界点为两图线的交点。计算出此处  $x = 1.6$ ，因此判决规则可以改写成

$$g(x) = x - 1.6 \begin{cases} < 0 & \Rightarrow x \in \omega_1 \\ > 0 & \Rightarrow x \in \omega_2 \end{cases} \quad (20)$$

总的分类错误概率即图中两块重合的部分的面积

$$\begin{aligned} P(e) &= \int_{\Omega_2} P(\omega_1)p(x|\omega_1)dx + \int_{\Omega_1} P(\omega_2)p(x|\omega_2)dx \\ &= \int_{1.6}^2 0.6(2-x)dx + \int_1^{1.6} 0.4(x-1)dx \\ &= 0.048 + 0.072 \\ &= 0.12 \end{aligned}$$

2、二维空间中的两类样本均服从正态分布，其参数分别为：

均值向量： $\boldsymbol{\mu}_1 = (1, 0)^T, \boldsymbol{\mu}_2 = (-1, 0)^T$

协方差矩阵： $\boldsymbol{\Sigma}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \boldsymbol{\Sigma}_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$

且两类的先验概率相等，试证明其基于最小错误率判决准则的决策分界面方程为一圆，并求其方程。

### 3.2 最小错误率判决规则（最简单的 Bayes 分类方法）

分析一个“两类问题”。

以上一个例子为例，用  $w_1$  和  $w_2$  表示两种不同的类型，如  $w_1$  表示诊断正常， $w_2$  表示诊断出患有癌症。

用  $P(w_1)$  和  $P(w_2)$  分别表示先验概率。如： $P(w_1)$  诊断正常的概率， $P(w_2)$  表示某地人患癌症的概率，可通过大量的统计得到。

用  $\rho(x|w_1)$  和  $\rho(x|w_2)$  表示两个类概率密度。

样本  $x$  表示“试验反应阳性”，则  $\rho(x|w_1)$  诊断为无癌症且试验反应为阳性， $P(w_1|x)$  试验为阳性且没有癌症。

根据全概率公式，模式样本  $x$  出现的全概率密度为：

$$\rho(x) = \rho(x|w_1) \cdot P(w_1) + \rho(x|w_2) \cdot P(w_2) \quad (3.2-1)$$



根据 Bayes 公式，在模式样本  $x$  出现的条件下，两个类型的后验概率为：

$$P(w_1 | x) = \frac{\rho(x | w_1) \cdot P(w_1)}{\rho(x)}, \quad P(w_2 | x) = \frac{\rho(x | w_2) \cdot P(w_2)}{\rho(x)} \quad (3.2-2)$$

此时，样本归属于“后验概率较高”的那种类型。

也就是：

$$\left. \begin{aligned} P(w_1 | x) &> P(w_2 | x), \quad \text{则 } x \in w_1 \\ P(w_2 | x) &> P(w_1 | x), \quad \text{则 } x \in w_2 \end{aligned} \right\} \quad (3.2-3)$$

$P(w_1 | x) = P(w_2 | x)$ ，则偶然决定  $x \in w_1$ ，或  $x \in w_2$

根据 (3.2-2) 式，上述判决规则等价于：

$$\left. \begin{aligned} \rho(x | w_1) \cdot P(w_1) &> \rho(x | w_2) \cdot P(w_2), \quad \text{则 } x \in w_1 \\ \rho(x | w_2) \cdot P(w_2) &> \rho(x | w_1) \cdot P(w_1), \quad \text{则 } x \in w_2 \end{aligned} \right\} \quad (3.2-4)$$


$\rho(x | w_2) \cdot P(w_2) = \rho(x | w_1) \cdot P(w_1)$ ，则偶然决定  $x \in w_1$ ，或  $x \in w_2$

上面只是给出了最小错误率贝叶斯决策规则，但没有证明按这种规则进行分类确实使错误率最小。下面用一维情况来证明最小错误率贝叶斯决策规则，其结果不难推广到多维。

如下图所示，在一维特征空间里，判决门限  $t$  把空间划分为两个类型区域  $R_1$ ,  $R_2$ 。

在  $R_1$  中，  $\rho(x|w_1) \cdot P(w_1) > \rho(x|w_2) \cdot P(w_2)$ ，则  $x \in w_1$ ；

在  $R_2$  中，  $\rho(x|w_2) \cdot P(w_2) > \rho(x|w_1) \cdot P(w_1)$ ，则  $x \in w_2$ ；



阴影区域是两类样本的交错分配区域，阴影面积就是这种分类方法的错误概率。总错误率有两种情况：

$x \in w_1$ ，而判为  $x \in w_2$ ，斜线区域。

$x \in w_2$ ，而判为  $x \in w_1$ ，纹线区域。

所以，总错误率：

$$P(e) = \int_{-\infty}^{\infty} P(e|x)\rho(x)dx$$

其中， $\int_{-\infty}^{\infty} ()dx$  表示在整个  $d$  维特征空间上的积分。

对上述两类问题：当  $P(w_2|x) > P(w_1|x)$  时，则  $x \in w_2$ 。显然作出决策  $w_2$  时， $x$  的条件错误概率为  $P(w_1|x)$ ，反之为  $P(w_2|x)$ 。

也就是：

$$P(e|x) = \begin{cases} P(w_1|x) & \text{当 } P(w_2|x) > P(w_1|x) \\ P(w_2|x) & \text{当 } P(w_1|x) > P(w_2|x) \end{cases}$$


若令  $t$  为两类分界面，特征向量  $x$  为一维时， $t$  为  $x$  轴上的一个点，如上图所示：

$$\begin{aligned} P(e) &= \int_{-\infty}^t P(w_2 | x) \cdot \rho(x) dx + \int_t^{\infty} P(w_1 | x) \rho(x) dx \\ &= \int_{-\infty}^t \rho(x | w_2) \cdot P(w_2) dx + \int_t^{\infty} \rho(x | w_1) \cdot P(w_1) dx \end{aligned}$$

也可写为：

$$\begin{aligned} P(e) &= P(x \in R_1, w_2) + P(x \in R_2, w_1) \\ &= P(w_2) \cdot P(x \in R_1 | w_2) + P(w_1) \cdot P(x \in R_2 | w_1) \\ &= P(w_2) \cdot \int_{R_1} \rho(x | w_2) dx + P(w_1) \cdot \int_{R_2} \rho(x | w_1) dx \\ &= P(w_2) \cdot P_2(e) + P(w_1) \cdot P_1(e) \end{aligned}$$





所以要使  $P(e)$  最小，判决门限应如上图所示，否则就会有多余的阴影面。而 (3.2-3)、(3.2-4) 表达的判决规则，判决门限正好如上图所示，所以称之为“最小错误概率判决规则”。

可以把上述两类问题导出的最小错误率判决规则一般化，推广到  $c$  类问题中，表达为：

若：
$$P(w_i | x) = \max_{j=1, \dots, c} \{P(w_j | x)\}, \quad \text{则 } x \in w_i,$$

等价于：
$$\rho(x | w_i) \cdot P(w_i) = \max_{j=1, \dots, c} \{\rho(x | w_j) \cdot P(w_j)\}, \quad \text{则 } x \in w_i$$

例：对一批人进行癌症普查，患癌症者定为属 $\omega_1$ 类，正常者定为属 $\omega_2$ 类。统计资料表明人们患癌的概率  $P(\omega_1) = 0.005$ ，从而  $P(\omega_2) = 0.995$ 。设有一种诊断此病的试验，其结果有阳性反应和阴性反应之分，依其作诊断。化验结果是一维离散模式特征。统计资料表明：癌症者有阳性反映的概率为**0.95**即  $P(x = \text{阳} | \omega_1) = 0.95$ ，从而可知  $P(x = \text{阴} | \omega_1) = 0.05$ ，正常人阳性反映的概率为**0.01**即  $P(x = \text{阳} | \omega_2) = 0.01$ ，可知  $P(x = \text{阴} | \omega_2) = 0.99$ 。

**问有阳性反映的人患癌症的概率有多大？**



解:

$$\begin{aligned}P(\omega_1|x = \text{阳}) &= \frac{P(x = \text{阳}|\omega_1)P(\omega_1)}{P(x = \text{阳})} \\&= \frac{P(x = \text{阳}|\omega_1)P(\omega_1)}{P(x = \text{阳}|\omega_1)P(\omega_1) + P(x = \text{阳}|\omega_2)P(\omega_2)} \\&= \frac{0.95 \times 0.005}{0.95 \times 0.005 + 0.01 \times 0.995} \\&= 0.323\end{aligned}$$

说明有阳性反应的人其患癌的概率有32.3%

写成似然比形式：

$$l_{12}(x) = \frac{P(x = \text{阳} | \omega_1)}{P(x = \text{阳} | \omega_2)} = \frac{0.95}{0.01} = 95$$

$$\theta_{12} = \frac{P(\omega_2)}{P(\omega_1)} = \frac{0.995}{0.005} = 197$$

$$\because l_{12}(x) < \theta_{12} \quad \therefore x \in \omega_2$$



二维空间中的两类样本均服从正态分布，其参数分别为：

均值向量：  $\boldsymbol{\mu}_1 = (1, 0)^T, \boldsymbol{\mu}_2 = (-1, 0)^T$

协方差矩阵：  $\boldsymbol{\Sigma}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \boldsymbol{\Sigma}_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$

且两类的先验概率相等，试证明其基于最小错误率判决准则的决策分界面方程为一圆，并求其方程。

解： 基于最小错误率判决准则为

$$\begin{cases} p(\mathbf{X}|\omega_1)P(\omega_1) > p(\mathbf{X}|\omega_2)P(\omega_2) & \Rightarrow \mathbf{X} \in \omega_1 \\ p(\mathbf{X}|\omega_2)P(\omega_2) > p(\mathbf{X}|\omega_1)P(\omega_1) & \Rightarrow \mathbf{X} \in \omega_2 \end{cases} \quad (21)$$

由于两类的先验概率相等，即  $P(\omega_1) = P(\omega_2)$ ，于是决策面方程可以写成

$$\frac{p(\mathbf{X}|\omega_1)}{p(\mathbf{X}|\omega_2)} = 1 \quad (22)$$

将正态分布的概率密度函数代入，计算得

$$\begin{aligned} \frac{p(\mathbf{X}|\omega_1)}{p(\mathbf{X}|\omega_2)} &= \frac{\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_1|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}_1^{-1}(\mathbf{X} - \boldsymbol{\mu}_1) \right\}}{\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_2|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}_2^{-1}(\mathbf{X} - \boldsymbol{\mu}_2) \right\}} \\ &= 2 \exp \left\{ -\frac{1}{2} \left[ \frac{1}{2} \mathbf{X}^T \mathbf{X} + (-3, 0) \cdot \mathbf{X} + \frac{1}{2} \right] \right\} \\ &= 1 \end{aligned}$$

解： 基于最小错误率判决准则为

$$\begin{cases} p(\mathbf{X}|\omega_1)P(\omega_1) > p(\mathbf{X}|\omega_2)P(\omega_2) & \Rightarrow \mathbf{X} \in \omega_1 \\ p(\mathbf{X}|\omega_2)P(\omega_2) > p(\mathbf{X}|\omega_1)P(\omega_1) & \Rightarrow \mathbf{X} \in \omega_2 \end{cases} \quad (21)$$

由于两类的先验概率相等，即  $P(\omega_1) = P(\omega_2)$ ，于是决策面方程可以写成

$$\frac{p(\mathbf{X}|\omega_1)}{p(\mathbf{X}|\omega_2)} = 1 \quad (22)$$

将正态分布的概率密度函数代入，计算得

$$\begin{aligned} \frac{p(\mathbf{X}|\omega_1)}{p(\mathbf{X}|\omega_2)} &= \frac{\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_1|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}_1^{-1}(\mathbf{X} - \boldsymbol{\mu}_1)\right\}}{\frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_2|^{\frac{1}{2}}} \exp\left\{-\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu}_2)^T \boldsymbol{\Sigma}_2^{-1}(\mathbf{X} - \boldsymbol{\mu}_2)\right\}} \\ &= 2 \exp\left\{-\frac{1}{2}\left[\frac{1}{2}\mathbf{X}^T \mathbf{X} + (-3, 0) \cdot \mathbf{X} + \frac{1}{2}\right]\right\} \\ &= 1 \end{aligned}$$

取对数，整理，得

$$(x_1 - 3)^2 + x_2^2 = 8 + 4 \ln 2 \quad (23)$$

因此，决策面方程是以  $(3, 0)^T$  为圆心， $2\sqrt{2 + \ln 2}$  为半径的圆。

### 3.4.1 损失概念、损失函数与平均损失

设模式空间中存在 $c$ 个类别： $\omega_1, \omega_2, \dots, \omega_c$ ,

决策空间由 $a$ 个决策： $\alpha_1, \alpha_2, \dots, \alpha_a$ ,

决策 $\alpha_j$ 常指将模式 $x$ 判为某一类 $w_j$ 或者是拒判。

对一个实属 $\omega_i$  类的模式采用了决策 $\alpha_j$  所造成的损失记为：

$$\lambda(\alpha_j / \omega_i) \triangleq \lambda_{ij}$$

于是就有 $\{\omega_1, \omega_2, \dots, \omega_c\} \times \{\alpha_1, \alpha_2, \dots, \alpha_a\}$   
空间中的二元函数，称其为**损失函数**。

# 决策-损失表

|                | $\omega_1$                       | $\omega_2$                       | ... | $\omega_c$                       |
|----------------|----------------------------------|----------------------------------|-----|----------------------------------|
| $\alpha_1$     | $\lambda(\alpha_1/\omega_1)$     | $\lambda(\alpha_1/\omega_2)$     | ... | $\lambda(\alpha_1/\omega_c)$     |
| $\alpha_2$     | $\lambda(\alpha_2/\omega_1)$     | $\lambda(\alpha_2/\omega_2)$     | ... | $\lambda(\alpha_2/\omega_c)$     |
| ...            |                                  |                                  |     | ...                              |
| $\alpha_c$     | $\lambda(\alpha_c/\omega_1)$     | $\lambda(\alpha_c/\omega_2)$     | ... | $\lambda(\alpha_c/\omega_c)$     |
| $\alpha_{c+1}$ | $\lambda(\alpha_{c+1}/\omega_1)$ | $\lambda(\alpha_{c+1}/\omega_2)$ | ... | $\lambda(\alpha_{c+1}/\omega_c)$ |

$\lambda_{ij}$

■ 决策 $\alpha_j$ 指将模式 $x$ 判为 $w_j$ 或者是拒判。

$$\lambda_{ij} = \begin{cases} = 0 & i = j \\ = 1 & i \neq j \end{cases}$$

0-1损失函数

## 3.4.2 最小损失准则判决

- 可以将最小条件平均损失判决规则表示为

如果  
则判

$$R_j(\vec{x}) = \min_i [R_i(\vec{x})]$$
$$\vec{x} \in \omega_j$$

**定理：**使条件平均损失最小的判决也必然使总的平均损失最小。

所以最小条件平均损失准则也称为最小平均损失准则或最小平均风险准则，简称为**最小损失准则**。

$$R_j(\vec{x}) = \sum_{i=1}^c \lambda_{ij} p(\vec{x}|\omega_i) P(\omega_i) / p(\vec{x}) = \sum_{i=1}^c \lambda_{ij} p(\vec{x}|\omega_i) P(\omega_i) / \sum_{i=1}^c p(\vec{x}|\omega_i) P(\omega_i)$$

对于两类问题,

$$R_1(\vec{x}) = [\lambda_{11} p(\vec{x}|\omega_1) P(\omega_1) + \lambda_{21} p(\vec{x}|\omega_2) P(\omega_2)] / p(\vec{x})$$

$$R_2(\vec{x}) = [\lambda_{12} p(\vec{x}|\omega_1) P(\omega_1) + \lambda_{22} p(\vec{x}|\omega_2) P(\omega_2)] / p(\vec{x})$$

如果  $R_1(\vec{x}) \leq R_2(\vec{x})$  则:  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

这时最小损失判决规则可以表为:

$$\lambda_{11} p(\vec{x}|\omega_1) P(\omega_1) + \lambda_{21} p(\vec{x}|\omega_2) P(\omega_2) \leq \lambda_{12} p(\vec{x}|\omega_1) P(\omega_1) + \lambda_{22} p(\vec{x}|\omega_2) P(\omega_2)$$



$$\lambda_{11}p(\vec{x}|\omega_1)P(\omega_1) + \lambda_{21}p(\vec{x}|\omega_2)P(\omega_2) \begin{matrix} \leq \\ > \end{matrix} \lambda_{12}p(\vec{x}|\omega_1)P(\omega_1) + \lambda_{22}p(\vec{x}|\omega_2)P(\omega_2)$$

经整理可得：

$$(\lambda_{21} - \lambda_{22})p(\vec{x}|\omega_2)P(\omega_2) \begin{matrix} \leq \\ > \end{matrix} (\lambda_{12} - \lambda_{11})p(\vec{x}|\omega_1)P(\omega_1)$$

**两类问题的最小损失准则的似然比形式的判决规则为：**

如果  $\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \begin{matrix} \geq \\ < \end{matrix} \frac{P(\omega_2)(\lambda_{21} - \lambda_{22})}{P(\omega_1)(\lambda_{12} - \lambda_{11})}$  则判  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

若记似然比阈值

$$\theta_{12} = \frac{P(\omega_2) (\lambda_{21} - \lambda_{22})}{P(\omega_1) (\lambda_{12} - \lambda_{11})}$$

则两类问题的判决规则为：

如果  $l_{12}(\vec{x}) \geq \theta_{12}$  则判：  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

注意，若  $l_{12}(\vec{x}) = \theta_{12}$

我们规定任判或拒判。

3、设信源信号为  $\{0,1\}$ ，其通过一受加性噪声干扰的信道，噪声为正态分布，均值为零，方差为  $\sigma^2$ ，信道输出为  $X$ ，运用最小损失准则的思想，试求出最优判决规则，以区分输入是 0 还是 1。

**解：** 设信号0为  $\omega_0$  类，信号1为  $\omega_1$  类。因输入信号受正态分布  $N(0, \sigma^2)$  的加性噪声干扰，所以输出信号的加性噪声干扰，所以输出信号为信源信号与噪声的迭加，输出信号的概型由噪声确定，方差仍为  $\sigma^2$  均值分别为0和1。

输入信号值为0和1而输出幅值为 $x$  的概密函数为:

$$\begin{cases} p(x|\omega_0) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{x^2}{2\sigma^2}\right] \\ p(x|\omega_1) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-1)^2}{2\sigma^2}\right] \end{cases}$$

似然比为:

$$l_{01}(x) = \frac{p(x|\omega_0)}{p(x|\omega_1)} = \exp\left[\frac{1-2x}{2\sigma^2}\right]$$

$$l_{01}(x) = \frac{p(x|\omega_0)}{p(x|\omega_1)} = \exp\left[\frac{1-2x}{2\sigma^2}\right]$$

运用最小损失准则，判决规则为：

$$l_{01}(x) = \exp\left[\frac{1-2x}{2\sigma^2}\right] \begin{matrix} \leq \\ \geq \end{matrix} \frac{(\lambda_{10} - \lambda_{11}) P(\omega_1)}{(\lambda_{01} - \lambda_{00}) P(\omega_0)} \text{ 时 } \vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

两边取对数： 当  $x < \frac{1}{2} - \sigma^2 \ln\left[\frac{(\lambda_{10} - \lambda_{11}) P(\omega_1)}{(\lambda_{01} - \lambda_{00}) P(\omega_0)}\right]$  时

判  $x \in \omega_0$  即信号为“0”。

若取  $\lambda_{01} = \lambda_{10} = 1$  ,  $\lambda_{00} = \lambda_{11} = 0$  ,  $P(\omega_0) = P(\omega_1) = \frac{1}{2}$

则  $x < \frac{1}{2}$  时，应判信号为“0”；  $x > \frac{1}{2}$  时应判信号为“1”。

这和我们通常的习惯处理方法是一致的。

**例：** 设正常细胞属于 $\omega_1$ 类，异常细胞属于 $\omega_2$ 类，它们的先验概率分别为 $P(\omega_1) = 0.9$ ， $P(\omega_2) = 0.1$ 。现有一个待识细胞，其观测矢量为 $\vec{x}$ ，从类概密曲线上查得 $p(\vec{x}|\omega_1) = 0.2$ ， $p(\vec{x}|\omega_2) = 0.4$ 。如果损失系数取为 $\lambda_{11} = 0$ ， $\lambda_{12} = 1$ ， $\lambda_{21} = 6$ ， $\lambda_{22} = 0$ 。试用最小误判概率准则和最小损失准则判断该细胞是正常的还是异常的。

**解：** 由贝叶斯定理可以分别算出 $\omega_1$ 和 $\omega_2$ 的后验概率。

$$P(\omega_1|\vec{x}) = \frac{p(\vec{x}|\omega_1)P(\omega_1)}{\sum_{i=1}^2 p(\vec{x}|\omega_i)P(\omega_i)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$



$$P(\omega_1|\vec{x})=0.818 \quad P(\omega_2|\vec{x})=1-P(\omega_1|\vec{x})=0.182$$

因  $P(\omega_1|\vec{x})=0.818 > P(\omega_2|\vec{x})=0.182$ ，所以按最小误判概率准则，应判  $\vec{x}$  归于正常细胞。

当依据损失进行判决时，需计算条件平均损失。

$$R(\alpha_1|\vec{x}) = \sum_{i=1}^2 \lambda_{i1} P(\omega_i|\vec{x}) = \lambda_{21} P(\omega_2|\vec{x}) = 1.092$$

$$R(\alpha_2|\vec{x}) = \sum_{i=1}^2 \lambda_{i2} P(\omega_i|\vec{x}) = \lambda_{12} P(\omega_1|\vec{x}) = 0.818$$

取损失最小的判决，由于  $R(\alpha_1|\vec{x}) > R(\alpha_2|\vec{x})$ ，故  $\vec{x} \in \omega_2$

之所以这两个判决结果相反，是因为  $\lambda_{21}$  取得较大的缘故。

### 3.4.3 含拒绝判决的最小损失判决

拒绝判决可以作为最小损失判决中的一个可能判决,

$$\alpha_{c+1} = \text{“拒绝判决”}。$$

令 $\lambda(\alpha_{c+1}/\omega_i)$ 表示模式 $\vec{x}$ 实属 $\omega_i$ 类但拒绝作出判决所造成的损失, 于是在模式 $\vec{x}$ 条件下拒绝判决的平均损失为

$$R(\alpha_{c+1}|\vec{x}) = \sum_{i=1}^c \lambda(\alpha_{c+1}/\omega_i)P(\omega_i|\vec{x})$$

**如果**  $R(\alpha_{c+1}|\vec{x}) < R(\alpha_j|\vec{x}) \quad j=1, 2, \dots, c$

**则作出拒绝判决。**

4、在图像识别中，假定有汽车和自行车两种类型，它们的先验概率分别是 0.8 和 0.2，损失函数如下表所示，其中  $\omega_1$  和  $\omega_2$  分别表示汽车和自行车， $\alpha_1$  和  $\alpha_2$  表示判决为汽车和自行车， $\alpha_3$  表示拒绝判决。

|            | $\omega_1$ | $\omega_2$ |
|------------|------------|------------|
| $\alpha_1$ | 0.5        | 6          |
| $\alpha_2$ | 2          | 1          |
| $\alpha_3$ | 1.5        | 1.5        |

现在做了三次实验，从类概率密度函数曲线上查得三个样本  $X_1, X_2, X_3$  的类概率密度值如下：

$$X_1 : p(X_1 | \omega_1) = 0.1, p(X_1 | \omega_2) = 0.7$$

$$X_2 : p(X_2 | \omega_1) = 0.3, p(X_2 | \omega_2) = 0.45$$

$$X_3 : p(X_3 | \omega_1) = 0.6, p(X_3 | \omega_2) = 0.5$$

- (1) 试用贝叶斯最小误判概率准则判决三个样本各属于哪一个类型；
- (2) 假定只考虑前两种判决，试用贝叶斯最小风险判决准则判决三个样本各属于哪一个类型；
- (3) 把拒绝判决考虑在内，重新考核三次实验的结果。

(1) 贝叶斯最小误判准则:

$$p(X|\omega_1)P(\omega_1) > p(X|\omega_2)P(\omega_2) \Rightarrow X \in \omega_1$$

$$p(X|\omega_1)P(\omega_1) < p(X|\omega_2)P(\omega_2) \Rightarrow X \in \omega_2$$

第一个样本:

$$p(X_1|\omega_1)P(\omega_1) = 0.1 \times 0.8 = 0.08$$

$$p(X_1|\omega_2)P(\omega_2) = 0.14$$

$$X_1 \in \omega_2$$

第二个样本:

$$p(X_2|\omega_1)P(\omega_1) = 0.24$$

$$p(X_2|\omega_2)P(\omega_2) = 0.09$$

$$X_2 \in \omega_1$$

第三个样本:

$$p(X_3|\omega_1)P(\omega_1) = 0.48$$

$$p(X_3|\omega_2)P(\omega_2) = 0.1$$

$$X_3 \in \omega_1$$

(2) 考虑前两种判决, 贝叶斯最小风险判决准则

$$l_{12} > \theta_{12} \Rightarrow x \in \omega_1$$

$$l_{12} < \theta_{12} \Rightarrow x \in \omega_2$$

$$l_{12} = \frac{p(x|\omega_1)}{p(x|\omega_2)} \quad \text{似然比}$$

$$\theta_{12} = \frac{[L(\alpha_1|\omega_2) - L(\alpha_2|\omega_2)]P(\omega_2)}{[L(\alpha_2|\omega_1) - L(\alpha_1|\omega_1)]P(\omega_1)} = \frac{5}{6}$$

第一个样本:

似然比阈值

$$l_{12} = \frac{1}{7} < \theta_{12} = \frac{5}{6}$$

$$X_1 \in \omega_2$$

第二个样本:

$$l_{12} = \frac{2}{3} < \theta_{12} = \frac{5}{6}$$

$$X_2 \in \omega_2$$

第三个样本:

$$l_{12} = 1.2 > \theta_{12} = \frac{5}{6}$$

$$X_3 \in \omega_1$$

## 条件平均风险

$$R(\alpha_{N+1} | \mathbf{X}) < R(\alpha_i | \mathbf{X}), \forall i = 1, 2, \dots, N \Rightarrow \mathbf{X} \in \alpha_{N+1}$$

$$R(\alpha_i | \mathbf{X}) = \sum_{j=1}^N L(\alpha_i | \omega_j) P(\omega_j | \mathbf{X}) = \sum_{j=1}^N L(\alpha_i | \omega_j) \frac{p(\mathbf{X} | \omega_j) P(\omega_j)}{\sum_{j=1}^N p(\mathbf{X} | \omega_j) P(\omega_j)}, i = 1, 2, 3, \dots, N+1$$

第一个样本:

$$R(\alpha_1 | \mathbf{X}_1) = 4$$

$$R(\alpha_2 | \mathbf{X}_1) = \frac{15}{11} \approx 1.36$$

$$R(\alpha_3 | \mathbf{X}_1) = 1.5$$

$$\mathbf{X}_1 \in \omega_2$$

第二个样本:

$$R(\alpha_1 | \mathbf{X}_2) = 2$$

$$R(\alpha_2 | \mathbf{X}_2) = \frac{19}{11} \approx 1.73$$

$$R(\alpha_3 | \mathbf{X}_2) = 1.5$$

拒绝判决

第三个样本:

$$R(\alpha_1 | \mathbf{X}_3) = \frac{42}{29} \approx 1.45$$

$$R(\alpha_2 | \mathbf{X}_3) = \frac{53}{29} \approx 1.83$$

$$R(\alpha_3 | \mathbf{X}_3) = 1.5$$

$$\mathbf{X}_3 \in \omega_1$$

5、简答题：（1）简述统计模式识别中概率方法与几何方法的区别。

解： 几何分类方法，是在模式类别集合可分的情形下适用的分类方法，该方法将  $d$  维的每个样本看作  $d$  维空间中的点，相同类别的样本有聚集性，不同类别的样本之间可以通过判决面分开。理想的基于几何分类方法的分类器是没有错误分类的。

概率分类方法，则认为不同类别的样本之间存在混叠现象，或者观测样本本身存在不确定性，这时样本已不再几何可分，不能实现无错误的分类。概率方法的主要内容，就是利用样本的统计特性，寻求误分概率最小化意义下的最佳分类。

5、简答题：（2）简要分析最小最大判决准则的基本思想；它的错分概率是最小的吗？为什么？

## 最小最大损失准则的基本思想：

实际中，类先验概率  $P(\omega_i)$  往往不能精确知道或在分析过程中是变动的，从而导致判决域不是最佳的。所以应考虑如何解决在  $P(\omega_i)$  不确定或变动的情况下使平均损失变小的问题。

应该立足最差的情况争取最好的结果。



5、简答题：（2）简要分析最小最大判决准则的基本思想；它的错分概率是最小的吗？为什么？

最小最大判决准则的基本思想：在最坏的情况下取得最好的结果，在其他情况下并不追求性能的最佳化。在最坏的情况下，它给出最好的结果，而在其他情况下给出的结果既不是最差也不是最好。具体来讲就是使最大的总平均风险最小化而给出的分类判决。

解：在最小风险判决规则中，求条件平均风险  $R(\alpha_i|\mathbf{X})$  需要知道各类别的先验概率  $P(\omega_j)$ ，然而实际问题中往往先验概率是不知道的。最小最大判决准则就是在不确定先验概率的情况下，对特定分类器下的先验概率作最坏的估计，使得总的平均风险取到最大值。然后改变分类器，最小化这个最坏估计下的总的平均风险。记总的平均风险为  $\bar{R}$ ，则我们的目标是

$$\min_{\Omega_1, \dots, \Omega_N} \max_{P(\omega_1), \dots, P(\omega_N)} \bar{R} \quad (12)$$

并以最小化时的  $\Omega_1, \dots, \Omega_N$  作为判决分类的依据。

最小最大判决规则的错分概率不一定是最小的，因为先验概率取较好的值时，可以构造已知先验概率情况下的最小错误概率的分类器使错分概率最小。但是，最小最大判决规则构造的分类器，可以保证先验概率不确定时，总的平均风险在最坏情况下最小。

5、简答题：（3）简要分析贝叶斯统计判决准则的缺陷以及 Neyman-Pearson (N-P) 判决准则的基本思想；

在某些实际问题中，可能存在以下几种情况：

- (1) 不知道各类的先验概率  $P(\omega_i)$ ；
- (2) 难于确定误判的代价  $\lambda_{ij}$ ；
- (3) 某一种错误较另一种错误更为重要。

针对(1)，可以采用最小最大损失准则或令各类概率相等的办法克服；

针对(2)，如果允许的话，可以避免使用损失函数而采用最小误判概率准则；

针对(3)，可以采用最小损失准则判决。针对上面的三个问题，更主要的是针对(3)，我们采用 N-P 准则。

54

---

所谓N-P准则，是严格限制较重要的一类错误概率令其等于某常数而使另一类误判概率最小。

贝叶斯风险判决准则的缺陷：需要已知先验概率和类条件概率密度且二者不变。在最小风险判决情况需要对误判风险做出恰当的定义。

**Neyman-Pearson** 判决规则基本思想：在保持一类分类错误概率不变的情况下，使另外一类分类错误概率最小。

**解：** 基于贝叶斯法则的判决规则，例如最小错误判决规则、最小风险判决规则具有一些缺陷：第一，需要事先知道先验概率的具体数值  $P(\omega_i)$ ，但事实上往往并不知道先验概率的数值；第二，对误判所承担的风险有时难于定量地确定，只知道其中一种分类错误比另一种分类错误的危害更严重。因此，希望实际的判决能把危害限制在一个可以接受的范围内，在这种情况下，可以采用 Neyman-Pearson 判决规则。

Neyman-Pearson 判决规则的基本思想是：在保持一类分类错误概率不变的情况下，使另一类分类错误概率最小。考虑  $\omega_1/\omega_2$  两类问题，两个类别的判决区域分别为  $\Omega_1, \Omega_2$ ，设

$$\varepsilon_1 = \int_{\Omega_2} p(\mathbf{X}|\omega_1)d\mathbf{X} \quad (9)$$

$$\varepsilon_2 = \int_{\Omega_1} p(\mathbf{X}|\omega_2)d\mathbf{X} \quad (10)$$

即  $\varepsilon_1, \varepsilon_2$  分别表示第一类和第二类分类错误概率，则我们的目标是在保证第二类分类错误概率不变的情况下，最小化第一类分类错误概率，即

$$\min \varepsilon_1, \quad \text{subject to } \varepsilon_2 = \alpha \quad (11)$$

其中， $\alpha$  是事先确定的常数。

求解这个条件极值问题所得到的判决规则就是 Neyman-Pearson 判决规则。

本章主要介绍了贝叶斯统计决策理论为基础的贝叶斯分类方法, 其中包括了**最小误判概率、最小损失准则**等, 依据这些准则设计的分类器, 从理论上讲是最优的性能, 即分类的错误率或风险在所有可能的分类器中为最小, 因此经常被用来作为衡量其他分类器设计方法优劣的标准。

由于正态分布在**物理上**的合理性和**数学上**的计算简便性, 我们详细介绍了贝叶斯分类方法在正态分布下的几种特殊情形, 导出了其对应的判决函数、决策面方程及相应的几何描述。

下面我们简单回顾一下本章所学的几种贝叶斯决策准则：

## 1、最小误判概率准则

**两类时：** 如果  $l_{12}(\vec{x}) = \frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)}$  则判  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

**多类时：** 如果  $P(\omega_i|\vec{x}) = \max_j [P(\omega_j|\vec{x})]$  判  $\vec{x} \in \omega_i$



## 2、最小损失准则

**两类时:** 如果  $\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \geq \frac{P(\omega_2)(\lambda_{21} - \lambda_{22})}{P(\omega_1)(\lambda_{12} - \lambda_{11})}$  则判  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

**多类时:** 计算  $R(\alpha_j|\vec{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i|\vec{x}) \quad j = 1, 2, \dots, c$

若  $R(\alpha_l|\vec{x}) = \min_j R(\alpha_j|\vec{x})$  则判  $\vec{x} \in \omega_l$

### 3、含拒绝判决的最小损失准则

两类时:

$$\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \geq \frac{P(\omega_2)(1-t)}{P(\omega_1)t}$$

$$\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \leq \frac{P(\omega_2)t}{P(\omega_1)(1-t)}$$

$$\frac{P(\omega_2)t}{P(\omega_1)(1-t)} < \frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} < \frac{P(\omega_2)(1-t)}{P(\omega_1)t}$$

$\vec{x} \in \omega_1$

$\vec{x} \in \omega_2$

拒判

其中:

$$t = \frac{\lambda_r - \lambda_c}{\lambda_e - \lambda_c}$$

$\lambda_r$

拒判损失

$\lambda_e$

误判损失

$\lambda_c$

正确判决损失





### 3、含拒绝判决的最小损失准则

**多类时:** 计算  $R(\alpha_j|\vec{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i|\vec{x}) \quad j = 1, 2, \dots, c, c+1$

若  $R(\alpha_l|\vec{x}) = \min_j R(\alpha_j|\vec{x})$  则判  $\vec{x} \in \omega_l$



其中  $\alpha_{c+1}$  为拒绝判决。



#### 4、最小最大损失准则

如果  $\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \geq \frac{(\lambda_{21} - \lambda_{22})(1 - P^*(\omega_1))}{(\lambda_{12} - \lambda_{11})P^*(\omega_1)}$  则判  $\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

$P^*(\omega_1)$  是如何获得的?

$P^*(\omega_2)$

让  $P(\omega_1)$  从0 逐渐变化到1，按最小损失准则算出最小平均损失，即取各类条件平均损失的最小者。  
由此可得出R— $P(\omega_1)$  曲线，最大的R对应的 $P(\omega_1)$  就是  $P^*(\omega_1)$

## 5、N-P准则

如果  $\frac{p(\vec{x}|\omega_1)}{p(\vec{x}|\omega_2)} \geq \lambda$  , 则判

$$\vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

$\lambda$ 是如何获得的?

由  $\varepsilon_{21} = \int_{\mu(\lambda)}^{+\infty} p(l|\omega_2)dl = \varepsilon_0$

固定 $\varepsilon_0$ 反求 $\lambda$

5、简答题：（4）试述最大似然估计与贝叶斯估计的区别；

## 最大似然估计与贝叶斯估计的比较

- 参数的解释不同：
  - ML：待估参数具有确定值，它的估计量才是随机的
  - Bayes：待估参数服从某种分布的随机变量。
- 利用的信息不同
  - ML：只利用样本信息
  - Bayes：要求事先提供一个参数的先验分布，即人们对有关参数的主观认识，是非样本信息。在参数估计中它们与样本信息一起被利用。
- 选择参数估计量的准则不同：
  - ML：最大似然为准则求解参数估计量
  - Bayes：要构造一个损失函数并以损失函数最小化为准则

5、简答题：（5）什么是非参数估计？它与参数估计有什么区别。

## 一、参数估计与非参数估计

**参数估计：**先假定研究的问题具有某种数学模型，如正态分布，二项分布，再用已知类别的训练样本估计里面的参数。

**非参数估计：**不假定数学模型，直接用已知类别的训练样本的先验知识直接估计数学模型。

参数估计：适用于类条件概率密度的函数形式已知，但是相关参数未知的情况。此时相应的估计问题转换为一个参数估计问题求解。

非参数估计：适用于类条件概率密度函数的形式和相关参数都未知的情况。此时需要根据给定的样本同时确定类条件概率密度的函数形式和相关参数。

5、简答题：（5）什么是非参数估计？它与参数估计有什么区别。

## ■ 原理

- 在实际应用中，类概率密度函数形式已知的条件并不一定成立，特别是多峰的概率分布，用普通函数难以拟合，这就需要用非参数估计技术。
- 非参数估计的原理是：不需获取类类概率密度的函数形式，而是直接利用学习样本估计特征空间任意点的类概率密度的值。
- 即直接由学习样本来直接设计分类器。

5、简答题：（5）什么是非参数估计？它与参数估计有什么区别。

## ■ 方法

➤ 直接由学习样本估计类概率密度  $P(X/\omega_i)$  ,  
*Parzen*窗口法

➤ 直接由学习样本估计后验概率  $P(\omega_i/X)$  ,  $K_n$  近邻法

非参数估计法

*Parzen*窗口法

$K_n$ 近邻法



5、简答题：（5）什么是非参数估计？它与参数估计有什么区别。

