

第二章 统计模式识别中的 几何分类法

中科大 自动化系 於俊



小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：


- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。

二、感知器法

感知器（perceptron）是一个具有单层计算单元的人工神经网络。感知器训练算法就是由这种神经网络演变来的。

1. 感知器的概念

美国学者F. Rosenblatt在1957年提出了感知器的模型，如下图。



感知器实质上是一种神经元模型，是一个多输入/单输出的非线性器件。用一个数学表达式表示，就是：

$$y = f\left(\sum_{i=1}^d w_i x_i - \theta\right)$$

2. 感知器训练算法

已知感知器输出函数：
$$y = \begin{cases} 1, & \sum_{i=1}^d w_i x_i - \theta > 0 \\ -1, & \sum_{i=1}^d w_i x_i - \theta \leq 0 \end{cases}$$

令： $w_{d+1} = -\theta$ ， $w_0^T = (w_1, w_2, \dots, w_d)$ ， $g(x) = w_0^T x + w_{d+1}$ （ $g(x)$ 是判决函数）

又令： $y = 1$ ， $y = -1$ 分别表示两种类型，则感知器输出函数变为：

若： $g(x) \begin{cases} > 0 \\ \leq 0 \end{cases}$ ，则 $x \in \begin{cases} w_i \\ w_j \end{cases}$

[可以这样考虑：用样本进行训练时，若 $x \in w_i, g(x) > 0$ ，则 w 不变。
而 $g(x) < 0$ ，则修改 w ，直到所有样本都满足条件为止。]



针对 w_i/w_j 两类问题, 利用增广型模式向量和增广型加权向量及判

决规则: $w^T x \begin{cases} > 0 \\ < 0 \end{cases}$, 则 $x \in \begin{cases} w_i \\ w_j \end{cases}$, 说明感知器算法。

设训练样本集 $X = \{x_1, x_2, \dots, x_n\}$, 其中每个样本 $x_k, k = 1, 2, \dots, n$, 分别属于类型 w_i 或类型 w_j , 且 x_k 类别属性已知。为了确定加权向量 w^* , 执行:

① 给定初始值: 置 $k = 0$, 分别给每个权向量赋任意值, 可选常数 $c > 0$ 。

② 输入训练样本 x_k , $x_k \in \{x_1, x_2, \dots, x_n\}$

③ 计算判决函数值: $g(x_k) = [w(k)]^T x_k$



④ 修正权向量 $w(k)$ ，修正规则如下：

若 $x_k \in w_i$ 和 $g(x_k) \leq 0$ ，则 $w(k+1) = w(k) + cx_k$

若 $x_k \in w_j$ 和 $g(x_k) > 0$ ，则 $w(k+1) = w(k) - cx_k$

如果类型 w_j 的训练样本 x_k 的各分量均乘以 (-1) ，则修正规则统一为：

若： $g(x_k) \leq 0$ ，则 $w(k+1) = w(k) + cx_k$

⑤ 令 $k = k + 1$ ，返回②。直到 w 对所有训练样本均稳定不变，则结束。一般情况， $0 < c \leq 1$ 。 c 值大小会影响收敛速度和稳定性， c 太小收敛速度慢， c 太大，会使 $w(k)$ 的值不稳定。


■ 感知器算法实质上是一种赏罚过程

- 对正确分类的模式则“赏”，实际上是“不罚”，即权向量不变。
- 对错误分类的模式则“罚”，使 $w(k)$ 加上一个正比于 x_k 的分量。
- 当用全部模式样本训练过一轮以后，只要有一个模式是判别错误的，则需要进行下一轮迭代，即用全部模式样本再训练一次。
- 如此不断反复直到全部模式样本进行训练都能得到正确的分类结果为止。

例：一个两类问题，4个训练样本。

$$w_1: (0, 0)^T, (0, 1)^T$$

$$w_2: (1, 0)^T, (1, 1)^T$$



用感知器求权向量 w^* 。

解：将训练样本变为增广型的， w_2 样本乘以 (-1) ，得到4个样本：

$$X = \{x_1, x_2, x_3, x_4\}$$

增广向量： $x_1 = (0,0,1)^T$ ， $x_2 = (0,1,1)^T$ ， $x_3 = (-1,0,-1)^T$ ， $x_4 = (-1,-1,-1)^T$ 。

$$g(x) = w^T x = (w_1, w_2, \dots, w_d, w_{d+1},) \begin{pmatrix} x_1 \\ \vdots \\ x_d \\ 1 \end{pmatrix}$$

取初值： $w(0) = (1,1,1)^T$ ， $c = 1$ 。

$$k=0, \quad x_k = x_1, \quad g(x_k) = w(k)^T x_k = (1,1,1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 > 0, \quad w(1) = w(0), \quad w \text{ 不变}$$

$$k=1, \quad x_k = x_2, \quad g(x_k) = w(k)^T x_k = (1,1,1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 2 > 0, \quad w(2) = w(1)$$

$$k=2, \quad x_k = x_3, \quad g(x_k) = w(k)^T x_k = (1,1,1) \begin{pmatrix} -1 \\ 0 \\ -1 \end{pmatrix} = -2 < 0, \quad w(3) = w(2) + x_3 = (0,1,0)^T$$

$$k=15, \quad x_k = x_3, \quad g(x_k) = w(k)^T x_k = (-3, 0, 1) \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix} = 2 > 0, \quad w(16) = w(15)$$

$$k=16, \quad x_k = x_1, \quad g(x_k) = w(k)^T x_k = (-3, 0, 1) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 1 > 0, \quad w(17) = w(16)$$

从 $k=13 \sim 16$ 的结果可以看出，使用 $w(13)$ 已经能对所有训练样本正确分类，也就是算法收敛于 $w(13)$ 。 $w(13)$ 即为解向量。

$$w^* = (-3, 0, 1)^T, \quad g(x) = w^* x = (-3, 0, 1) \begin{bmatrix} x_1 \\ x_2 \\ 1 \end{bmatrix} = -3x_1 + 1$$

分界面 $g(x) = 0$ ，也就是： $x_1 = \frac{1}{3}$ ，如上图所示。 w^* 是不唯一的， w^* 属于解集空间。

1、 (1) 对以下样本集合，使用感知器算法求解线性分类器（取初始 W 为全 0 向量，取 $\rho = 1$ ），请写出迭代过程，并求出解向量和分界面。

$$\omega_1: X_1 = (1,0)^T; \omega_2: X_2 = (-1,0)^T, X_3 = (0,1)^T$$

- 模式类的增广形式: $\omega_1: X_1 = (1,0,1)^T; \omega_2: X_2 = (-1,0,1)^T, X_3 = (0,1,1)^T$
- $k = 0, g(X_1) = 0; \quad W(1) = W(0) + \rho X_1 = (1,0,1)^T; \quad N_c = 0$
- $k = 1, g(X_2) = 2; \quad W(2) = W(1) - \rho X_2 = (2,0,0)^T; \quad N_c = 0$
- $k = 2, g(X_3) = 0; \quad W(3) = W(2) - \rho X_3 = (2, -1, -1)^T; \quad N_c = 0$
- $k = 3, g(X_1) = 2; \quad W(4) = W(3); \quad N_c = 1$
- $k = 4, g(X_2) = -3; \quad W(5) = W(4); \quad N_c = 2$
- $k = 5, g(X_3) = -2; \quad W(6) = W(5); \quad N_c = 3$

注:

1. 增广形式
2. 迭代终止的条件为 $N_c =$ 样本个数
3. 每次迭代只输入一个样本

$$g(x) = 2x_1 - x_2 - 1$$

$$\text{分界面 } g(x) = 0 \text{ 得 } 2x_1 - x_2 - 1 = 0$$

4. 感知器训练算法在多类问题中的应用(推广)

在上一节，介绍了多类问题的三种情况。其中，第三种情况是没有不确定区的，对于 c 种类型中的某一种类型 w_i ，存在 k 个判别函数，如果样本 $x \in w_i$ ，则： $g_i(x) > g_j(x) \quad j=1,2,\dots,k \quad i \neq j$ ，其中 k 取决于在特征空间里与类型 w_i 相邻的类型数目， $k \leq c$ 。这样就把多类问题转变成多个没有不确定区的 w_i/w_j 两类问题，可使用最大值判决规则。

假定 $k=c$ ，首先建立 c 个判决函数： $g_i(x) = w_i^T x$ ， $i=1,2,\dots,c$ 。

判决规则为：若 $g_i(x) > g_j(x)$ ， $j=1,2,\dots,c$ ， $j \neq i$ ，则 $x \in w_i$ 。

将本节2中介绍的感知器训练算法用到这种情况，可以建立如下
的算法步骤。

① 赋给初始值：分别赋给 c 个权向量 w_i ($i=1,2,\dots,c$) 任意的初值，
选择正常数 c ，把训练样本变为增广型模式向量，置 $k=0$ 。

② 输入训练样本 x_k ， $x_k \in \{x_1, x_2, \dots, x_n\}$ ，假定 $x_k \in w_i$

③ 计算 c 个判决函数值： $g_i(x_k) = w_i(k)^T x_k$ $i=1,2,\dots,c$

④ 修正权向量。修正规则为：

若 $g_i(x) > g_j(x)$ ， $j=1,2,\dots,c$ ， $j \neq i$ ，则 $w_i(k+1) = w_i(k)$ ， $i=1,2,\dots,c$ 。

否则，若 $g_l(x_k) > g_i(x_k)$ ，则：

$$\begin{cases} w_i(k+1) = w_i(k) + cx_k \\ w_l(k+1) = w_l(k) - cx_k \\ w_j(k+1) = w_j(k) \quad j \neq i, j \neq l \end{cases}$$

⑤ 令 $k=k+1$ ，返回②。直到所有的权向量对所有训练样本都稳定
不变时结束。只要模式样本线性可分，则算法迭代有限次后收敛。

例：已知三类训练样本： $w_1 = (0, 0)^T$ ， $w_2 = (1, 1)^T$ ， $w_3 = (-1, 1)^T$

试求解 w_1^* ， w_2^* ， w_3^* 。

解：训练样本变成增广型模式向量：

$$x_1 = (0, 0, 1)^T, \quad x_2 = (1, 1, 1)^T, \quad x_3 = (-1, 1, 1)^T$$

在此， x 的下标就是它所属类型，且没有一个样本乘以 (-1) 。置

$k=0$ ，选 $c=1$ 。

赋初值： $w_1(0) = (0, 0, 0)^T$ ， $w_2(0) = (0, 0, 0)^T$ ， $w_3(0) = (0, 0, 0)^T$ ，开始迭代：

$k=0$ ， $x_k = x_1 \in w_1$ 但 $g_1(x_k) = 0$ ， $g_2(x_k) = 0$ ， $g_3(x_k) = 0$ ， $g_1(x_k) \not> g_2(x_k)$ ， $g_1(x_k) \not> g_3(x_k)$ 。

所以：

$$\begin{cases} w_1(1) = w_1(0) + x_1 = (0, 0, 1)^T \\ w_2(1) = w_2(0) - x_1 = (0, 0, -1)^T \\ w_3(1) = w_3(0) - x_1 = (0, 0, -1)^T \end{cases}$$

$$k=1, \quad x_k = x_2 \in w_2 \text{ 但 } g_1(x_k) = (0,0,1) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = 1, \quad g_2(x_k) = (0,0,-1) \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = -1,$$

$$g_3(x_k) = -1, \quad g_1(x_k) > g_2(x_k), \quad g_2(x_k) \not> g_3(x_k)。$$

$$\text{所以: } \begin{cases} w_1(2) = w_1(1) - x_2 = (-1, -1, 0)^T \\ w_2(2) = w_2(1) + x_2 = (1, 1, 0)^T \\ w_3(2) = w_3(1) - x_2 = (-1, -1, -2)^T \end{cases}$$

$$k=2, \quad x_k = x_3 \in w_3 \text{ 但 } g_1(x_k) = (-1, -1, 0) \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = 0, \quad g_2(x_k) = (1, 1, 0) \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = 0, \quad g_3(x_k) =$$

$$-2, \quad g_3(x_k) < g_1(x_k) \quad g_3(x_k) < g_2(x_k)。$$

$$\text{所以: } \begin{cases} w_1(3) = w_1(2) - x_3 = (0, -2, -1)^T \\ w_2(3) = w_2(2) - x_3 = (2, 0, -1)^T \\ w_3(3) = w_3(2) + x_3 = (-2, 0, -1)^T \end{cases}$$

$$k=5, \quad x_k = x_3 \in w_3 \text{ 但 } g_1(x_k) = (0, -2, 0) \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = -2, \quad g_2(x_k) = (2, 0, -2) \begin{pmatrix} -1 \\ 1 \\ 1 \end{pmatrix} = -4,$$

$$g_3(x_k) = 0, \quad g_3(x_k) > g_1(x_k) \quad g_3(x_k) > g_2(x_k)$$

$$\text{所以: } \begin{cases} w_1(6) = w_1(5) \\ w_2(6) = w_2(5) \\ w_3(6) = w_3(5) \end{cases}$$

$$k=6, \quad x_k = x_1 \in w_1 \text{ 但 } g_1(x_k) = (0, -2, 0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0, \quad g_2(x_k) = (2, 0, -2) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = -2,$$

$$g_3(x_k) = -2, \quad g_1(x_k) > g_2(x_k) \quad g_1(x_k) > g_3(x_k)$$

因此，可得到3个解向量： $w_1^* = w_1(4)$ ， $w_2^* = w_2(4)$ ， $w_3^* = w_3(4)$ 。

对应的三个判决函数： $g_1(x) = -2x_2$ ， $g_2(x) = 2x_1 - 2x_2$ ， $g_3(x) = -2x_1 - 2$ 。

(2) 有三个模式类： $\omega_1: X_1 = (-1, -1)^T$; $\omega_2: X_2 = (2, -1)^T$; $\omega_3: X_3 = (-2, 2)^T$,
使用感知器算法求解线性分类器（取初始 W 为全 0 向量，取 $\rho = 1$ ），请写出
迭代过程，并求出解向量和判决函数。

模式类的增广形式： $\omega_1: X_1 = (-1, -1, 1)^T$, $\omega_2: X_2 = (2, -1, 1)^T$, $\omega_3: X_3 = (-2, 2, 1)^T$

三个决策函数： $g_1(X) = W_1^T X$, $g_2(X) = W_2^T X$, $g_3(X) = W_3^T X$

初始权向量： $W_1(0) = W_2(0) = W_3(0) = [0, 0, 0]^T$, $\rho = 1$

1) $k = 0$, $g_1(X_1) = 0$, $g_2(X_1) = 0$, $g_3(X_1) = 0$, $Nc = 0$

由于 $g_1(X_1) = g_2(X_1)$, $g_1(X_1) = g_3(X_1)$, 所以对 $W_1 W_2 W_3$ 进行修正

$$W_1(1) = W_1(0) + \rho X_1 = (-1, -1, 1)^T$$

$$W_2(1) = W_2(0) - \rho X_1 = (1, 1, -1)^T$$

$$W_3(1) = W_3(0) - \rho X_1 = (1, 1, -1)^T$$

2) $k = 1$, $g_1(X_2) = 0$, $g_2(X_2) = 0$, $g_3(X_2) = 0$, $Nc = 0$

由于 $g_2(X_2) = g_1(X_2)$, $g_2(X_2) = g_3(X_2)$, 所以对 $W_1 W_2 W_3$ 进行修正

$$W_1(2) = W_1(1) - \rho X_2 = (-3, 0, 0)^T$$

$$W_2(2) = W_2(1) + \rho X_2 = (3, 0, 0)^T$$

$$W_3(2) = W_3(1) - \rho X_2 = (-1, 2, -2)^T$$

(2) 有三个模式类： $\omega_1: X_1 = (-1, -1)^T$; $\omega_2: X_2 = (2, -1)^T$; $\omega_3: X_3 = (-2, 2)^T$,
使用感知器算法求解线性分类器（取初始 W 为全 0 向量，取 $\rho = 1$ ），请写出
迭代过程，并求出解向量和判决函数。

$$3) \quad k = 2, g_1(X_3) = 6, g_2(X_3) = -6, g_3(X_3) = 4, N_c = 0$$

由于 $g_1(X_3) > g_3(X_3)$ ，所以对 W_1 W_3 进行修正

$$W_1(3) = W_1(2) - \rho X_3 = (-1, -2, -1)^T$$

$$W_2(3) = W_2(2) = (3, 0, 0)^T$$

$$W_3(3) = W_3(2) + \rho X_3 = (-3, 4, -1)^T$$

$$4) \quad k = 3, g_1(X_1) = 2, g_2(X_1) = -3, g_3(X_1) = -2, N_c = 1$$

由于 $g_1(X_1) > g_2(X_1)$, $g_1(X_1) > g_3(X_1)$ ，所以无需修正

$$W_1(4) = W_1(3) = (-1, -2, -1)^T$$

$$W_2(4) = W_2(3) = (3, 0, 0)^T$$

$$W_3(4) = W_3(3) = (-3, 4, -1)^T$$

$$5) \quad k = 4, g_1(X_2) = -1, g_2(X_2) = 6, g_3(X_2) = -11, N_c = 2$$

由于 $g_2(X_2) > g_1(X_2)$, $g_2(X_2) > g_3(X_2)$ ，所以无需修正

$$W_1(5) = W_1(4) = (-1, -2, -1)^T$$

$$W_2(5) = W_2(4) = (3, 0, 0)^T$$

$$W_3(5) = W_3(4) = (-3, 4, -1)^T$$

$$6) \quad k = 5, g_1(X_3) = -3, g_2(X_3) = -6, g_3(X_3) = 13, N_c = 3$$

由于 $g_3(X_3) > g_1(X_3)$, $g_3(X_3) > g_2(X_3)$ ，所以无需修正

$$W_1(6) = W_1(5) = (-1, -2, -1)^T$$

$$W_2(6) = W_2(5) = (3, 0, 0)^T$$

$$W_3(6) = W_3(5) = (-3, 4, -1)^T$$

由于 $N_c = 3$ ，迭代终止

得到判决函数

$$g_1(X) = W_1^T X = [-1, -2, -1]X$$

$$g_2(X) = W_2^T X = [3, 0, 0]X$$

$$g_3(X) = W_3^T X = [-3, 4, -1]X$$

小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：

- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。

三、最小平方误差准则(MSE法)---非迭代法

针对 w_i / w_j 二类问题，利用增广型加权向量和增广型模式向量，并把所有来自 w_j 的训练样本的各分量均乘以 (-1) ，则所有模式都应该满足： $w^T \cdot x > 0$ 。

现在任意给定一个小的正数 b ，则可在解区里寻找一个解向量 w ，使之满足： $w^T \cdot x = b$ 。

假定有 n 个训练样本，则上式可以写成 n 个联立方程组：

$$\begin{cases} w^T x_1 = b_1 \\ w^T x_2 = b_2 \\ \vdots \\ w^T x_n = b_n \end{cases}$$

式中 $b_i > 0, i = 1, 2, \dots, n$

上述方程组可简写为： $x \cdot w = b$ (是一个超定方程组)。

其中， x 为训练样本的增广矩阵：

$$x = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix} = \left(\begin{array}{cccc} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ \vdots & & & & \\ x_{n_1 1} & x_{n_1 2} & \cdots & x_{n_1 d} & 1 \\ x_{(n_1+1)1} & x_{(n_1+1)2} & \cdots & x_{(n_1+1)d} & -1 \\ \vdots & & & & \\ x_{n_2 1} & x_{n_2 2} & \cdots & x_{n_2 d} & -1 \end{array} \right) \left\{ \begin{array}{l} n_1 \in w_i \\ n_2 \in w_j \end{array} \right.$$

$$b = [b_1, b_2, \dots, b_n]^T$$

注意：假定来自 w_i 和 w_j 的样本数目分别为 n_1 和 n_2 ，且 $n = n_1 + n_2$ ， x 为 $n \times (d+1)$ 维矩阵，一般 $n > d+1$ 。 b 为 n 维列向量。 w 为 $d+1$ 维列向量。

如果样本是线性可分的，则 x 的任意 $(d+1) \times (d+1)$ 子阵的秩均等于 $d+1$ 。这时可以通过最小二乘法求解。

定义：误差向量 $e = xw - b$

又定义平方误差准则函数： $J_s(w, x, b) = \|e\|^2 = \|xw - b\|^2 = \sum_{i=1}^n (w^T x_i - b_i)^2$

约束条件：要使 J_s 得到的解 w 就是解向量 w^* ，必须保证 $w^T x_i - b_i \geq 0$ 。

下面求 J_s 的极小值： $\frac{\partial J_s}{\partial w} = 2x^T(xw^* - b)$

令 $\frac{\partial J_s}{\partial w} = 0$ ，得到 $2x^T(xw^* - b) = 0 \rightarrow x^T x w^* - x^T b = 0$

所以有： $w^* = (x^T x)^{-1} x^T b$

上式中：用 $x^\# = (x^T x)^{-1} x^T$ 代入，得到 $w^* = x^\# b$ 。

其中， $x^\#$ 称为 x 的伪逆， w^* 是伪逆解。

取：

$$b = \begin{bmatrix} N / N_1 \\ \dots\dots \\ N / N_1 \\ N / N_2 \\ \dots\dots \\ N / N_2 \end{bmatrix}$$

其中 N/N_1 有 N_1 个， N/N_2 有 N_2 个

最小平方误差法同 Fisher 法是一致的

上节得到MSE法的W解为： $W=X^{\#}b$

伪逆 $X^{\#}=(X^T X)^{-1} X^T$ 计算量很大

在计算 $X^{\#}$ 时，

1. 要求 $X^T X$ 矩阵为非奇异
2. 由于计算量太大而引入比较大误差

所以要用迭代法来求

至此，我们就建立了一种算法，通常称为LMSE算法，即最小均方误差算法。LMSE: Least Mean Square Error。这种算法也简称H-K算法。其主要内容为：

$$\begin{cases} w^*(k+1) = w^*(k) + cx^{\#}(e_k + |e_k|) \\ w^*(1) = x^{\#}b(1) \\ b(1) > 0 \end{cases}$$

H-K算法

该算法的步骤如下：

- ① 由训练样本集构成增广矩阵 x ，求伪逆 $x^\# = (x^T x)^{-1} x^T$ 。
- ② 赋初值 $b(1)$ ，应使其各分量为正值。选常数 c ，置 $k=1$ 。
- ③ 计算： $w(k) = x^\# b(k)$ ， $e_k = xw(k) - b(k)$ 。
- ④ 判断：若 e_k 的各分量停止变为正值或者不是全部为0，则线性不可分，中止迭代。否则，若 e_k 的各分量均接近于0，即 $e_k \rightarrow 0$ ，则迭代过程完成，结束。否则算法继续。
- ⑤ 计算： $w(k+1) = w(k) + cx^\# [e_k + |e_k|] = w(k) + cx^\# |e_k|$
 $b(k+1) = b(k) + c[e_k + |e_k|]$

『注意推导：

$$x^\# e_k = (x^T x)^{-1} \cdot x^T [xw(k) - b(k)] = (x^T x)^{-1} \cdot x^T [xx^\# - 1]b(k) = (x^T x)^{-1} \cdot (x^T - x^T)b(k) = 0$$

其中： $w(k) = x^\# b(k)$ ， $x^T x x^\# = (x^T x)(x^T x)^{-1} x^T = x^T$ 』

⑥ 令 $k = k + 1$ ，返回③

注意：第⑤步中，可以先计算 $b(k+1)$ ，然后再由公式 $w(k+1) = x^\# b(k+1)$

求 $w(k+1)$ 。

可以证明：当模式类型可分，且 $0 < c \leq 1$ 时，H-K算法收敛。证明收敛性的关键在于，在极限情况下， $e_k = xw(k) - b(k) = 0$ ，而H-K算法中指出 $b(k)$ 的各分量为非负的矢量，故若 $xw(k) = b(k)$ ，则 $xw(k) > 0$ （回到本节1中的定义）。

算法没有给出精确的迭代次数，通常在每次迭代后均对 $xw(k)$ 和 e_k 进行检查，当 $xw(k) > 0$ 或 $e_k = 0$ ，则有解；反之，若 e_k 变为非正，则迭代停止，表明模式线性不可分。

■ 例题:

$$\omega_1 = \{(0,0)^T, (0,1)^T\} \quad \omega_2 = \{(1,0)^T, (1,1)^T\}$$


■ 解: 正规化

对 ω_2 取负, 有

$$X = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

X的伪逆矩阵为

$$X^\# = (X^T X)^{-1} X^T = \frac{1}{2} \begin{bmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & 1 & 1 \\ 3/2 & 1/2 & -1/2 & 1/2 \end{bmatrix}$$



取 $b_1 = (1, 1, 1, 1)^T$ $c = 1$

$$W_1 = X^\# b_1 = (-2, 0, 1)^T$$


因为

$$X W_1 = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix} \begin{bmatrix} -2 \\ 0 \\ 1 \end{bmatrix} = (1, 1, 1, 1)^T > 0$$

所以 W_1 为所求解 $e_1 = XW_1 - b_1 = 0$ 系统线性可分

3、 两类样本： $\omega_1 : (1,1)^T, (2,3)^T$
 $\omega_2 : (2,0)^T, (4,1)^T$

- (1) 请用最小平方误差法构造线性分类器（余量 $b = [1, 2, 1, 2]^T$ ）；
 (2) 请用 H-K 算法进行分类器训练（步长因子 $\rho = 1$ ，余量初值同上）；
 (3) 用 Fisher 线性判别法构造分类器。



答：(1) $[X] = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 1 \\ -2 & 0 & -1 \\ -4 & -1 & -1 \end{bmatrix}$, $b = [1 \ 2 \ 1 \ 2]^T$,

$$X^\# = \begin{bmatrix} -0.2667 & -0.0333 & 0.0667 & -0.3667 \\ -0.0667 & 0.3667 & 0.2667 & 0.0333 \\ 0.9333 & -0.1333 & -0.7333 & 0.5333 \end{bmatrix}$$

$$W = (X^T X)^{-1} X^T b = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}$$

分类器是 $G(X) = -x_1 + x_2 + 1$

$G(X) > 0$ ，为 W_1 ， $G(X) < 0$ ，为 W_2 。

(2) 计算伪逆，

然后取余量矢量 $b(0) = [1 \ 2 \ 1 \ 2]^T$ ，由算法可知

$$W(0) = X^\# * b(0) = [-1 \ 1 \ 1]^T$$

$$e(0) = XW(0) - b(0) = [0 \ 0 \ 0 \ 0]^T$$

所以 $W(0)$ 就是所求的解，分类器和 (1) 一样。

3、 两类样本： $\omega_1 : (1,1)^T, (2,3)^T$
 $\omega_2 : (2,0)^T, (4,1)^T$

- (1) 请用最小平方误差法构造线性分类器（余量 $b = [1, 2, 1, 2]^T$ ）；
- (2) 请用 H-K 算法进行分类器训练（步长因子 $\rho = 1$ ，余量初值同上）；
- (3) 用 Fisher 线性判别法构造分类器。

(3) 计算两个类别的均值向量，

$$\mathbf{m}_x1 = \left(\frac{3}{2}, 2\right)^T, \mathbf{m}_x2 = \left(3, \frac{1}{2}\right)^T$$

计算类内总离散度矩阵

$$\begin{aligned} S_w &= \begin{bmatrix} 2.5000 & 2.0000 \\ 2.0000 & 2.5000 \end{bmatrix} \\ S_w^{-1} &= \begin{bmatrix} 1.1111 & -0.8889 \\ -0.8889 & 1.1111 \end{bmatrix} \end{aligned}$$

最佳投影方向

$$W^* = \begin{bmatrix} -3 \\ 3 \end{bmatrix}$$

$W_1: (1,1)^T$ 投影为 0, $(2,3)^T$ 投影为 3, $W_2: (2,0)^T$ 投影为 -6, $(4,1)^T$ 投影为 -9, 阈值可选为 -3, 故判决函数 $G(X) = -3X_1 + 3X_2 \rightarrow 3$ 判为 W_1 , < 3 判为 W_2 。

其实和 (1) 一样。

小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：

- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。

六、Fisher分类准则


前面讲过的感知器准则、最小平方和准则属于用神经网络的方法解决分类问题。下面介绍一种新的判决函数分类方法。

由于线性判别函数易于分析，关于这方面的研究工作特别多。历史上，这一工作是从R. A. Fisher的经典论文（1936年）开始的。我们知道，在用统计方法进行模式识别时，许多问题涉及到维数，在低维空间行得通的方法，在高维空间往往行不通。因此，降低维数就成为解决实际问题的关键。Fisher的方法，实际上涉及维数压缩。

如果要把模式样本在高(d)维的特征向量空间里投影到一条直线上,实际上就是把特征空间压缩到一维,这在数学上容易办到。另外,即使样本在高维空间里聚集成容易分开的群类,把它们投影到一条任意的直线上,也可能把不同的样本混杂在一起而变得无法区分。也就是说,直线的方向选择很重要。

在一般情况下,总可以找到某个最好的方向,使样本投影到这个方向的直线上是最容易分得开的。如何找到最好的直线方向,如何实现向最好方向投影的变换,是Fisher法要解决的基本问题。这个投影变换就是我们寻求的解向量 w^* 。

如下图:



抽样试验在直线 w 上的投影

图中画出了直线的两种选择，图(a)中， Y_1 和 Y_2 还无法分开，而图(b)的选择可以使 Y_1 和 Y_2 区分开来。所以图(b)的方向是一个好的选择。

Fisher方法实现步骤总结:

- (1) 把来自两类 ω_1/ω_2 的训练样本集 X 分成与 ω_1 对应的子集 X_1 和与 ω_2 对应的子集 X_2 。
- (2) 由 $\vec{m}_i = \frac{1}{N_i} \sum_j \vec{x}_j^{(i)}$ ($i=1,2$) , 计算 m_i 。
- (3) 由 $S_{W_i} = \sum_j (\vec{x}_j^{(i)} - \vec{m}_i)(\vec{x}_j^{(i)} - \vec{m}_i)'$, 计算各类的类内离差阵 S_{W1} , S_{W2} 。
- (4) 计算类内总离差阵 $S_W = S_{W1} + S_{W2}$ 。
- (5) 计算 S_W 的逆矩阵 S_W^{-1} 。
- (6) 按 $\vec{u} = S_W^{-1}(\vec{m}_1 - \vec{m}_2)$ 求解 μ 。

(7) 计算 $\tilde{m}_i$ 。

$$\tilde{m}_i = \frac{1}{N_i} \sum_j y_j^{(i)} = \frac{1}{N_i} \sum_j \vec{u}' x_j^{(i)} = \vec{u}' \vec{m}_i$$

(8) 计算 y_t 。 $y_t = \frac{\tilde{m}_1 + \tilde{m}_2}{2}$

(9) 对未知模式 x 判定模式类。

$$\vec{u}' \vec{x} = y \geq y_t \Rightarrow \vec{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$$

例题：有两个模式类： $\omega_1: X_1 = (0,0)^T, X_2 = (1,2)^T$; $\omega_2: X_3 = (1,-1)^T, X_4 = (3,0)^T$ ，使用 Fisher 线性判别法构造分类器，确定最佳投影方向，并简要说明类内总离散度矩阵的含义。

(1) 计算两个样本的均值向量：

$$m_x^1 = \frac{1}{n_1} \sum_{X_k \in \omega_1} X_k = [0.5, 1]^T$$

$$m_x^2 = \frac{1}{n_2} \sum_{X_k \in \omega_2} X_k = [2, -0.5]^T$$

(2) 计算类内总离散度矩阵：

$$\begin{aligned} S_w &= \sum_{X_k \in \omega_1} (X_k - m_x^1)(X_k - m_x^1)^T + \sum_{X_k \in \omega_2} (X_k - m_x^2)(X_k - m_x^2)^T \\ &= \begin{bmatrix} 0.5 & 1 \\ 1 & 2 \end{bmatrix} + \begin{bmatrix} 2 & 1 \\ 1 & 0.5 \end{bmatrix} = \begin{bmatrix} 2.5 & 2 \\ 2 & 2.5 \end{bmatrix} \end{aligned}$$

(3) 计算 S_w 的逆矩阵 S_w^{-1} ：

$$S_w^{-1} = \begin{bmatrix} \frac{10}{9} & -\frac{8}{9} \\ -\frac{8}{9} & \frac{10}{9} \end{bmatrix}$$

(4) 计算最佳投影

$$W^* = S_w^{-1}(m_x^1 - m_x^2) = [-3, 3]^T$$

(5) 类内总离散度矩阵刻画了投影后两类样本偏离各自均值的总的差异程度。

2、有两个模式类：

$$\omega_1: X_1 = (1,0)^T, X_2 = (0,1)^T;$$

$$\omega_2: X_3 = (3,3)^T, X_4 = (3,5)^T, X_5 = (5,5)^T, X_6 = (5,3)^T.$$

使用 Fisher 线性判别法构造分类器，画出样本分布和投影直线，给出分界面方程和图形。

简单说明类内总离散度矩阵在 Fisher 判别中的作用。

答：

(1)计算两个类别的均值向量

$$m_x^1 = \frac{1}{2} \sum_{X_k \in \omega_1} X_k = \left(\frac{1}{2}, \frac{1}{2}\right)^T$$

$$m_x^2 = \frac{1}{4} \sum_{X_k \in \omega_2} X_k = (4, 4)^T$$

(2)计算类内总离散度矩阵


$$\begin{aligned} S_w &= \sum_{X_k \in \omega_1} (X_k - m_x^1)(X_k - m_x^1)^T + \sum_{X_k \in \omega_2} (X_k - m_x^2)(X_k - m_x^2)^T \\ &= \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{pmatrix} + \begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix} = \begin{pmatrix} \frac{9}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{9}{2} \end{pmatrix} \end{aligned}$$

(3)计算逆矩阵

$$S_w^{-1} = \begin{pmatrix} \frac{9}{40} & \frac{1}{40} \\ \frac{1}{40} & \frac{9}{40} \end{pmatrix}$$

(4)最佳投影方向

$$W^* = S_w^{-1}(m_x^1 - m_x^2) = \left(-\frac{7}{8}, -\frac{7}{8}\right)^T$$



2、有两个模式类：

$$\omega_1: X_1 = (1,0)^T, X_2 = (0,1)^T;$$

$$\omega_2: X_3 = (3,3)^T, X_4 = (3,5)^T, X_5 = (5,5)^T, X_6 = (5,3)^T.$$

使用 Fisher 线性判别法构造分类器，画出样本分布和投影直线，给出分界面方程和图形。

简单说明类内总离散度矩阵在 Fisher 判别中的作用。

(5)降维投影

$$Y_1 = W^{*T} X_1 = -\frac{7}{8}, Y_2 = W^{*T} X_2 = -\frac{7}{8},$$


$$Y_3 = W^{*T} X_3 = -\frac{21}{4}, Y_4 = W^{*T} X_4 = -7,$$

$$Y_5 = W^{*T} X_5 = -\frac{35}{4}, Y_6 = W^{*T} X_6 = -7$$

(6)采用最近邻法分类

$$Y_0 = \frac{\left(-\frac{7}{8}\right) + (-7)}{2} = -\frac{63}{16}$$

若 $Y_k \geq Y_0$, 则 $X_k \in \omega_1$; 反之, $X_k \in \omega_2$



$$\text{分界面方程 } -\frac{7}{8}x_1 - \frac{7}{8}x_2 = -\frac{63}{16}$$

$$x_1 + x_2 = \frac{9}{2}$$

类内总离散度矩阵反映了投影后各样本偏离其均值的总的差异程度，取值越小，表明投影后各类别的样本在类内分布得越集中，也越容易区分。

小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：

- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。

下面讨论两种典型的 $f_i(\vec{x})$ 的形式

$$d(\vec{x}) = \sum_{i=1}^n w_{ii} x_i^2 + \sum_{i=1}^{n-1} \sum_{j=i+1}^n w_{ij} x_i x_j + \sum_{i=1}^n w_i x_i + w_{n+1}$$

在非线性判决函数中，一种常见的情况是 $f_i(x)$ 取 x 的平方函数，且 x 是二维的，此时：

$g(x) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$ 为二次多项式。

令 $y_1 = x_1^2$, $y_2 = x_1x_2$, $y_3 = x_2^2$, $y_4 = x_1$, $y_5 = x_2$

则： $g(x) \Leftrightarrow g(y) = w_{11}y_1 + w_{12}y_2 + w_{22}y_3 + w_1y_4 + w_2y_5 + w_3$ 。

也就是：二维二次多项式判决函数变成五维线性判决函数。

当非判决函数为线性判决之后，其中的参数 w 可以用感知器、H-K、Fisher等算法来计算。


$$d(\vec{x}) = \sum_{i=1}^n w_{ii} x_i^2 + \sum_{i=1}^{n-1} \sum_{j=i+1}^n w_{ij} x_i x_j + \sum_{i=1}^n w_i x_i + w_{n+1}$$

上式右边前两项是x各分量的二次项求和式，显然它们的项数分别为n和 $n(n-1)/2$ 。

第三项是x的各分量一次项求和式，项数为n。

所以d(x)的项数为：

$$n + n(n-1)/2 + n + 1 = (n+1)(n+2)/2$$

由于有一个常数项，变换后的特征空间维数为：

$$(n+1)(n+2)/2 - 1 = n(n+3)/2$$

4、简答题：

(1) 描述设计分类器的主要步骤；

答：1、选择合适的特征并据此构建特征空间；

2、获取已知类别的观测样本并将其映射到所构建的特征空间中；

3、根据观测样本在特征空间中的分布情况，确定相应的分界面将整个特征空间划分为与待分类的类别数相等的子区域。

(2) 设在三维空间样本 $X = (x_1, x_2, x_3)$ 中一个类别分类问题拟采用二次曲面。如欲采用广义线性方程求解，试问其广义样本向量与广义权向量的表达式是什么？其维数是多少？

答：

设二次曲面为 $ax_1^2 + bx_2^2 + cx_3^2 + dx_1x_2 + ex_1x_3 + fx_2x_3 + gx_1 + hx_2 + lx_3 + m = 0$

广义样本向量 $Y = (x_1^2, x_2^2, x_3^2, x_1x_2, x_1x_3, x_2x_3, x_1, x_2, x_3)^T$

广义权向量 $W = (a, b, c, d, e, f, g, h, l)^T$

维数：9 维

小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：

- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。

4、简答题：

(3) 势函数法的特点是什么？简要描述势函数的选择需要满足哪些条件。

势函数法的特点就是可以直接确定判决函数，它不但适用于线性分类器，而且还适用于非线性分类器。这里着重介绍势函数法，以示范一个非线性分类器。

势函数法借用电场的概念，来解决模式的分类问题。在这种算法中，把属于 w_1 类的样本点看作正电荷，而属于 w_2 类的样本点看作负电荷，从而把模式的分类转变为正、负电荷的转移的问题，电位为0的等位线（面）就是判别界线。

4、简答题：

(3) 势函数法的特点是什么？简要描述势函数的选择需要满足哪些条件。


势函数的选择

令 $K(x, x_k)$ 表示 x 与 x_k 之间的电位势函数，则 $K(x, x_k)$ 的选择应满足以下三个条件：

- ① $K(x, x_k) = K(x_k, x)$ ，当 $x = x_k$ 时， $K(x, x_k)$ 达到最大值；
- ② 当矢量 x 与 x_k 之间的距离趋于无穷大时， $K(x, x_k) = 0$ ；
- ③ $K(x, x_k)$ 是光滑函数，且是 x 与 x_k 之间距离的单调下降函数。

所有样本点 x_k ($k = 1, 2, \dots$) 的电位势函数 $K(x, x_k)$ 在任一点 x 产生的电位总和被称为积累电位势函数，表示为 $K(x)$ 。如果 $K(x)$ 能够把样本正确分类，可取为判决函数 $g(x)$ ，即： $g(x) = K(x)$ 。

例. 设一个两类训练样本: $w_1 = \{(0,0)^T, (2,0)^T\}$, $w_2 = \{(1,1)^T, (1,-1)^T\}$ 样本分布如下图所示:



解: 如样本分布图所示, 这两类样本是非线性可分的。因为特征向量是二维的, 势函数为: $K(x, x_k) = \exp\{[(x_1 - x_{k_1})^2 + (x_2 - x_{k_2})^2]\}$, 取 $\alpha = 1$,

$$K_0(x) = 0, \quad k = 0。$$

第一步: 输入 $x_1 = (0,0)^T$, $x_1 \in w_1$, $K_1(x) = K(x, x_1) = \exp[-(x_1^2 + x_2^2)]$

第二步: 输入 $x_2 = (2,0)^T$, $x_2 \in w_1$, $K_1(x_2) = e^{-4} > 0$ 分类正确, 不修正

$$K_2(x) = K_1(x) = \exp[-(x_1^2 + x_2^2)]$$

第三步：输入 $x_3 = (1, 1)^T$ ， $x_3 \in w_2$ ， $K_1(x_3) = e^{-2} \triangleleft 0$ ，分类错，修正

$$K_3(x) = K_2(x) - K(x, x_3) = \exp[-(x_1^2 + x_2^2)] - \exp\{-(x_1 - 1)^2 + (x_2 - 1)^2\}$$

第四步：输入 $x_4 = (1, -1)^T$ ， $x_4 \in w_2$ ， $K_3(x_4) = e^{-2} - e^{-4} \triangleleft 0$ ，分类错，修正

$$K_4(x) = K_3(x) - K(x, x_4)$$

$$= \exp[-(x_1^2 + x_2^2)] - \exp\{-(x_1 - 1)^2 + (x_2 - 1)^2\} - \exp\{-(x_1 - 1)^2 + (x_2 + 1)^2\}$$

第五步：再次输入 $x_1 = (0, 0)^T$ ， $x_1 \in w_1$ ， $K_4(x_1) = e^0 - e^{-2} - e^{-2} > 0$ ，不修正

$$K_5(x) = K_4(x)$$

第六步：再次输入 $x_2 = (2, 0)^T$ ， $x_2 \in w_1$ ， $K_5(x_2) = e^{-4} - 2e^{-2} \triangleright 0$ ，修正

$$K_6(x) = K_5(x) + K(x, x_2)$$

$$= \exp[-(x_1^2 + x_2^2)] - \exp\{-(x_1 - 1)^2 + (x_2 - 1)^2\} - \exp\{-(x_1 - 1)^2 + (x_2 + 1)^2\} \\ + \exp\{[(x_1 - 2)^2 + x_2^2]\}$$

第七步：再次输入 $x_3 = (1, 1)^T$ ， $x_3 \in w_2$ ， $K_6(x_3) = 2e^{-2} - 1 - e^{-4} < 0$ ，不修正

$$K_7(x) = K_6(x)$$

第八步：再次输入 $x_4 = (1, -1)^T$ ， $x_4 \in w_2$ ， $K_7(x_4) = e^{-2} - e^{-2} - 1 + e^{-4} < 0$ ，不修正

$$K_8(x) = K_7(x)$$

第九步：重新输入 $x_1 = (0, 0)^T$ ， $x_1 \in w_1$ ， $K_8(x_1) = e^0 - e^{-2} - e^{-2} + e^{-4} > 0$ ，不修正

正： $K_9(x) = K_8(x)$ 。

第十步：重新输入 $x_2 = (2, 0)^T$ ， $x_2 \in w_1$ ， $K_9(x_2) = e^{-4} - e^{-2} - e^{-2} + e^0 > 0$ ，不修正

正： $K_{10}(x) = K_9(x)$ 。

至此，所有训练样本皆被正确分类，分类器设计完毕。

判决函数：

$$g(x) = K_{10}(x)$$

$$= \exp[-(x_1^2 + x_2^2)] - \exp\{-(x_1 - 1)^2 + (x_2 - 1)^2\} - \exp\{-(x_1 - 1)^2 + (x_2 + 1)^2\} \\ + \exp\{[(x_1 - 2)^2 + x_2^2]\}$$

势函数迭代公式，具有很强的分类能力，但修正次数增多，势函数方程的项数将会增加，从而使计算机的计算量大增。

小结

本章介绍了“确定性模式”分类器的几种分类训练方法，同时还介绍了广义线性判别函数。其中：线性判别函数方法都是求解向量 w^* 包含下列四种方法：

- ① 感知器算法：是梯度下降法的特例，固定增量法。
- ② 梯度下降。
- ③ H-K算法：最小均方误差算法，LMSE算法。
- ④ Fisher：不用迭代运算，但要求 $\bar{S}_w$ 类内总离散度矩阵。

非线性判别函数包含下列三种方法：

- ① 分段线性判别函数。
- ② 二次判别函数
- ③ 用势函数法直接求 $g(x)$ 。