

2025学年秋季学期

《人工智能导论A》第三次习题课

任课教师：於俊

助教：刘凌峰

11/28/2025 10:40:29 PM

概念可视化

1、准备采用两套系统做患病辅助诊断（判断是否患病），假设共有 100 名受测者，其中 80 名是正常人，20 名是某病患者。

系统 1 检测结果：检出 82 正常人，其中 78 名为正常人，4 名为患者

系统 2 检测结果：检出 88 正常人，其中 80 名正常人，8 名患者

以正常人为正类：


(1) 计算：系统 1 的查准率，查全率，F1；

查准率 (precision)、查全率 (recall)、F1

对于二分类问题，可将样例根据其真实类别与学习器预测类别的组合划分为真正例(true positive)、假正例(false positive)、真反例(true negative)、假反例(false negative)四种情形，令 TP 、 FP 、 TN 、 FN 分别表示其对应的样例数，则显然有 $TP + FP + TN + FN = \text{样例总数}$ 。分类结果的“混淆矩阵”(confusion matrix)如表 2.1 所示。

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)



1、准备采用两套系统做患病辅助诊断（判断是否患病），假设共有 100 名受测者，其中 80 名是正常人，20 名是某病患者。

系统 1 检测结果：检出 82 正常人，其中 78 名为正常人，4 名为患者

系统 2 检测结果：检出 88 正常人，其中 80 名正常人，8 名患者

以正常人为正类：

(1) 计算：系统 1 的查准率，查全率，F1；

(2) 计算：系统 2 的查准率，查全率，F1；

(3) 请讨论：这两个系统哪个更优秀？

查准率 (precision)、查全率 (recall)、F1

查准率 P 与查全率 R 分别定义为

F1 度量:

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

表 2.1 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

1、(1) 对于系统1:

TP=78 FN=2

FP=4 TN=16

查准率 $P=78/(78+4)=0.951$

查全率 $R=78/(78+2)=0.975$

F1=0.963

(2) 对于系统2:

TP=80 FN=0

FP=8 TN=12

查准率 $P=80/(80+8)=0.909$

查全率 $R=80/(80+0)=1$

F1=0.952

(3) 系统1更优秀，查准率高，将病人误判为正常人的概率小，F1更高等

2、在一组测试中，根据每个测试样本属于正样本的概率值从大到小排序，表中共有20个样本，“CLASS”表示样本真正的标签（P为正样本，N为负样本），SCORE表示每个样本属于正样本的概率。当测试样本的概率大于或等于阈值时我们认为他为正样本，否则为负样本。

性能度量 (performance measure)


► ROC 与 AUC

“受试者工作特征” (Receiver Operating Characteristic)


很多学习器是为测试样本产生一个实值或概率预测，然后将这个预测值与一个分类阈值(threshold)进行比较，若大于阈值则分为正类，否则为反类。

$$TPR = \frac{TP}{TP + FN},$$

$$FPR = \frac{FP}{TN + FP}.$$



(a) ROC 曲线与 AUC



(b) 基于有限样例绘制的 ROC 曲线与 AUC

► AUC:

► ROC曲线下面积

$$AUC = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \cdot (y_i + y_{i+1})$$

2.4 ROC 曲线与 AUC 示意图

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

2、在一组测试中，根据每个测试样本属于正样本的概率值从大到小排序，表中共有20个样本，“CLASS”表示样本真正的标签（P为正样本，N为负样本），SCORE表示每个样本属于正样本的概率。当测试样本的概率大于或等于阈值时我们认为他为正样本，否则为负样本。

(1) 当选取阈值为 0.7 时，列出混淆矩阵，计算此时对应ROC曲线的点的坐标；

(2) 当选取阈值为 0.55 时，列出混淆矩阵，计算此时对应ROC曲线的点的坐标。

Inst#	Class	Score
1	p	.9
2	p	.8
3	n	.7
4	p	.6
5	p	.55
6	p	.54
7	n	.53
8	n	.52
9	p	.51
10	n	.505

2、（1）当阈值为0.7时

TP=2 FN=4

FP=1 TN=3

$FPR = FP / (TN + FP) = 1/4 = 0.25$

$TPR = TP / (TP + FN) = 2/6 = 0.33$

坐标 (0.25, 0.33) 或 (1/4, 1/3)

2、在一组测试中，根据每个测试样本属于正样本的概率值从大到小排序，表中共有20个样本，“CLASS”表示样本真正的标签（P为正样本，N为负样本），SCORE表示每个样本属于正样本的概率。当测试样本的概率大于或等于阈值时我们认为他为正样本，否则为负样本。

(1) 当选取阈值为 0.7 时，列出混淆矩阵，计算此时对应ROC曲线的点的坐标；

(2) 当选取阈值为 0.55 时，列出混淆矩阵，计算此时对应ROC曲线的点的坐标。

Inst#	Class	Score
1	p	.9
2	p	.8
3	n	.7
4	p	.6
5	p	.55
6	p	.54
7	n	.53
8	n	.52
9	p	.51
10	n	.505

(2) 当阈值为0.55时

TP=4 FN=2

FP=1 TN=3

$FPR = FP / (TN + FP) = 1/4 = 0.25$

$TPR = TP / (TP + FN) = 4/6 = 0.67$

坐标 (0.25, 0.67) 或 (1/4, 2/3)

3、(1) Logistic 回归是在回归模型中引入 Sigmoid 函数的一种非线性回归模型，对于一个二分类问题，定义线性函数 $z = \omega^T \mathbf{x} + b$ ($\mathbf{x}$ 为输入数据， ω 和 b 为模型的参数)，设输出为 y ，写出 Logistic 回归模型的表达式；

(2) 在该二分类问题中，如何理解 y 对应的实际含义；

(3) 简要绘制 Sigmoid 函数的示意图，并简述它的数学性质具有哪些主要优势。


$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

$y = \frac{1}{1 + e^{-(w^T x + b)}}$ 可用来计算输入数据 $\mathbf{x}$ 属于正例概率，这里 y 理解

为输入数据 $\mathbf{x}$ 为正例的概率、 $1-y$ 理解为输入数据 $\mathbf{x}$ 为负例的概率，即

$P(y=1|\mathbf{x})$ 。 $\frac{P}{1-P}$ 被称为几率 (odds)，反映了输入数据 $\mathbf{x}$ 作为正例的相

对可能性。 $\frac{P}{1-P}$ 的对数几率 (log odds) 或 logit 函数可表示为 $\log\left(\frac{P}{1-P}\right)$ 。



- 3、（1）Logistic 回归是在回归模型中引入 Sigmoid 函数的一种非线性回归模型，对于一个二分类问题，定义线性函数 $z = \omega^T \mathbf{x} + b$ （ $\mathbf{x}$ 为输入数据， ω 和 b 为模型的参数），设输出为 y ，写出 Logistic 回归模型的表达式；
- （2）在该二分类问题中，如何理解 y 对应的实际含义；
- （3）简要绘制 Sigmoid 函数的示意图，并简述它的数学性质具有哪些主要优势。

它是一种“Sigmoid”函数，Sigmoid 函数这个名词是表示形式S形的函数，对数几率函数就是其中最重要的代表。这个函数相比前面的分段函数，具有非常好的数学性质，其主要优势如下：

- 使用该函数做分类问题时，不仅可以预测出类别，还能够得到近似概率预测。这点对很多需要利用概率辅助决策的任务很有用。
- 对数几率函数是任意阶可导函数，它有着很好的数学性质，很多数值优化算法都可以直接用于求取最优解。

1. 什么是决策树 (Decision Tree)?

想象你在玩“20个问题”游戏 (Twenty Questions)。你的目标是通过一系列“是/否”的问题，猜出对方心里想的东西。

- “它是活的吗？” -> 是。
- “它是陆地动物吗？” -> 是。
- “它吃肉吗？” -> 否。
- **结论：** 可能是兔子。

决策树就是这样一个树状的流程图结构。它的核心逻辑是：**通过不断地根据特征 (Feature) 对数据进行“切分”，直到将数据分得足够“纯净”为止。**

核心结构

- **根节点 (Root Node)：** 包含所有数据的初始状态。
- **内部节点 (Internal Node)：** 进行判断和决策的地方（例如：“天气是晴天吗？”）。
- **叶节点 (Leaf Node)：** 最终的决策结果或分类标签（例如：“去打球”或“不去”）。

2. ID3 算法：寻找“信息量”最大的特征

ID3 (Iterative Dichotomiser 3) 是非常早期的决策树算法。它的核心思想是***“信息熵” (Entropy)** 和 “信息增益” (Information Gain)。

核心概念：熵 (Entropy)

在物理学中，熵代表混乱程度。在信息论中，熵代表**不确定性**。

- 如果一个集合里只有“红球”，没有任何杂质，**熵为 0**（确定性最高）。
- 如果一个集合里红球、蓝球各占 50%，**熵最大**（不确定性最高）。

ID3 的目标是：**每次切分后，让数据的混乱程度（熵）下降得最快。**

数学公式

假设数据集 D 中有 K 个类别，第 k 类样本所占的比例为 p_k ，则 D 的信息熵定义为：

$$H(D) = - \sum_{k=1}^K p_k \log_2 p_k$$

ID3 的运行步骤

- 计算总熵：**算出当前数据集 D 的总熵 $H(D)$ 。
- 尝试切分：**假设我们选择特征 A 来切分数据。特征 A 有 v 个可能的取值（例如“天气”有晴、阴、雨 3 种），这会将数据分成 v 个子集 $D_1, D_2, ..., D_v$ 。

- 计算条件熵：**计算切分后，所有子集的加权平均熵。

$$H(D|A) = \sum_v \frac{|D_v|}{|D|} H(D_v)$$

- 计算信息增益 (Information Gain)：**

$$Gain(D, A) = H(D) - H(D|A)$$

即：**切分前的混乱度 - 切分后的混乱度 = 信息的增加量。**

- 选择特征：**遍历所有特征，选择**信息增益最大**的那个特征作为当前的划分节点。
- 递归：**对切分后的子集重复上述步骤，直到所有子集都很“纯”或者没有特征可用。

ID3 的缺点：它特别喜欢选择那些**取值很多**的特征（例如“身份证号”或“日期”），因为切分得越细，子集越纯，熵降得越快，但这会导致严重的过拟合（Overfitting），且泛化能力差。

4、下表是一个由 15 个样本组成的贷款申请训练数据。数据包括贷款申请人的 4 个特征（属性）：第 1 个特征是年龄，有 3 个可能值：青年，中年，老年；第 2 个特征是有工作，有 2 个可能值：是，否；第 3 个特征是有自己的房子，有 2 个可能值：是，否；第 4 个特征是信贷情况，有 3 个可能值：非常好，好，一般。表的最后一列是类别，是否同意贷款，取 2 个值：是，否。

(1) 根据表中所给的训练数据集，应用ID3算法搭建决策树；

年龄的信息增益(其中 D_1, D_2, D_3 表示青年,中年,老年)

$$\begin{aligned} g(D, A_1) &= H(D) - \left[\frac{5}{15} H(D_1) + \frac{5}{15} H(D_2) + \frac{5}{15} H(D_3) \right] \\ &= 0.971 - \left[\frac{5}{15} \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{5}{15} \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) + \frac{5}{15} \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) \right] \\ &= 0.971 - 0.888 = 0.083 \end{aligned}$$

同理可以计算其他三种特征的信息增益如下

有无工作的信息增益

$$\begin{aligned} g(D, A_2) &= H(D) - \left[\frac{5}{15} H(D_1) + \frac{10}{15} H(D_2) \right] \\ &= 0.971 - \left[\frac{5}{15} \times 0 + \frac{10}{15} \left(-\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10} \right) \right] \\ &= 0.971 - 0.647 = 0.324 \end{aligned}$$

有无房子的信息增益

$$\begin{aligned} g(D, A_3) &= H(D) - \left[\frac{6}{15} H(D_1) + \frac{9}{15} H(D_2) \right] \\ &= 0.971 - \left[\frac{6}{15} \times 0 + \frac{9}{15} \left(-\frac{3}{9} \log_2 \frac{3}{9} - \frac{6}{9} \log_2 \frac{6}{9} \right) \right] \\ &= 0.971 - 0.551 = 0.420 \end{aligned}$$

信贷情况的信息增益


$$g(D, A_4) = 0.971 - 0.608 = 0.363$$

继续选择子节点特征，计算可得：↵

$$g(D_2, A_1) = 0.251 \leftarrow$$

$$g(D_2, A_2) = 0.918 \leftarrow$$

$$g(D_2, A_4) = 0.474 \leftarrow$$



3. CART 算法：更实用的二叉树

CART (Classification and Regression Trees) 是目前应用最广泛的决策树算法。与 ID3 不同，CART **严格生成二叉树** (每次只分两叉：是/否)，并且既能做分类 (Classification)，也能做回归 (Regression)。

CART 分类树：基尼系数 (Gini Impurity)

CART 不使用复杂的对数运算 (熵)，而是使用**基尼系数**来衡量“不纯度”。

- 基尼系数越小，纯度越高。
- 基尼系数为 0，表示所有样本属于同一类。

数学公式

对于数据集 D ，假设有 K 个类别，第 k 类概率为 p_k ，则基尼系数为：

$$Gini(D) = 1 - \sum_{k=1}^K p_k^2$$

CART 分类树运行步骤

1. **遍历特征**：甚至对于连续型特征 (如年龄)，它也会尝试所有可能的切分点 (例如：是否 < 25 岁？是否 < 35岁？)。
2. **计算切分后的基尼指数**：假设特征 A 将数据切分为 D_1 (Yes) 和 D_2 (No) 两部分：

$$Gini(D, A) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

3. **选择最优切分**：寻找让 $Gini(D, A)$ **最小** 的特征和切分点。
4. **递归构建**：不断生成二叉树，直到满足停止条件。

4、下表是一个由 15 个样本组成的贷款申请训练数据。数据包括贷款申请人的 4 个特征（属性）：第 1 个特征是年龄，有 3 个可能值：青年，中年，老年；第 2 个特征是有工作，有 2 个可能值：是，否；第 3 个特征是有自己的房子，有 2 个可能值：是，否；第 4 个特征是信贷情况，有 3 个可能值：非常好，好，一般。表的最后一列是类别，是否同意贷款，取 2 个值：是，否。

(2) 根据表中所给的训练数据集，应用CART算法搭建决策树。

最佳划分属性选择：基尼值

$$Gini = 1 - \sum_{i=1}^n p_i^2$$

其中 P_i 表示类 i 的数量占比。其同样以上述熵的二分类例子为例，当两类数量相等时，基尼值等于0.5；当节点数据属于同一类时，基尼值等于0。基尼值越大，数据越不纯。

基尼指数 (gini index): CART 中使用

$$Gini_index(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} Gini(D^v).$$

分别以 A_1 ， A_2 ， A_3 ， A_4 表示年龄、有工作、有自己的房子和信贷情况 4 个特征，并以 1，2，3 表示年龄的值为青年、中年和老年，以 1，2 表示有工作和有自己的房子的值为是和否，以 1，2，3 表示信贷情况的值为非常好、好和一般。

求特征 A_1 的基尼指数：

$$Gini(D, A_1 = 1) = \frac{5}{15} \left(2 * \frac{2}{5} * \left(1 - \frac{2}{5} \right) \right) + \frac{10}{15} \left(2 * \frac{7}{10} * \left(1 - \frac{7}{10} \right) \right) = 0.44$$

$$Gini(D, A_1 = 2) = 0.48$$

$$Gini(D, A_1 = 3) = 0.44$$

$A_1 = 1$ 或 $A_1 = 3$ 可作为最优切分点

同理

$$Gini(D, A_2 = 1) = 0.32$$

$$Gini(D, A_3 = 1) = 0.27$$

$$Gini(D, A_4 = 1) = 0.36$$

$$Gini(D, A_4 = 2) = 0.47$$

$$Gini(D, A_4 = 3) = 0.32$$

$Gini(D, A_3 = 1) = 0.27$ 最小，所以选择其作为最优特征， $A_3 = 1$ 为最优切分点，继续划分，可达到与(1)相同的决策树。

算法 7.1 (线性可分支持向量机器学习算法——最大间隔法)

输入：线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，其中， $x_i \in \mathcal{X} = \mathbf{R}^n$ ， $y_i \in \mathcal{Y} = \{-1, +1\}$ ， $i = 1, 2, \dots, N$ ；

输出：最大间隔分离超平面和分类决策函数。

(1) 构造并求解约束最优化问题：

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_i(w \cdot x_i + b) - 1 \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

求得最优解 w^*, b^* 。

(2) 由此得到分离超平面：

$$w^* \cdot x + b^* = 0$$

分类决策函数

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

■

已知 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$, 负例点是 $x_3 = (1, 1)^T$, 试求最大间隔分离超平面.




图 7.4 间隔最大分离超平面示例

解 按照算法 7.1, 根据训练数据集构造约束最优化问题:

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2}(w_1^2 + w_2^2) \\ \text{s.t.} \quad & 3w_1 + 3w_2 + b \geq 1 \\ & 4w_1 + 3w_2 + b \geq 1 \\ & -w_1 - w_2 - b \geq 1 \end{aligned}$$

求得此最优化问题的解 $w_1 = w_2 = \frac{1}{2}$, $b = -2$. 于是最大间隔分离超平面为

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$

其中, $x_1 = (3, 3)^T$ 与 $x_3 = (1, 1)^T$ 为支持向量.

算法 7.2 (线性可分支持向量机学习算法)

输入: 线性可分训练集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 其中 $x_i \in \mathcal{X} = \mathbf{R}^n$, $y_i \in \mathcal{Y} = \{-1, +1\}$, $i = 1, 2, \dots, N$;

输出: 分离超平面和分类决策函数.

(1) 构造并求解约束最优化问题

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N$$

求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$.

(2) 计算

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

并选择 α^* 的一个正分量 $\alpha_j^* > 0$, 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

(3) 求得分离超平面

$$w^* \cdot x + b^* = 0$$


分类决策函数:

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

5、已知一个如下图所示的训练数据集，其正例点为 $x_1 = (4,2)^T$ ，负例点为 $x_2 = (1,1)^T$ ， $x_3 = (2,3)^T$ ，试求：

(1) 请通过转化为对偶问题的思路，求解约束最优问题；

(2) 求解分离超平面和分类决策函数。



(1) 对偶问题是：

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ & = \frac{1}{2} (20\alpha_1^2 + 2\alpha_2^2 + 13\alpha_3^2 - 12\alpha_1\alpha_2 - 28\alpha_1\alpha_3 + 10\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \end{aligned}$$

$$\text{s.t.} \quad \alpha_1 - \alpha_2 - \alpha_3 = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, 3$$

求解最优问题： $\alpha_1 = \alpha_2 + \alpha_3$ 代入目标函数

$$s(\alpha_2, \alpha_3) = 5\alpha_2^2 + 5\alpha_2\alpha_3 + \frac{5}{2}\alpha_3^2 - 2\alpha_2 - 2\alpha_3$$

对 α_2, α_3 求偏导数并令其为 0，在点 $(0, \frac{2}{5})^T$ 取极值，此时 $\alpha_1 = \frac{2}{5}$ ，最优解 $\alpha^* = (\frac{2}{5}, 0, \frac{2}{5})^T$

5、已知一个如下图所示的训练数据集，其正例点为 $x_1 = (4,2)^T$ ，负例点为 $x_2 = (1,1)^T$ ， $x_3 = (2,3)^T$ ，试求：

(1) 请通过转化为对偶问题的思路，求解约束最优问题；

(2) 求解分离超平面和分类决策函数。

(2) 此时 $\alpha_1^* = \alpha_3^* = \frac{2}{5}$ 对应的实例点 x_1, x_3 是支持向量，故

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i = \frac{2}{5} \times (4,2)^T - \frac{2}{5} \times (2,3)^T = \left(\frac{4}{5}, -\frac{2}{5}\right)$$

即 $w_1^* = \frac{4}{5}$ ， $w_3^* = -\frac{2}{5}$ ，对应

$$b^* = y_1 - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_1) = -\frac{7}{5}$$

由此得到分离超平面为

$$4x^{(1)} - 2x^{(2)} - 7 = 0$$

分离决策函数为

$$f(x) = \text{sign}(4x^{(1)} - 2x^{(2)} - 7)$$

例 7.2 训练数据与例 7.1 相同. 如图 7.4 所示, 正例点是 $x_1 = (3, 3)^T$, $x_2 = (4, 3)^T$, 负例点是 $x_3 = (1, 1)^T$, 试用算法 7.2 求线性可分支持向量机.

解 根据所给数据, 对偶问题是

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ & = \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, 3 \end{aligned}$$

解这一最优化问题. 将 $\alpha_3 = \alpha_1 + \alpha_2$ 代入目标函数并记为

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

对 α_1, α_2 求偏导数并令其为 0, 易知 $s(\alpha_1, \alpha_2)$ 在点 $\left(\frac{3}{2}, -1\right)^T$ 取极值, 但该点不满足约束条件 $\alpha_2 \geq 0$, 所以最小值应在边界上达到.

当 $\alpha_1 = 0$ 时, 最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$; 当 $\alpha_2 = 0$ 时, 最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$. 于是 $s(\alpha_1, \alpha_2)$ 在 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 达到最小, 此时 $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$.

这样, $\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例点 x_1, x_3 是支持向量. 根据式 (7.25) 和式 (7.26) 计算得

$$\begin{aligned} w_1^* &= w_2^* = \frac{1}{2} \\ b^* &= -2 \end{aligned}$$

分离超平面为

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$

分类决策函数为

$$f(x) = \text{sign}\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2\right) \quad \blacksquare$$

当 $\alpha_1 = 0$ 时, 最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$; 当 $\alpha_2 = 0$ 时, 最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$. 于是 $s(\alpha_1, \alpha_2)$ 在 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 达到最小, 此时 $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$.

这样, $\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例点 x_1, x_3 是支持向量. 根据式 (7.25) 和式 (7.26) 计算得

$$\begin{aligned} w_1^* &= w_2^* = \frac{1}{2} \\ b^* &= -2 \end{aligned}$$

分离超平面为

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$