

人工智能导论填空题知识点提取

第三章 知识与知识表示方式

1. 人工智能技术的三个发展阶段分别是（计算智能）、（感知智能）、（认知智能），其中（认知智能）是最高阶段，目标是让机器掌握人类的语言 and 知识体系，并真正理解其内在逻辑。
2. Feigenbaum 认为知识是经过（消减）、（塑造）、（解释）和（转换）的信息。
3. 信息是物质的性质、物质之间的一种相互作用，数据是信息的（表示）和（载体），信息是内容、实质，数据是信息的一种表示。
4. 知识是有关联的信息的（信息结构），在 AI 系统中，（事实）、（规则）和（策略）都为知识。
5. 知识的特性包括（相对正确性）、（不确定性）、（不完全性）、（经验性）。
6. 按范围划分，知识可分为（常识性知识）和（领域性知识）。
7. 按作用和表示划分，知识可分为（事实性知识）、（过程性知识）、（控制性知识），其中事实性知识的形式常为“…是…”，过程性知识的形式常为“如果…那么…”。
8. 知识的要素包括（事实）、（规则）、（控制）、（元知识），其中（事实）是最低层的知识。
9. 知识表示是研究用机器表示知识的（可行性）、（有效性）的一般方法，是一种数据结构与控制结构的统一体。
10. 选取知识表示的因素包括表示范围是否广泛、是否适于推理、是否适于计算机处理、是否有高效的算法、能否表示不精确知识、能否模块化等。
11. 知识表示方法可分为（直接表示法）和（替代表示法），替代表示法又可分为（局部表示类）和（分布表示法）。
12. 直接表示法由 Gelernter 于 1963 年提出，用于基于传统欧氏几何证明的（几何定理证明器）。
13. 一阶谓词逻辑表示法中，事实性知识简单的采用（原子谓词公式）表示，复杂的采用谓词公式的（与或形）表示；过程性知识常用（蕴涵式）表示。
14. 谓词逻辑规范表达式为 $P(x_1, x_2, x_3, \dots)$ ，其中 P 是谓词， x_i 是主体与客体。
15. 产生式表示法中，事实一般使用三元组（对象，属性，值）或（关系，对象 1，对象 2）表示，规则以“if condition then action”的单一形式表示。
16. 产生式系统由（规则库）、（综合数据库）和（控制系统）三个基本部分组成。
17. 产生式系统的控制流程是（识别--行动循环）。
18. 冲突解决的策略可分为（First）、（Best）、（All）三大类。
19. 语义网络是一种用（实体及其语义关系）来表达知识的有向图，结点代表（实体），弧代表（语义关系）。
20. 语义基元可用三元组（结点 1，弧，结点 2）表示。
21. 语义网络中常用的语义关系包括分类关系、聚类关系、属性关系、推论关系、时间位置关系、合取析取关系等，其中分类关系的标注常为（is a）或（is kind of），聚类关系的标注常为（part of）或（a member of）。
22. 语义网络中的推理主要包括（继承）和（匹配）两种。
23. 框架是由若干个结点和关系（统称为槽）构成的网络，是语义网络的一般化形式的一种结构，其表示形式由（框架名）、（槽名）、（侧面）、（值）组成。
24. 框架的侧面主要有（值侧面）、（如果需要侧面）、（默认侧面）。
25. 框架网络的关系包括（纵向关系）和（横向关系），纵向关系是抽象-具体框架之间的关系，横向关系表现为某一个槽值为另外一个框架的名字。

26. 脚本表示法是框架知识表示法的一种特例, 可用来描述特殊范围内的事件发生的 (序列), 其结构包括进入条件、角色、道具、场景、结局。
27. 过程表示法将有关某一问题领域的知识连同如何使用这些知识的方法均 (隐式地表达为一个求解过程)。

第四章 经典逻辑推理

1. 数理逻辑的内容包括逻辑演算、证明论、公理集合论、递归论、模型论, 其中逻辑演算包括 (命题逻辑) 和 (谓词逻辑)。
2. 命题是能够判断真假的 (陈述句), 其真值包括真 (1, T) 和假 (0, F)。
3. 不能够再分解的命题称为 (原子命题), 由简单命题用联结词联结而成的命题称为 (复合命题)。
4. 常用的逻辑联结词包括否定 ($\neg$)、合取 ($\wedge$)、析取 ($\vee$)、蕴涵 ($\rightarrow$)、等价 ($\leftrightarrow$)。
5. 蕴涵联结词 $\rightarrow$ 为假当且仅当 (p 为真, q 为假)。
6. 逻辑联结词的优先级从高到低依次为 ($\neg$)、($\wedge$)、($\vee$)、($\rightarrow$)、($\leftrightarrow$)。
7. 单个命题常项或变项、0、1 是 (0 层) 公式。
8. 设 A 为一个命题公式, 若 A 在它的各种赋值下取值均为真, 则称 A 为 (重言式) 或永真式; 若均为假, 则称 A 为 (矛盾式) 或永假式; 若至少存在一组赋值是成真赋值, 则称 A 为 (可满足式)。
9. 设 A, B 为 2 个命题公式, 若等价式 $A \leftrightarrow B$ 是重言式, 则称 A 与 B 是 (等值的), 记做 $A \leftrightarrow B$ 。
10. 命题逻辑中的归结推理, 要证明定理 $A_1 \wedge A_2 \wedge \dots \wedge A_n \Rightarrow B$ 成立, 需证明 $A_1 \wedge A_2 \wedge \dots \wedge A_n \wedge \neg B$ (永假)。
11. 归结式 $R(C_1, C_2)$ 为 2 个子句 C_1, C_2 的 (逻辑结论)。
12. 空子句没有任何解释可以满足它, 意味着 (矛盾) 和 (不可满足)。
13. 一阶谓词逻辑中, 简单命题可分解为 (个体词)、(谓词) 和 (量词)。
14. 个体常项表示具体或特定的词, 用 (小写英文字母 $a, b, c, \dots$) 表示; 个体变项泛指个体, 用 (小写英文字母 $x, y, z, \dots$) 表示。
15. 量词包括 (全称量词) 和 (存在量词), 全称量词对应日常语言中的“一切”“任意的”“所有的”, 表示为 ($\forall$); 存在量词对应“存在着”“有一个”“至少一个”, 表示为 ($\exists$)。
16. 谓词的元数是指谓词中包含的 (个体词的个数), 包含 n 个个体词的谓词称为 n 元谓词。
17. 在合式公式 $\forall x A$ 和 $\exists x A$ 中, x 称为 (指导变项), A 称为相应量词的 (辖域)。
18. 若 A 中无自由出现的个体变项, 则称 A 是 (封闭的合式公式), 简称闭式。
19. 为避免变项既是自由出现又是约束出现, 可采用 (换名规则) 和 (代替规则)。
20. 一阶逻辑等值式中, 量词否定等值式为 $\neg \forall x A(x) \Leftrightarrow (\exists x \neg A(x))$ 和 $\neg \exists x A(x) \Leftrightarrow (\forall x \neg A(x))$ 。
21. 前束范式是指量词非否定地放在全式的开头, 而量词的辖域都延伸到整个谓词公式, 其形式为 $Q_1 x_1 \dots Q_n x_n M(x_1, \dots, x_n)$, 其中 Q_i 是 $\forall x_i$ 或 $\exists x_i$, M 称为 (母式)。
22. 斯柯林标准型是谓词逻辑中公式的另一种标准形式, 通过将母式化为等值的合取范式, 然后 (消去所有的存在量词) 得到。
23. 子句集 S 是公式 G 的子句集, 公式 G 是不可满足的当且仅当 (S 是不可满足的)。
24. 鲁滨逊归结原理的本质思想是检查子句集 S 是否包含 (空子句), 如果 S 包含, 则 S 是不可满足的。

25. 置换是形为 $\{t_1/a_1, t_2/a_2, \dots, t_n/a_n\}$ 的有限集，其中 a_i 为相互不同的变元， t_i 为与 a_i 不同的项。
26. 合一指设有公式集 $\{F_1, F_2, \dots, F_n\}$ ，如果存在一个置换 θ ，使得 $F_1 \cdot \theta \Leftrightarrow F_2 \cdot \theta \Leftrightarrow \dots \Leftrightarrow F_n \cdot \theta$ ，则 θ 为公式集的（合一）。
27. 最一般合一是指对于公式集 F 有一个合一 σ ，且对 F 的任何一个合一 θ ，都有置换 λ 存在，使得 $\theta = (\sigma \cdot \lambda)$ 。
28. 谓词逻辑中的归结过程包括使用置换方式找到（互补的文字对）和消去互补的文字对，余下的经过置换的文字的析取构成归结式。
29. 归结策略包括广度优先策略、支持集策略、单元子句策略、线性输入策略、祖先过滤策略、删除策略等，其中（广度优先策略）和（支持集策略）是完备的。
30. 支持集策略要求在每一次归结中，其亲本子句中至少有一个与（目标公式的否定）有关。
31. 单元子句策略要求在做归结的 2 个子句中，至少一个是（单元子句）。
32. 删除策略包括纯文字删除法、重言式删除法、包孕删除法。

第五章 非精确性推理

1. 做不精确推理的原因包括推理所需信息不完备、背景知识不足、多种原因导致同一结果、信息描述模糊、信息中含有噪声、规则是模糊的、推理能力不足、解决方案不唯一等。
2. 常用的非精确性推理技术包括确定性理论、证据理论、（主观贝叶斯方法）、模糊理论。
3. 非精确性推理中的特殊问题包括非精确性的表示和度量、非精确性的传递和推算、条件部分的非精确性确定、非精确性的匹配算法及阈值选择。
4. 非精确性的表示方法应与（推理方式）相关、相适应。
5. 主观贝叶斯方法中，推理规则表示为 if E then H (LS, LN)，其中 LS 表示 E 为真对 H 的支持程度，称为（充分性度量）； LN 表示 E 为假对 H 的支持程度，称为（必要性度量）。
6. 几率 $O(H)$ 的定义为 $P(H)/(1-P(H))$ ，取值范围为 $[0, \infty)$ 。
7. 后验几率和先验几率的关系为 $O(H | E) = (LS * O(H))$ 、 $O(H | \neg E) = (LN * O(H))$ 。
8. LS 和 LN 都是非负的，且满足 $LS > 1$ 时 $LN < 1$ ， $LS < 1$ 时 $LN > 1$ ， $LS = 1$ 时 $LN = 1$ 。
9. 可信度方法中，知识用产生式规则表示为 IF E THEN H ($CF(H, E)$)，其中 $CF(H, E)$ 是知识的可信度，取值范围为 $[-1, 1]$ 。
10. $CF(H, E) = (MB(H, E) - MD(H, E))$ ，其中 MB 是信任增长度， MD 是不信任增长度。
11. 可信度的互斥性指当 $MB(H, E) > 0$ 时， $MD(H, E) = 0$ ；当 $MD(H, E) > 0$ 时， $MB(H, E) = 0$ 。
12. 证据的不确定性也用可信度表示，取值范围为 $[-1, 1]$ ，否定证据的可信度计算为 $CF(\neg E) = (-CF(E))$ 。
13. 组合证据为合取时， $CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$ ；组合证据为析取时， $CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$ 。
14. 不确定性更新公式为 $CF(H) = (CF(H, E) \times \max\{0, CF(E)\})$ 。

第六章 统计学习方法

1. 机器学习是从数据中自动分析获得规律，并利用规律对未知数据进行（预测）的算法，目前机器学习=“分类”+“预测”。
2. 人工智能的三个研究阶段分别是推理期、知识期、（机器学习期）。
3. 机器学习的三要素包括（模型）、（学习准则）、（优化/学习方法）。
4. 监督学习的训练样本集合为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，其学习目标是找到映射函数 f ，使

得 $f(x)$ 尽可能接近 y 。

5. 无监督学习的训练样本集合为 $\{x_1, x_2, \dots, x_n\}$ ，其学习目标是发现数据中的潜在规律或结构。
6. 强化学习是智能体和环境交互，通过获得的轨迹和累积奖励 G ，学习最优策略以最大化（期望总回报）。
7. 经验风险是模型关于训练样本集的平均损失，期望风险是模型关于（联合分布）的期望损失。
8. 结构风险最小化是为了防止过拟合，在经验风险上加上表示（模型复杂度）的正则化项或惩罚项。
9. 常用的损失函数包括均方损失、绝对值损失、二值损失等，其中均方损失常用于（回归问题），二值损失常用于（分类问题）。
10. 梯度下降法的搜索步长 α 也叫作（学习率）。
11. 随机梯度下降法每个样本都进行更新，小批量随机梯度下降法的 K 通常设置为（2 的 n 次方）。
12. 过拟合是指模型在训练集上错误率很低，但在未知数据上错误率很高，往往由训练数据少和噪声等原因造成；欠拟合是指模型学习能力不足，在训练集和测试集上表现都不好。
13. 应对过拟合的方法包括增大训练数据、正则化、减小模型参数、提前停止、交叉验证、Dropout 等；应对欠拟合的方法包括增加模型复杂度、增大参数数量、减小正则化参数等。
14. 正则化是所有损害优化的方法，包括增加优化约束、干扰优化过程等，常见的正则化方法有 $L1/L2$ 约束、数据增强、权重衰减等。
15. 模型评估的方法包括留出法、交叉验证法、自助法等。
16. 留出法直接将数据集 D 划分为训练集 S 和测试集 T ，划分时应采用（分层采样）保持数据分布的一致性。
17. 交叉验证法中，特例留一法（LOO）当 m 比较大时，计算开销（较大）。
18. 自助法通过有放回的抽样得到训练集 D' ， $D \setminus D'$ 作为测试集，样本在 m 次采样中始终不被采到的概率约等于（0.368）。
19. 回归任务最常用的性能度量是（均方误差），分类任务的性能度量包括错误率、精度、查准率、查全率、 $F1$ 、ROC、AUC 等。
20. 查准率 $P = TP / (TP + FP)$ ，查全率 $R = (TP / (TP + FN))$ ， $F1$ 度量 $= 2 \times P \times R / (P + R)$ 。
21. ROC 曲线以（假正例率）为横轴，（真正例率）为纵轴，AUC 是 ROC 曲线下的面积。
22. 线性回归的模型为 $f(x; w, b) = (w^T x + b)$ ，其代价函数常用均方误差。
23. 逻辑回归的模型是一个非线性模型，使用（sigmoid 函数）将线性模型的输出映射到 $[0, 1]$ 区间，本质上是一个线性回归模型。
24. 逻辑回归的损失函数常用（对数损失函数）。
25. 决策树基于“树”结构进行决策，学习过程是确定（划分属性），预测过程是将测试示例从根结点沿划分属性构成的“判定测试序列”下行至叶结点。
26. 决策树分裂属性的选择依据包括信息增益、信息增益率、基尼系数等，ID3 中使用（信息增益），C4.5 中使用（信息增益率），CART 中使用（基尼系数）。
27. 熵描述了数据的混乱程度，熵越大，混乱程度越高，纯度越（低）；基尼系数越大，数据越（不纯）。
28. 决策树的剪枝是对付过拟合的主要手段，包括（预剪枝）和（后剪枝）。
29. 集成学习通过构建并结合多个机器学习器来完成学习任务，其个体学习器可分为同质和异质，同质个体学习器按依赖关系可分为串行生成的（Boosting）和并行生成的（Bagging）。
30. Boosting 的代表算法包括 AdaBoost、GBDT 等，Bagging 的代表算法是（随机森林）。
31. 集成学习的组合策略包括平均法、投票法、（学习法）。

32. AdaBoost 算法中，每个训练样本的权重初始化为 $(1/N)$ ， N 为样本个数。
33. AdaBoost 算法通过（提高在上一轮中分类错误样本的权重）来改变训练数据的权重，通过（加权多数表决）将弱分类器组合成强分类器。

第七章 深度学习

1. 学习的核心动机是（自动学习特征），避免人工设计特征的耗时费力，其本质是通过构建（多隐层的模型）和海量训练数据，学习更有用的特征以提升分类或预测准确性。
2. 深度学习与浅层学习的区别在于强调（模型结构的深度）（通常 5-10 多层隐层节点）和（特征学习的重要性）。
3. 神经元的数学模型包括对输入信息的（加权累加）和通过（激活函数）进行的非线性变换，输出为 $(Out = g(In))$ ，其中 $(In = \sum_{i=1}^n w_i * a_i)$ 。
4. 常用的激活函数有 Sigmoid、Tanh、ReLU 等，其中 ReLU 函数的表达式为 $(f(x) = \max(0, x))$ ，其导数在 $(x \geq 0)$ 时为 (1) ， $(x < 0)$ 时为 (0) 。
5. 前馈神经网络的特点是各神经元接受前一级输入并输出到下一级，层间（全连接），层内神经元（不相互连接），感知机网络是无（隐藏层）的特殊前馈神经网络。
6. 前馈神经网络的参数优化常用（梯度下降）算法，核心是沿着损失函数梯度的（反方向）更新参数，学习率 η 控制更新步长。
7. 误差反向传播（BP）算法通过（链式求导）将输出层误差反向传递给隐藏层，分摊误差并修正各层参数，参数更新公式为 $(w_1^{new} = w_1 - \eta \times \frac{\partial L}{\partial w_1})$ 。
8. 卷积神经网络（CNN）的核心特性是（局部连接）和（权重共享），可有效减少权重参数，避免过拟合。
9. CNN 的基本组成单元包括（卷积层）、（激活层）、（池化层）和（全连接层），典型结构为“输入-卷积-ReLU-汇聚-全连接-softmax”。
10. 卷积层通过（卷积核/滤波器）提取特征，输出为（特征映射），其输出大小计算公式为 $(O = \frac{I - F + 2P}{S} + 1)$ （ I 为输入大小， F 为卷积核大小， P 为零填充， S 为步长）。
11. 池化层（降采样层）的主要作用是减少数据量、保留关键信息，常用操作有（最大池化）和（平均池化），池化过程中特征图的（深度）保持不变。
12. 循环神经网络（RNN）通过（带自反馈的神经元）处理变长序列数据，其状态更新公式为 $(h_t = f(U h_{t-1} + W x_t + b))$ ，按时间展开后可视为多层前馈网络。
13. RNN 面临的核心问题是（长期依赖问题），表现为梯度（消失）或梯度（爆炸），常用改进模型有 LSTM 和 GRU。
14. LSTM 通过（遗忘门）、（输入门）、（细胞状态）和（输出门）解决长期依赖问题，GRU 则简化为（重置门）和（更新门）两个门结构。
15. 网络优化的难点包括（非凸优化问题）、（参数初始化影响）、（逃离局部最优）等，常用优化算法有 SGD、Mini-Batch SGD、Adam 等。
16. 学习率衰减方法包括（梯级衰减）、（线性衰减）、（余弦衰减）、（周期性学习率调整）等，目的是平衡收敛速度和稳定性。
17. 正则化方法用于防止过拟合，常见的有（L1/L2 正则化）、（Dropout）、（提前停止）、（数据增强）、（标签平滑）等。
18. Dropout 在训练时以概率 p 随机丢弃神经元，测试时需将输出乘以 (p) 或在训练时对输出除以 $(1-p)$ 以保持期望一致。

19. 批量归一化 (BN) 通过对批量数据进行 (均值归一化) 和 (方差缩放), 减轻内部协变量偏移问题, 加速网络训练。
20. 词向量 (Word2Vec) 将单词表征为低维实数值向量, 训练模式包括 (CBOW, 根据上下文预测单词) 和 (Skip-gram, 根据单词预测上下文)。

第八章 强化学习与博弈

1. 强化学习是智能体在与 (环境) 的交互中, 通过学习 (最大化累积奖励) 的策略来完成序贯决策的过程, 核心概念包括智能体、环境、状态、动作、策略、奖励。
2. 强化学习与有监督学习的区别在于学习依据为 (评估反馈) 而非监督信息, 数据在 (时序交互) 中产生, 决策过程为 (序贯决策)。
3. 马尔可夫决策过程 (MDP) 是刻画强化学习环境的标准形式, 由状态空间 S 、动作集合 A 、(状态转移概率 Pr)、(奖励函数 R) 和 (折扣系数 γ) 构成, 记为 $(MDP = (S, A, Pr, R, \gamma))$ 。
4. 反馈 (return) 的计算公式为 $(G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots)$, 其中折扣系数 $\gamma \in [0, 1]$, 用于权衡 (即时奖励) 和 (未来奖励) 的重要性。
5. 强化学习中的价值函数 $(V_{\pi}(s))$ 表示在状态 s 下遵循策略 π 的期望反馈, 动作-价值函数 $(q_{\pi}(s, a))$ 表示在状态 s 采取动作 a 后遵循策略 π 的期望反馈, 二者关系为 $(V_{\pi}(s) = \sum_{a \in A} \pi(s, a) q_{\pi}(s, a))$ 。
6. 贝尔曼方程描述了价值函数的递推关系, 价值函数的贝尔曼方程为 $(V_{\pi}(s) = \mathbb{E}_{a \sim \pi(s, \cdot)} [\mathbb{E}_{s' \sim P(\cdot | s, a)} [R(s, a, s') + \gamma V_{\pi}(s')]])$ 。
7. 策略迭代 (GPI) 由 (策略评估) 和 (策略优化) 交替进行, 策略评估计算当前策略的价值函数, 策略优化通过贪心选择改进策略。
8. 策略评估的常用方法包括 (动态规划法)、(蒙特卡洛采样法) 和 (时序差分法 (TD)), 其中时序差分法结合了蒙特卡洛的采样特性和动态规划的在线更新特性。
9. Q-Learning 直接更新 (动作-价值函数 q), 其更新公式为 $(q_{\pi}(s, a) \leftarrow q_{\pi}(s, a) + \alpha [R + \gamma \max_{a'} q_{\pi}(s', a') - q_{\pi}(s, a)])$, 属于 (离策略) 方法。
10. 为平衡探索 (exploration) 与利用 (exploitation), Q-Learning 常采用 (ϵ -贪心策略), 以 $1-\epsilon$ 概率选择最优动作, ϵ 概率随机选择动作。
11. 深度强化学习 (Deep Q-Learning) 用 (深度神经网络) 拟合 q 函数, 通过 (经验重现) 解决样本相关性问题的, 通过 (目标网络) 提升优化稳定性。
12. 博弈论 (对策论) 研究带有竞争性质的主体的最优对抗策略, 核心要素包括参与者、策略、局势、(收益) 和 (规则)。
13. 纳什均衡是博弈的稳定局势, 指在该策略组合下, (任何参与者单独改变策略都不会提高自身收益), 混合策略纳什均衡允许参与者以 (概率分布) 选择策略。
14. 遗憾最小化算法通过计算过去博弈的 (遗憾值) 调整未来策略选择, 虚拟遗憾最小化算法 (CFR) 适用于状态空间巨大的博弈, 通过 (虚拟价值) 计算遗憾值。
15. 稳定婚姻问题的 Gale-Shapley 算法中, (单身男性) 主动表白, (女性) 选择最优匹配并可替换当前匹配, 最终达成稳定匹配。
16. AlphaGo 的核心技术融合了 (深度学习) (感知棋面)、(强化学习) (自我博弈) 和 (蒙特卡洛树搜索) (采样验证), 其策略网络预测落子概率, 价值网络评估局面胜负。
17. AlphaGo Zero 摒弃人类棋谱, 通过 (自我对弈) 从零训练, 采用 (深度残差网络) 统一策略和价值网络, 40 天内击败前代版本。

1. 简答题 1: 请简述强化学习的定义。

答案：强化学习是智能体在与环境的交互过程中，通过学习状态到动作的映射策略，以最大化累积奖励的机器学习方法。其核心是智能体根据环境反馈的状态和奖励，不断调整行为策略，最终掌握在序贯决策中获取最大收益的行动模式，模仿人类“试错学习”的过程。

2. 简答题 2：强化学习的核心组成要素有哪些？请分别说明。

答案：**核心组成要素包括 6 个：

- 智能体 (Agent)：决策主体，能执行动作并接收环境反馈。
- 环境 (Environment)：智能体外部的所有部分，可被动作影响并反馈状态和奖励。
- 状态 (State)：智能体对环境的编码，包含决策所需关键信息。
- 动作 (Action)：智能体影响环境的方式，来自预设动作集合。
- 策略 (Policy)：智能体在特定状态下选择动作的依据，可分为确定性策略和随机策略。
- 奖励 (Reward)：环境对智能体动作的反馈，是策略优化的核心目标。

3. 简答题 3：强化学习与有监督学习、无监督学习的核心区别是什么？

答案：**三者核心区别体现在 3 个维度：

- 学习依据：强化学习基于环境的评估反馈，有监督学习基于标注的监督信息，无监督学习基于数据结构假设。
- 数据来源：强化学习的数据在时序交互中动态产生，后两者的数据为一次性给定。
- 决策过程：强化学习是序贯决策（如棋类博弈），有监督学习多为单步决策（如分类识别），无监督学习无明确决策过程。

4. 简答题 4：什么是马尔可夫决策过程 (MDP)？其核心构成是什么？

答案：**马尔可夫决策过程是刻画强化学习环境的标准数学模型，用于描述序贯决策问题，满足“未来状态仅依赖当前状态，与历史无关”的马尔可夫性。核心构成包括 5 个部分，记为 $(MDP = \{S, A, Pr, R, \gamma\})$ ：

- 状态空间 (S) ：所有可能状态的集合。
- 动作集合 (A) ：智能体可执行的所有动作。
- 状态转移概率 (Pr) ：给定当前状态和动作时，转移到下一状态的概率。
- 奖励函数 (R) ：状态-动作-下一状态三元组对应的即时奖励。
- 折扣系数 (γ) ：用于权衡即时奖励和未来奖励的权重，取值范围为 $[0, 1]$ 。

5. 简答题 5：强化学习中“反馈 (Return)”的定义是什么？折扣系数 (γ) 的作用是什么？

答案：**反馈是智能体从某一时刻开始获得的累积奖励，公式为 $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ 。折扣系数 (γ) 的作用是：

- 控制未来奖励对当前决策的影响程度， (γ) 越接近 1，越重视未来长期奖励；越接近 0，越关注即时奖励。
- 保证累积奖励的收敛性，避免无限时序下奖励总和发散。

6. 简答题 6：价值函数和动作-价值函数的定义及核心关系是什么？

答案：**

- 价值函数 $(V_{\pi}(s))$ ：在状态 (s) 下遵循策略 (π) ，未来获得的期望反馈，反映状态 (s) 的长期价值。
- 动作-价值函数 $(Q_{\pi}(s, a))$ ：在状态 (s) 下采取动作 (a) 后遵循策略 (π) ，未来获得的

期望反馈，反映特定状态-动作对的长期价值。

- 核心关系：价值函数是动作-价值函数的加权和，即 $V_{\pi}(s) = \sum_{a \in A} \pi(a|s) Q_{\pi}(s,a)$ ，权重为策略 π 中动作 a 的选择概率。

7. 简答题 7：强化学习中策略评估与策略优化的含义是什么？二者的关系如何？

答案：

- 策略评估：给定策略 π ，计算对应的价值函数或动作-价值函数，评估该策略的长期收益。

- 策略优化：基于评估得到的价值函数，调整策略使各状态的价值最大化，得到更优策略 π' 。

- 关系：二者是通用策略迭代（GPI）的核心环节，交替进行。先通过策略评估计算当前策略的价值，再通过策略优化改进策略，反复迭代直至策略收敛到最优。

8. 简答题 8：Q-Learning 算法的核心思想是什么？如何平衡“探索”与“利用”？

答案：

- 核心思想：直接学习动作-价值函数（Q 函数），无需依赖环境模型（状态转移概率）。通过时序差分更新 Q 值，公式为 $Q_{\pi}(s,a) \leftarrow Q_{\pi}(s,a) + \alpha [R + \gamma \max_{a'} Q_{\pi}(s',a') - Q_{\pi}(s,a)]$ ，其中 α 为学习率， $\max_{a'} Q_{\pi}(s',a')$ 表示下一状态的最优动作价值。

- 探索与利用平衡：采用 ϵ -贪心策略。以 $(1-\epsilon)$ 的概率“利用”当前 Q 值最大的最优动作，以 ϵ 的小概率“探索”随机动作，避免陷入局部最优，保证发现更优策略的可能性。

9. 简答题 9：深度强化学习（Deep Q-Learning）解决了传统 Q-Learning 的什么问题？核心改进技术有哪些？

答案：

- 解决的问题：传统 Q-Learning 用表格存储 Q 值，无法处理状态数量庞大或无限的场景（如连续状态空间），深度强化学习用深度神经网络拟合 Q 函数，实现对复杂状态的泛化表示。

- 核心改进技术：

1. 经验重现（Experience Replay）：存储历史交互样本，随机采样训练，降低样本相关性，提升模型稳定性。

2. 目标网络（Target Network）：使用独立参数的目标网络计算目标 Q 值，避免训练过程中目标值波动过大，优化更稳定。

10. 简答题 10：强化学习的策略评估方法主要有哪些？请简述其核心特点。

答案：主要有 3 种方法：

- 动态规划法：基于贝尔曼方程迭代更新价值函数，需事先知晓状态转移概率，适合有限状态空间，计算精确但依赖环境模型。

- 蒙特卡洛采样法：通过采样完整轨迹，用样本均值估计价值函数，无需环境模型，但需等待轨迹终止，反馈周期长，样本稀疏时方差较大。

- 时序差分法（TD）：结合前两者优点，在线实时更新，无需环境模型和完整轨迹，通过下一状态的价值估计当前价值，反馈周期短，泛化能力强。