

一. 无约束问题

数学基础: $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$ 二次连续可微

梯度向量

$$\nabla f(\mathbf{x}) \triangleq \begin{bmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \frac{\partial f}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{bmatrix}, \quad d\mathbf{x} \triangleq \begin{bmatrix} dx_1 \\ dx_2 \\ \vdots \\ dx_n \end{bmatrix}, \quad \frac{\partial f}{\partial \mathbf{x}}(\mathbf{x}) \triangleq \nabla f(\mathbf{x})^T$$

$$\begin{aligned} df &\triangleq \frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \cdots + \frac{\partial f}{\partial x_n} dx_n \\ &= \nabla f(\mathbf{x})^T d\mathbf{x} = \frac{\partial f}{\partial \mathbf{x}} d\mathbf{x}. \end{aligned}$$

► 二阶偏导数: $\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) \triangleq \frac{\partial}{\partial x_j} \left(\frac{\partial f}{\partial x_i}(\mathbf{x}) \right)$

► 海森矩阵

$$\nabla^2 f(\mathbf{x}) \triangleq \begin{bmatrix} \nabla \frac{\partial f}{\partial x_1}(\mathbf{x})^T \\ \nabla \frac{\partial f}{\partial x_2}(\mathbf{x})^T \\ \vdots \\ \nabla \frac{\partial f}{\partial x_n}(\mathbf{x})^T \end{bmatrix} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{bmatrix}$$

► 如果 $f(\mathbf{x})$ 二次连续可微, 则有 $\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) = \frac{\partial^2 f}{\partial x_j \partial x_i}(\mathbf{x})$. 此时 $\nabla^2 f(\mathbf{x})$ 是一个对称阵.

考虑函数 $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$. 泰勒定理告诉我们:

$$f(\mathbf{x}_0 + \mathbf{d}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \nabla^2 f(\mathbf{x}_0 + \theta \mathbf{d}) \mathbf{d}, \quad 0 < \theta < 1$$

$$f(\mathbf{x}_0 + \mathbf{d}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \nabla^2 f(\mathbf{x}_0) \mathbf{d} + o(\|\mathbf{d}\|^2), \quad \|\mathbf{d}\| \rightarrow 0$$

$$df = \nabla f(\mathbf{x}_0)^T d\mathbf{x}, \quad \text{微分形式}$$

正定矩阵

定义: (只考虑我们用到的情况)

对于实对称方阵 $A \in \mathbb{R}^{n \times n}$, 若 $\forall x \in \mathbb{R}^n$, 有 $x^T A x > 0$, 则称 A 正定, 记为 $A > 0$

负定: A 负定 $\Leftrightarrow -A$ 正定

半正定, 半负定, 不定

正定的判断方法: 顺序主子式全为正, 特征值全为正

鞍点: 不是极值点的平稳点

定理 4.1

- (1) x_0 为极值点的必要条件: x_0 是平稳点, 即 $\nabla f(x_0) = 0$.
- (2) x_0 为极小值点的必要条件: $\nabla f(x_0) = 0$, $\nabla^2 f(x_0) \geq 0$.
- (3) x_0 为极大值点的必要条件: $\nabla f(x_0) = 0$, $\nabla^2 f(x_0) \leq 0$.

定理 4.2

- (1) x_0 为极小值点的充分条件: $\nabla f(x_0) = 0$, $\nabla^2 f(x_0) > 0$.
- (2) x_0 为极大值点的充分条件: $\nabla f(x_0) = 0$, $\nabla^2 f(x_0) < 0$.

定理 4.3

已知 x_0 是 $f(x)$ 的平稳点, 若前 $(n-1)$ 阶导数均为零, 且 $f^{(n)}(x_0) \neq 0$, 则

- (1) 如 n 为奇数, 则 x_0 不是极值点 (是鞍点);
- (2) 若 n 为偶数, 则当 $f^{(n)}(x_0) > 0$ 时 x_0 是极小值点, 当 $f^{(n)}(x_0) < 0$ 时 x_0 为极大值点. 证明方法: 泰勒展开

二. 等式约束问题.

$$\max / \min \quad Z = f(x)$$

$$\text{s.t.} \quad g_i(x) = 0 \quad i = 1, 2, \dots, m, \quad m < n$$

$x \in \mathbb{R}^n$, $f(x), g_i(x)$ 连续可微.

一阶必要条件: 前提: $\{\nabla g_i(x_0)\}$ 线性无关, $i = 1, 2, \dots, m$

$$L(x, \lambda) = f(x) - \sum_{i=1}^m \lambda_i g_i(x)$$

$$x_0 \text{ 是极值点} \Rightarrow \nabla L(x, \lambda) = 0$$

定理 4.5 (二阶充分条件)

已知 (x^*, λ^*) 是拉格朗日函数 $L(x, \lambda)$ 的平稳点, 定义

$$L_1(x) \triangleq L(x, \lambda^*), \quad D \triangleq \{d \mid \nabla g_i(x^*)^T d = 0, i = 1, \dots, m\}.$$

(1) 若对任意非零 $d \in D$ 有 $d^T \nabla^2 L_1(x^*) d < 0$, 则 x^* 是等式约束问题的严格极大值点.

(2) 若对任意非零 $d \in D$ 有 $d^T \nabla^2 L_1(x^*) d > 0$, 则 x^* 是等式约束问题的严格极小值点.

注意: 二阶充分条件并不需要 $\nabla g_i(x_0)$ 线性无关

d 不是随便取, 需要 $d \in D$

可行方向:

例 4.1B-5C

对下列无约束非线性规划问题, 验证给定点 x_0 是否为平稳点. 若是, 则判断平稳点类型; 若否, 则给出一个能够改善解的移动方向 d :

(a) $\min f(x) = x_1^2 + x_1x_2 - 6x_1 - 8x_2, \quad x_0 = (8, -10).$

(b) $\max f(x) = 10x_1^2 + 12\ln(x_2), \quad x_0 = (1, 2).$

(c) $\min f(x) = -x_1x_2 + 2x_2^2 + 16x_1, \quad x_0 = (3, 0).$

(d) $\max f(x) = x_1x_2 - 10x_1 + 4x_2, \quad x_0 = (-4, 10).$

4.1B-5.

(a) $\nabla f = \begin{bmatrix} 2x_1 - x_2 - 6 \\ x_1 - 8 \end{bmatrix}$ 代入 x_0 得 $\nabla f|_{x=x_0} = 0$

$\Rightarrow$ 是平稳点 $\nabla^2 f = \begin{bmatrix} 2 & 1 \\ 1 & 0 \end{bmatrix}$ $2 > 0$ $\begin{vmatrix} 2 & 1 \\ 1 & 0 \end{vmatrix} < 0$ 不定
故 x_0 为鞍点.

(b) $\nabla f = \begin{bmatrix} 20x_1 \\ \frac{12}{x_2} \end{bmatrix}$ $\nabla f(x_0) = \begin{bmatrix} 20 \\ 6 \end{bmatrix}$ 不是平稳点

d 可取 $\begin{bmatrix} 20 \\ 6 \end{bmatrix}$

注意梯度的意义是什么? 某点梯度的方向表征了函数在这一点附近上升最快的方向, 大小表示

上升的快慢, 这点梯度的反方向就是函数下降最快的方向。

把函数平稳点求出来, 再和 x_0 坐标相减得到一个方向是没有意义的。

首先这个平稳点可能极大, 可能极小, 可能是鞍点, 甚至可能不存在, 向这个平稳点移动并不一定能保证函数值改善。

其次, 即使找到一个平稳点是符合题目优化目标的, 也只能保证在向平稳点移动足够距离后解

会改善, 而不能保证在 x_0 处是能改善解的。中间的路程上可能有恶化的情况。即使不想用梯

度或者逆梯度方向 (取决于题目优化目标), 也应该用泰勒展开加以证明, 该方向可以改善

解。具体参照下问

$$(c) \nabla f = \begin{bmatrix} -x_2 + 16 \\ -x_1 + 4x_2 \end{bmatrix} \quad \nabla f(x_0) = \begin{bmatrix} 16 \\ -3 \end{bmatrix} \neq 0$$

故不是平稳点. $d = \begin{bmatrix} -16 \\ 3 \end{bmatrix}$ (题目要求 min)

$$\text{或: 在 } x_0 \text{ 邻域内: } f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + o(\|d\|)$$

其中 $d = \|x - x_0\|_2$ 令 $x - x_0$ 沿 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 方向, 则

$$\lim_{x \rightarrow x_0} f(x) - f(x_0) = d \cdot \nabla f(x_0)^T \begin{bmatrix} 0 \\ 1 \end{bmatrix} = -3d < 0$$

故 $f(x) < f(x_0)$ 即: 沿 $[0, 1]^T$ 可以改善解.

$$(d) \nabla f(x) = \begin{bmatrix} x_2 - 10 \\ x_1 + 4 \end{bmatrix} \quad \nabla f(x_0) = 0 \Rightarrow \text{是平稳点}$$

$$\nabla^2 f = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad \text{令 } \det(\lambda I - \nabla^2 f) = \begin{vmatrix} \lambda & -1 \\ -1 & \lambda \end{vmatrix} = 0 \text{ 得 } \lambda = \pm 1$$

故 $\nabla^2 f$ 不定, $\Rightarrow$ 鞍点.

灵敏度 $\max/\min z = f(x)$

$$\text{s.t. } g(x) = b$$

$$\nabla_b f(x^*) = \nabla_b f(x(b)) \big|_{b=0} = \lambda^*$$

$$L(x, \lambda) = f(x) - \lambda^T (g(x) - b)$$

$$\frac{\partial L}{\partial b} = \lambda$$

$$\text{应用: } \Delta f = \lambda^* \cdot \Delta b$$

不等式约束

$$\max z = f(x)$$

$$\text{s.t. } g_i(x) \leq 0 \quad i=1 \cdots r$$

$$g_i(x) \geq 0 \quad i=r+1 \cdots p$$

$$g_i(x) = 0 \quad i=p+1 \cdots m \quad m < n$$

$$\begin{aligned} L(x, s, \lambda) = & f(x) - \sum_{i=1}^r \lambda_i (g_i(x) + s_i^2) \\ & - \sum_{i=r+1}^p \lambda_i (g_i(x) - s_i^2) \\ & - \sum_{i=p+1}^m \lambda_i g_i(x) \end{aligned}$$

令 $\nabla L(x, s, \lambda) = 0$, 得到 KKT 条件.

极大值非线性规划问题的 KKT 条件 注意: 仍要求 $\nabla g_i(x)$ 线性无关

$$\textcircled{1} \begin{cases} \lambda_i \geq 0 & \leq \text{极小值} & i=1, \dots, r \\ \lambda_i \leq 0 & \geq & i=r+1, \dots, p \\ \lambda_i \text{ 无符号限制} & & i=p+1, \dots, m \end{cases}$$

$$\textcircled{2} \nabla f(x) = \sum_{i=1}^m \lambda_i \nabla g_i(x)$$

$$\textcircled{3} \lambda_i g_i(x) = 0, \quad i=1, \dots, r, r+1, \dots, p$$

$$\textcircled{4} \begin{cases} g_i(x) \leq 0, & i=1, \dots, r \\ g_i(x) \geq 0, & i=r+1, \dots, p \\ g_i(x) = 0, & i=p+1, \dots, m \end{cases}$$

定理 4.7 (极大值问题的二阶充分条件)

已知 (x^*, λ^*) 满足定理 4.6 中的 KKT 条件, 令

$\hat{I} = \{i \in I \mid \lambda_i^* > 0\}$, $\tilde{I} = \{i \in I \mid \lambda_i^* = 0\}$. 定义

极小值 $D \triangleq \left\{ d \in \mathbb{R}^n \mid \nabla g_i(x^*)^T d = 0, i \in \hat{I}; \nabla g_i(x^*)^T d \leq 0, i \in \tilde{I} \right\}$

$$L_1(x) \triangleq f(x) - \sum_{i \in \hat{I}} \lambda_i^* g_i(x).$$

若对任意非零 $d \in D$ 有 $d^T \nabla^2 L_1(x^*) d < 0$ 成立, 则 x^* 是严格局部极大值点.

$\hat{I}$: 起作用的约束 $\check{I}$: 不起作用的约束

注意: $D, L(x)$ 都只加起作用的约束有关

凸规划问题

1. 凸集:

凸集的定义

设 S 为 n 维欧式空间 $\mathbb{R}^n$ 中的一个集合. 若对 S 中任意两点 x_1, x_2 及任意实数 $\alpha \in (0, 1)$, 都有

$$\alpha x_1 + (1 - \alpha)x_2 \in S$$

则称 S 为凸集.

即: S 中任意两点的凸组合都在 S 内

凸组合

给定 k 个点 $x_1, x_2, \dots, x_k$, 称 $\sum_{i=1}^k \alpha_i x_i$ 为点 $x_1, x_2, \dots, x_k$ 的凸组合, 其中 $\alpha_i \geq 0, i = 1, 2, \dots, k, \sum_{i=1}^k \alpha_i = 1$.

凸集的极点

若点 $x \in S$ 不能表示成 S 中不同于 x 的两个点的凸组合, 则称 x 是凸集 S 的极点.

注意: “等价于”的意思

凸函数的定义

设 S 为 $\mathbb{R}^n$ 中的非空凸集, f 是定义在 S 上的实值函数. 如果对任意的 $x_1, x_2 \in S$ 及任意实数 $\alpha \in (0, 1)$, 都有

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2),$$

则称 f 为 S 上的凸函数.

严格凸函数、凹函数.

凸函数在优化问题中的重要性在于下面的基本性质.

定理 4.9

设 S 是 $\mathbb{R}^n$ 中非空凸集, f 是定义在 S 上的凸函数, 则

- (1) f 在 S 上的局部极小值点是全局极小值点;
- (2) 极小值点的集合为凸集.

若严格凸且有极小值点, 则必唯一.

定理 4.10 (一阶判据)

设 S 是 $\mathbb{R}^n$ 中一非空开凸集, $f(x)$ 是 S 上的可微函数, 则

- (1) $f(x)$ 为凸函数的充要条件是对任意两点 $x_1, x_2 \in S$, 有

$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T (x_2 - x_1).$$

- (2) $f(x)$ 为严格凸函数的充要条件是对任意互不相同的两点 $x_1, x_2 \in S$, 有

$$f(x_2) > f(x_1) + \nabla f(x_1)^T (x_2 - x_1).$$

二阶判据: $\nabla^2 f(x) \geq 0$

仿射函数既是凸函数又是凹函数.

凸规划问题的定义:

$$\min / \max \quad z = f(x)$$

$$\text{s.t.} \quad g_i(x) \leq 0 \quad i=1 \cdots r$$

$$g_i(x) = 0 \quad i=r+1 \cdots m$$

凸规划问题, KKT 条件是充要条件.

第五章：非线性规划算法

— 无约束

1. 一维搜索 $\begin{cases} \text{二分法} \\ \text{黄金分割法} \end{cases}$

算法思路

通过逐步缩小包含极值点的不确定区间，最终确定近似最优解。

迭代 $k+1$

令 $I^{(k)} = [x_L^{(k)}, x_R^{(k)}]$ 为第 k 次迭代的不确定区间(在迭代 1 中 $I^{(0)} = [a, b]$)。按以下方法找出试探点 $x_1^{(k+1)}$ 和 $x_2^{(k+1)}$ ：

二分法	黄金分割法
$x_1^{(k+1)} = \frac{1}{2}(x_R^{(k)} + x_L^{(k)} - \Delta)$	$x_1^{(k+1)} = x_R^{(k)} - (\frac{\sqrt{5}-1}{2})(x_R^{(k)} - x_L^{(k)})$
$x_2^{(k+1)} = \frac{1}{2}(x_R^{(k)} + x_L^{(k)} + \Delta)$	$x_2^{(k+1)} = x_L^{(k)} + (\frac{\sqrt{5}-1}{2})(x_R^{(k)} - x_L^{(k)})$

确定新的不确定区间 $I^{(k+1)}$ ：

情况 1：若 $f(x_1^{(k+1)}) > f(x_2^{(k+1)})$ ，则 $I^{(k+1)} = [x_L^{(k)}, x_2^{(k+1)}]$ 。

情况 2：若 $f(x_1^{(k+1)}) < f(x_2^{(k+1)})$ ，则 $I^{(k+1)} = [x_1^{(k+1)}, x_R^{(k)}]$ 。

情况 3：若 $f(x_1^{(k+1)}) = f(x_2^{(k+1)})$ ，则 $I^{(k+1)} = [x_1^{(k+1)}, x_2^{(k+1)}]$ 。

包含更优的 f 值

2. 梯度法

问题: $\max$ 或 $\min f(\mathbf{x})$.

目标: 求解 $\nabla f(\mathbf{x}) = \mathbf{0}$.

思想: 给定点 $\mathbf{x}^{(k)}$, 沿着梯度方向 $\nabla f(\mathbf{x}^{(k)})$ 找下一个点:

$$\mathbf{x}(r) = \begin{cases} \mathbf{x}^{(k)} + r \nabla f(\mathbf{x}^{(k)}), & \text{对极大值问题;} \\ \mathbf{x}^{(k)} - r \nabla f(\mathbf{x}^{(k)}), & \text{对极小值问题.} \end{cases}$$

本质: 多变量优化问题转换为单变量优化问题

$$\max \text{ 或 } \min h(r) = f(\mathbf{x}(r)) = f(\mathbf{x}^{(k)} \pm r \nabla f(\mathbf{x}^{(k)})).$$

迭代终止条件: $\|\nabla f(\mathbf{x}^{(k+1)})\| \approx 0$.

最优步长. $r_k = - \frac{\nabla f(\mathbf{x}^{(k)})^T \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})}$

上升迭代算法的一般迭代格式:

第 1 步 初始化. 选取初始点 $\mathbf{x}^{(0)}$, 令 $k = 0$.

第 2 步 终止准则. 检验 $\mathbf{x}^{(k)}$ 是否是极值点或近似极值点. 如果满足精度要求, 迭代停止. 否则, 进行第 3 步.

第 3 步 确定搜索方向. 从 $\mathbf{x}^{(k)}$ 出发确定一个可行上升方向 $\mathbf{d}^{(k)}$, 以便进行一维搜索. (也适应于有约束规划问题, 见第 5.2.4 节)

第 4 步 确定步长. 从迭代点 $\mathbf{x}^{(k)}$ 出发, 沿 $\mathbf{d}^{(k)}$ 前进步长 r_k , 得到 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + r_k \mathbf{d}^{(k)}$.

第 5 步 前进. 置 $k = k + 1$, 回到第 2 步.

牛顿法

问题: $\max f(\mathbf{x})$.

目标: 求解 $\nabla f(\mathbf{x}) = \mathbf{0}$.

思想: 用二次近似式的极值点近似 $f(\mathbf{x})$ 的极值点.

$$f_2(\mathbf{x}^{(k)} + \mathbf{d}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{d}.$$

令 $\nabla f_2(\mathbf{x}^{(k)} + \mathbf{d}) = \mathbf{0}$, 得到 $\mathbf{d}^{(k)} = -\nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$.

下一个迭代点选取为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}.$$

本质: 用线性化的方法解非线性方程组.

迭代终止条件: $\|\nabla f(\mathbf{x}^{(k+1)})\| \approx 0$.

若 $f(\mathbf{x}) = f(x_1, x_2, \dots, x_n)$ 可写为 $f_1(x_1) + f_2(x_2) + \dots + f_n(x_n)$

则称 $f(\mathbf{x})$ 可分离

若目标函数和约束函数都可分离, 则称为可分离规划.

可分离规划问题

$$\max \quad z = f(\mathbf{x})$$

$$\text{s. t.} \quad g_i(\mathbf{x}) \leq b_i, \quad i = 1, 2, \dots, m.$$

其中

$$f(\mathbf{x}) = f_1(x_1) + f_2(x_2) + \dots + f_n(x_n),$$


$$g_i(\mathbf{x}) = g_{i1}(x_1) + g_{i2}(x_2) + \dots + g_{in}(x_n).$$

算法的基本思想

► 观察: 一元函数 $f(x)$ 可以用分段线性函数近似.

► 思想: 用线性规划近似可分离规划, 用线性规划的单纯形法求近似解.

5: 一元非线性函数的分段线性近似



线性化后的模型为

$$\begin{aligned} \max \quad & z(\mathbf{w}) = \sum_{j=1}^n \left(\sum_{k=1}^{K_j} f_j(a_{jk}) w_{jk} \right) \\ \text{s. t.} \quad & \sum_{j=1}^n \left(\sum_{k=1}^{K_j} g_{ij}(a_{jk}) w_{jk} \right) \leq b_i, \quad i = 1, 2, \dots, m \\ & \sum_{k=1}^{K_j} w_{jk} = 1, \quad j = 1, 2, \dots, n \\ & w_{jk} \geq 0, \quad k = 1, 2, \dots, K_j, \\ & \quad \quad \quad j = 1, 2, \dots, n. \end{aligned}$$

且 w_{jk} 需满足两个额外的条件

(1) 最多两个 w_{jk} 是正的.

(2) 若 w_{jk} 为正, 则仅 $w_{j,k+1}$ 或 $w_{j,k-1}$ 可取正值.

限制基的单纯形法, 可能会无法满足最优性条件

二次规划模型

$$\begin{aligned} \max \quad & f(\mathbf{x}) = \mathbf{c}^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \mathbf{D} \mathbf{x} \\ \text{s. t.} \quad & \mathbf{A} \mathbf{x} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$, $\mathbf{c} \in \mathbb{R}^n$, $\mathbf{D} \in \mathbb{R}^{n \times n}$, 且满足 $\text{rank}(\mathbf{A}) = m$, $\mathbf{D} = \mathbf{D}^T$.

思路: 应用 KKT 条件求解问题. (定理 4.12)

► 注: 模型不唯一, 但方法适用.

KKT 条件矩阵形式:

$$\begin{bmatrix} -\mathbf{D} & \mathbf{A}^T & -\mathbf{I} & \mathbf{0} \\ \mathbf{A} & \mathbf{0} & \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \boldsymbol{\lambda} \\ \boldsymbol{\mu} \\ \mathbf{s} \end{bmatrix} = \begin{bmatrix} \mathbf{c} \\ \mathbf{b} \end{bmatrix}$$

$$\boldsymbol{\lambda}, \boldsymbol{\mu}, \mathbf{x}, \mathbf{s} \geq \mathbf{0}$$

限制 $\lambda_i s_i = 0, \mu_j x_j = 0$, 对所有的 i, j .

- (1) 如果 $\mathbf{D} = \mathbf{D}^T < \mathbf{0}$, 则上述条件也是充分条件. ★
- (2) 用限制基的两阶段法中的第一阶段求解.

$$\min r = R_1 + K_2 \dots$$

机会约束规划

机会约束规划问题定义为

$$\begin{aligned} \max \quad & f(\mathbf{x}) = \sum_{j=1}^n c_j x_j = \mathbf{c}^T \mathbf{x} \\ \text{s. t.} \quad & \Pr \left\{ \sum_{j=1}^n A_{ij} x_j \leq \begin{matrix} B_i \\ b_i \end{matrix} \right\} \geq 1 - \alpha_i, \quad i = 1, 2, \dots, m \\ & x_j \geq 0, \quad j = 1, 2, \dots, n. \end{aligned}$$

其中 x_j 是决策变量, 参数 A_{ij} 和 B_i 是随机变量, c_j 是常数.

情况一: A 是随机变量, $B_i = b_i$ 是常数.

$$\begin{aligned} \Pr \left\{ \sum_{j=1}^n A_{ij} x_j \leq b_i \right\} &\triangleq \sum_{j=1}^n A_{ij} x_j = H_i \\ &= \Pr \left\{ \frac{H_i - E(H_i)}{\sqrt{\text{Var } H_i}} \leq \frac{b_i - E(H_i)}{\sqrt{\text{Var } H_i}} \right\} \geq 1 - \alpha_i = \Phi(K_{\alpha_i}) \\ &\Leftrightarrow \frac{b_i - E(H_i)}{\sqrt{\text{Var } H_i}} \geq K_{\alpha_i} \end{aligned}$$

引入一个新的决策变量

$$y_i = \sqrt{\sum_{j=1}^n \text{var} \{A_{ij}\} x_j^2}, \quad i = 1, 2, \dots, m.$$

则原机会约束等价于

$$\begin{aligned} \sum_{j=1}^n E \{A_{ij}\} x_j + K_{\alpha_i} y_i &\leq b_i, \\ \sum_{j=1}^n \text{var} \{A_{ij}\} x_j^2 - y_i^2 &= 0, \quad y_i \geq 0. \end{aligned}$$

情况二: $B_i \sim \mathcal{N}(E(B_i), \text{Var } B_i)$

$$\text{原问题} \Leftrightarrow \sum_{j=1}^n a_{ij} x_j \leq E B_i + K_{1-\alpha_i} \sqrt{\text{Var } B_i}$$

$$\text{情况三: } \Pr \left\{ \sum_{j=1}^n A_{ij} x_j - B_i \leq 0 \right\} \geq 1 - \alpha_i$$

转化为(1)

可行方向法

考虑一类优化问题

$$\begin{aligned} \max \quad & f(\mathbf{x}) \\ \text{s. t.} \quad & \mathbf{Ax} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

基本思想: 梯度法在约束问题中的应用.

- (1) 给定当前迭代点, 找到一个可行上升 (下降) 方向;
- (2) 沿可行方向作一维搜索, 确定步长, 得到下一个迭代点.

迭代步骤

第 1 步 设 $\mathbf{x}^{(k)}$ 为可行迭代点, 求线性规划子问题的最优解 $\mathbf{y}^{(k)}$:

$$\begin{aligned} \max \quad & w(\mathbf{x}) = \nabla f(\mathbf{x}^{(k)})^T \mathbf{x} \quad \nearrow \quad \text{即 } \max f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \\ \text{s. t.} \quad & \mathbf{Ax} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}. \end{aligned}$$

(x - x^(k))
得乘上常数

第 2 步 若 $w(\mathbf{y}^{(k)}) > w(\mathbf{x}^{(k)})$, 则 $\mathbf{d}^{(k)} \triangleq \mathbf{y}^{(k)} - \mathbf{x}^{(k)}$ 为可行上升方向.

第 3 步 进行一维搜索, 确定最优步长 r_k :

$$\begin{aligned} \max \quad & h(r) \triangleq f(\mathbf{x}^{(k)} + r\mathbf{d}^{(k)}) \\ \text{s. t.} \quad & 0 \leq r \leq 1. \end{aligned}$$

第 4 步 下一个迭代点为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + r_k \mathbf{d}^{(k)}.$$

直到找不到上升方向为止

87

第六章: 动态规划

动态规划的基本思想:

1. 将难以求解的复杂问题分解成多个容易求解的简单问题;
2. 通过求解多个简单问题得到原来复杂问题的解.

阶段:

- ▶ 要解决的决策问题划分为有限个阶段.
- ▶ 每个阶段对应决策问题的一个子问题.
- ▶ 用 n 表示阶段的数量, i 表示当前阶段的标号.