

第四章 非线性规划理论

一、无约束问题

考虑二次连续可微函数 $f(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}$

梯度向量

$$\nabla f(\mathbf{x}) \triangleq \begin{bmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \frac{\partial f}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{bmatrix}, \quad d\mathbf{x} \triangleq \begin{bmatrix} dx_1 \\ dx_2 \\ \vdots \\ dx_n \end{bmatrix}, \quad \frac{\partial f}{\partial \mathbf{x}}(\mathbf{x}) \triangleq \nabla f(\mathbf{x})^T$$

$$\begin{aligned} df &\triangleq \frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \cdots + \frac{\partial f}{\partial x_n} dx_n \\ &= \nabla f(\mathbf{x})^T d\mathbf{x} = \frac{\partial f}{\partial \mathbf{x}} d\mathbf{x}. \end{aligned}$$

► 二阶偏导数: $\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) \triangleq \frac{\partial}{\partial x_j} \left(\frac{\partial f}{\partial x_i}(\mathbf{x}) \right)$

► 海森矩阵

$$\nabla^2 f(\mathbf{x}) \triangleq \begin{bmatrix} \nabla \frac{\partial f}{\partial x_1}(\mathbf{x})^\top \\ \nabla \frac{\partial f}{\partial x_2}(\mathbf{x})^\top \\ \vdots \\ \nabla \frac{\partial f}{\partial x_n}(\mathbf{x})^\top \end{bmatrix} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{bmatrix}$$

► 如果 $f(\mathbf{x})$ 二次连续可微, 则有 $\frac{\partial^2 f}{\partial x_i \partial x_j}(\mathbf{x}) = \frac{\partial^2 f}{\partial x_j \partial x_i}(\mathbf{x})$. 此时 $\nabla^2 f(\mathbf{x})$ 是一个对称阵.

$f(\mathbf{x})$ 在点 $\mathbf{x}_0$ 附近的一阶近似函数为

$$f_1(\mathbf{x}_0 + \mathbf{d}) \triangleq f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \mathbf{d}.$$

二阶近似函数为

$$f_2(\mathbf{x}_0 + \mathbf{d}) \triangleq f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \nabla^2 f(\mathbf{x}_0) \mathbf{d}.$$

正定矩阵.

定义: 给定实对称方阵 $A \in \mathbb{R}^{n \times n}$. 若 $\forall x \in \mathbb{R}^n$ 有 $x^T A x > 0$, 则称 A 正定.

负定. 半正/负定. 不定.

正定判断方式:

矩阵 A 的 k 阶顺序主子式为

$$\begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{vmatrix}, \quad k = 1, 2, \dots, n.$$

(1) A 正定 $\iff A$ 的所有顺序主子式为正.

特征值全为正.

7 给定实对称阵 D , 称 $q(x) = \frac{1}{2}x^T D x$ 为二次型. 判断下面二次型中对称阵的正定性:

(a) $q(x) = 6x_1 + 3x_2 - 4x_1x_2 - 2x_1^2 - 3x_2^2$.

(b) $q(x) = 2x_1^2 + 2x_2^2 + 3x_3^2 + 2x_1x_2 + 2x_2x_3$.

(a) 令 $x = [1, x_1, x_2]^T$

$$\text{则 } q(x) = \frac{1}{2} x^T \begin{bmatrix} 0 & 6 & 3 \\ 6 & -4 & -4 \\ 3 & -4 & -6 \end{bmatrix} x$$

顺序主子式

$$0 = 0$$

$$\begin{vmatrix} 0 & 6 \\ 6 & -4 \end{vmatrix} = -36 < 0$$

$$\begin{vmatrix} 0 & 6 & 3 \\ 6 & -4 & -4 \\ 3 & -4 & -6 \end{vmatrix} = 108 > 0$$

D 不定

无约束问题

$$\text{平稳点, } \nabla f(x) = 0 \left\{ \begin{array}{l} \text{极值点,} \\ \text{鞍点,} \end{array} \right\} \left\{ \begin{array}{l} \text{小 } \nabla^2 f(x_0) \geq 0 \\ \text{大 } \nabla^2 f(x_0) \leq 0 \end{array} \right. \quad \text{定理 4.1}$$

定理 4.3

已知 x_0 是 $f(x)$ 的平稳点, 若前 $(n-1)$ 阶导数均为零, 且 $f^{(n)}(x_0) \neq 0$, 则

x_0 为平稳点, $\nabla^2 f(x_0) \left\{ \begin{array}{l} \text{不定} \\ = 0 \\ \geq 0 \\ \leq 0 \end{array} \right. \left\{ \begin{array}{l} x_0 \text{ 为鞍点,} \\ \text{极值或鞍点} \end{array} \right. \left\{ \begin{array}{l} \text{由高阶项确定} \end{array} \right.$

- (1) 如 n 为奇数, 则 x_0 不是极值点 (是鞍点);
- (2) 若 n 为偶数, 则当 $f^{(n)}(x_0) > 0$ 时 x_0 是极小值点, 当 $f^{(n)}(x_0) < 0$ 时 x_0 为极大值点.

可用泰勒展开证明

二、约束问题

前置理论

雅可比矩阵

向量值函数 $\mathbf{g}(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ 在点 $\mathbf{x}$ 处的雅可比矩阵为

$$\mathbf{J}(\mathbf{x}) \triangleq \begin{bmatrix} \nabla g_1(\mathbf{x})^\top \\ \vdots \\ \nabla g_m(\mathbf{x})^\top \end{bmatrix} = \begin{bmatrix} \frac{\partial g_1}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial g_1}{\partial x_i}(\mathbf{x}) & \cdots & \frac{\partial g_1}{\partial x_n}(\mathbf{x}) \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_1}(\mathbf{x}) & \cdots & \frac{\partial g_m}{\partial x_i}(\mathbf{x}) & \cdots & \frac{\partial g_m}{\partial x_n}(\mathbf{x}) \end{bmatrix} \in \mathbb{R}^{m \times n}$$

► $\mathbf{J}(\mathbf{x})$ 又记为 $\mathbf{g}'(\mathbf{x})$ 或 $\frac{\partial \mathbf{g}}{\partial \mathbf{x}}(\mathbf{x})$, 称为 $\mathbf{g}(\mathbf{x})$ 在 $\mathbf{x}$ 处的导数.

记 $\nabla \mathbf{g}(\mathbf{x}) \triangleq \mathbf{J}(\mathbf{x})^\top = [\nabla g_1(\mathbf{x}) \quad \nabla g_2(\mathbf{x}) \quad \cdots \quad \nabla g_m(\mathbf{x})]$.

► 函数 $\mathbf{g}(\mathbf{x})$ 在 $\mathbf{x}$ 处的微分可写为

$$d\mathbf{g} = \mathbf{g}'(\mathbf{x}) d\mathbf{x} = \frac{\partial \mathbf{g}}{\partial \mathbf{x}}(\mathbf{x}) d\mathbf{x} = \nabla \mathbf{g}(\mathbf{x})^\top d\mathbf{x}.$$

链式法则. 对复合函数 $h(\mathbf{x}) \triangleq f(\mathbf{g}(\mathbf{x}))$

$$h'(\mathbf{x}) = f'(\mathbf{g}) g'(\mathbf{x}) \xrightarrow{\text{转置}} \nabla h(\mathbf{x}) = \nabla g(\mathbf{x}) \nabla f(\mathbf{g})$$

考虑等式约束问题

$$\begin{aligned} \max \text{ 或 } \min \quad & z = f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) = 0, \quad i = 1, 2, \dots, m, \quad m < n. \end{aligned}$$

其中 $\mathbf{x} \in \mathbb{R}^n$, 函数 $f(\mathbf{x})$, $g_i(\mathbf{x})$ 是连续可微函数.

定理 4.4 (一阶必要条件)

假设在 $\mathbf{x}_0$ 处, 向量组 $\{\nabla g_1(\mathbf{x}_0), \nabla g_2(\mathbf{x}_0), \dots, \nabla g_m(\mathbf{x}_0)\}$ 线性无关. 若 $\mathbf{x}_0$ 是等式约束问题的极值点, 则

- (1) $g_i(\mathbf{x}_0) = 0, \quad i = 1, 2, \dots, m;$
- (2) 存在实数 $\lambda_1, \lambda_2, \dots, \lambda_m$ 使得 $\nabla f(\mathbf{x}_0) - \sum_{i=1}^m \lambda_i \nabla g_i(\mathbf{x}_0) = \mathbf{0}$.

$$\text{令 } L(\mathbf{x}, \lambda) = f(\mathbf{x}) - \sum_{i=1}^m \lambda_i g_i(\mathbf{x})$$

$$\mathbf{x}_0 \text{ 是极值点} \Rightarrow \nabla L(\mathbf{x}, \lambda) = \mathbf{0}$$

定理 4.5 (二阶充分条件)

已知 $(\mathbf{x}^*, \lambda^*)$ 是拉格朗日函数 $L(\mathbf{x}, \lambda)$ 的平稳点, 定义

$$L_1(\mathbf{x}) \triangleq L(\mathbf{x}, \lambda^*), \quad D \triangleq \left\{ \mathbf{d} \mid \nabla g_i(\mathbf{x}^*)^\top \mathbf{d} = 0, i = 1, \dots, m \right\}.$$

- (1) 若对任意非零 $\mathbf{d} \in D$ 有 $\mathbf{d}^\top \nabla^2 L_1(\mathbf{x}^*) \mathbf{d} < 0$, 则 $\mathbf{x}^*$ 是等式约束问题的严格极大值点.
- (2) 若对任意非零 $\mathbf{d} \in D$ 有 $\mathbf{d}^\top \nabla^2 L_1(\mathbf{x}^*) \mathbf{d} > 0$, 则 $\mathbf{x}^*$ 是等式约束问题的严格极小值点.

二阶充分条件不需要 $\nabla g_i(\mathbf{x}_0)$ 线性无关

4.2B-1

1 考虑等式约束优化问题

$$\begin{aligned} \min \quad & f(x) = x_1^2 + 2x_2 + 10x_3^2 \\ \text{s. t.} \quad & g_1(x) = x_1 - x_2^2 + x_3 - 5 = 0 \\ & g_2(x) = x_1 + 5x_2 + x_3 - \frac{11}{4} = 0. \end{aligned}$$

(a) 求解问题的最优解.

(b) 假设约束变化为 $g_1(x) = 0.01$, $g_2(x) = 0.02$, 利用灵敏度分析法求解最优目标函数值的改变量.

(a) 定义 $L(x, \lambda) = f(x) - \lambda_1 g_1(x) - \lambda_2 g_2(x)$

$$\frac{\partial L}{\partial x_1} = 2x_1 - \lambda_1 - \lambda_2 = 0 \quad \frac{\partial L}{\partial x_2} = 2 + 2\lambda_1 x_2 - 5\lambda_2 = 0$$

$$\frac{\partial L}{\partial x_3} = 20x_3 - \lambda_1 - \lambda_2 = 0 \quad \frac{\partial L}{\partial \lambda_1} = -g_1(x) \quad \frac{\partial L}{\partial \lambda_2} = -g_2(x)$$

解得 $\begin{cases} x_1 = \frac{105}{22} & x_2 = -\frac{1}{2} \\ x_1 = \frac{505}{22} & x_2 = -\frac{9}{2} \end{cases} \quad \begin{cases} x_3 = \frac{21}{44} & \lambda_1 = \frac{503}{44} & \lambda_2 = \frac{-83}{44} \\ x_3 = \frac{101}{44} & \lambda_1 = \frac{-2503}{44} & \lambda_2 = \frac{4523}{44} \end{cases} \rightarrow \nabla^2 L(x) > 0 \quad x \text{ 为极小值点}$

$$\nabla^2 L(x) = \begin{pmatrix} 2 & & \\ & 2\lambda_1 & \\ & & 20 \end{pmatrix}$$

对所有 $\nabla g_i(x)^T d = 0, i=1,2$ 的 d 有 $d^T \nabla^2 L(x) d > 0$

$$\begin{cases} d_1 + 9d_2 + d_3 = 0 \\ d_1 + 5d_2 + d_3 = 0 \end{cases} \Rightarrow d = [d_1, 0, -d_1]^T \therefore x = \left[\frac{505}{22}, -\frac{9}{2}, \frac{101}{44} \right] \text{ 也是极小值点}$$

可行方向

- ▶ 设 $\mathbf{x}_0$ 是约束问题的可行解, $\mathbf{u}$ 是非零向量. 若存在数 $\delta > 0$, 使得对每一个 $t \in (0, \delta)$, $\mathbf{x}(t) = \mathbf{x}_0 + t\mathbf{u}$ 都是优化问题的可行解, 则称 $\mathbf{u}$ 为约束问题在 $\mathbf{x}_0$ 处的一个可行方向.
- ▶ 基本概念: 可行下降方向, 可行上升方向
- ▶ $\mathbf{x}_0$ 是局部极小值点 $\iff \mathbf{x}_0$ 处不存在可行下降方向.

4.13-5

- 5 对下列无约束非线性规划问题, 验证给定点 $\mathbf{x}_0$ 是否为平稳点. 若是, 则判断平稳点类型; 若否, 则给出一个能够改善解的移动方向 $\mathbf{d}$:

(a) $\min f(\mathbf{x}) = x_1^2 + x_1x_2 - 6x_1 - 8x_2, \quad \mathbf{x}_0 = (8, -10).$

(b) $\max f(\mathbf{x}) = 10x_1^2 + 12\ln(x_2), \quad \mathbf{x}_0 = (1, 2).$

(c) $\min f(\mathbf{x}) = -x_1x_2 + 2x_2^2 + 16x_1, \quad \mathbf{x}_0 = (3, 0).$

(d) $\max f(\mathbf{x}) = x_1x_2 - 10x_1 + 4x_2, \quad \mathbf{x}_0 = (-4, 10).$

(b) $\nabla f(\mathbf{x}) = \begin{bmatrix} 20x_1 \\ \frac{12}{x_2} \end{bmatrix}$ $\mathbf{x}_0$ 处 $\nabla f(\mathbf{x}_0) = \begin{bmatrix} 20 \\ 6 \end{bmatrix}$. 不是平稳点
移动方向可取 $\mathbf{d} = \begin{bmatrix} 20 \\ 6 \end{bmatrix}$

(c) $\nabla f(x) = \begin{bmatrix} -x_2 + 16 \\ -x_1 + 4x_2 \end{bmatrix}$ $\nabla f(x_0) = \begin{bmatrix} 16 \\ -3 \end{bmatrix}$ 不是平稳点, d 可取 $\begin{bmatrix} -16 \\ 3 \end{bmatrix}$

在 x_0 邻域内 $f(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + o(d)$

其中 $d = \|x - x_0\|_2$ 令 $x - x_0$ 沿 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 方向, 则

$$\lim_{x \rightarrow x_0} f(x) - f(x_0) = d \cdot \nabla f(x_0)^T \begin{bmatrix} 0 \\ 1 \end{bmatrix} = -3d < 0$$

故 $f(x) < f(x_0)$. 即沿 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 方向可改善解.

灵敏度分析

$$\max \text{ 或 } \min \quad z = f(x)$$

$$\text{s. t.} \quad g(x) = b.$$

等式约束优化问题右端项出现扰动，对最优值的影响为

$$\frac{\partial L}{\partial b_i}(x^*, \lambda^*) = \lambda_i^*$$

例: $g(x)=0$ 变为 $g(x)=0.01$

最优目标函数值变量 $\Delta f = \lambda^* \cdot \Delta b = 0.01 \lambda^*$

不等式约束

$$\max \quad z = f(\mathbf{x})$$

$$\text{s. t.} \quad g_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, r$$

$$g_i(\mathbf{x}) \geq 0, \quad i = r+1, r+2, \dots, p$$

$$g_i(\mathbf{x}) = 0, \quad i = p+1, p+2, \dots, m, \quad m < n.$$

拉格朗日函数为

$$\begin{aligned} L(\mathbf{x}, \mathbf{s}, \boldsymbol{\lambda}) = & f(\mathbf{x}) - \sum_{i=1}^r \lambda_i (g_i(\mathbf{x}) + s_i^2) \\ & - \sum_{i=r+1}^p \lambda_i (g_i(\mathbf{x}) - s_i^2) \\ & - \sum_{i=p+1}^m \lambda_i g_i(\mathbf{x}) \end{aligned}$$

若约束 $g_i(\mathbf{x}) \leq 0$ 在 $\mathbf{x}_0$ 满足 $g_i(\mathbf{x}_0) = 0$
则称约束 $g_i(\mathbf{x}) \leq 0$ 为 $\mathbf{x}_0$ 处有效约束

非有效约束并不对优化问题构成限制，故只需要有效约束构成的向量组 $\{ \nabla g_i(\mathbf{x}_0) \mid i \in I(\mathbf{x}_0) \}$ 线性无关

极大值非线性规划问题的 KKT 条件

$\lambda_i \geq 0$	≤ 0	$i = 1, \dots, r$
$\lambda_i \leq 0$	> 0	$i = r+1, \dots, p$
λ_i 无符号限制		$i = p+1, \dots, m$

$$\nabla f(\mathbf{x}) = \sum_{i=1}^m \lambda_i \nabla g_i(\mathbf{x})$$

$\lambda_i g_i(\mathbf{x}) = 0,$	$i = 1, \dots, r, r+1, \dots, p$
$g_i(\mathbf{x}) \leq 0,$	$i = 1, \dots, r$
$g_i(\mathbf{x}) \geq 0,$	$i = r+1, \dots, p$
$g_i(\mathbf{x}) = 0,$	$i = p+1, \dots, m$

详见定理 4.6

4.2C.9

9 考虑非线性规划问题

$$\min f(x) = 15x_1^2 + 4x_2^2$$

$$\text{s.t. } 3x_1 + 2x_2 = 8$$

$$x_1, x_2 \geq 0.$$

(a) 写出问题的 KKT 条件.

(b) 用 KKT 条件验证点 $x_0 = (0, 4)$ 不是最优解.(c) 验证在点 $x_0 = (0, 4)$ 处, 存在可行下降方向 $d = (2, -3)$.

(d) 求解 (a) 中的 KKT 条件, 并说明得到的 KKT 点是否为问题的最优解.

$$(a) \text{ KKT 条件: } \begin{cases} g_1(x) = 3x_1 + 2x_2 - 8 = 0 \\ g_2(x) = x_1 \geq 0 \quad g_3(x) = x_2 \geq 0 \end{cases}$$

$$\lambda_i g_i(x) = 0 \quad (i=2,3) \quad \nabla f(x) - \sum_{i=1}^m \lambda_i \nabla g_i(x) = 0$$

$$\lambda_i \geq 0 \quad (i=2,3)$$

↓

$$\begin{cases} 30x_1 - 3\lambda_1 - \lambda_2 = 0 \\ 8x_2 - 2\lambda_1 - \lambda_3 = 0 \end{cases}$$

(b) 在 $x_0 = (0, 4)$ 处梯度 $\nabla g_1(x) = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$ $\nabla g_2(x) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 线性无关

$$\text{代入(a)中解得 } \begin{cases} \lambda_1 = 16 \\ \lambda_2 = -48 < 0 \end{cases} \text{ 不满足 KKT 条件.}$$

(0, 4) 不是极值点.

$$(c) \quad \nabla g_1(x_0)^T d = [3 \ 2] \begin{bmatrix} 2 \\ -3 \end{bmatrix} = 0$$

$$\nabla g_2(x_0)^T d = [1 \ 0] \begin{bmatrix} 2 \\ -3 \end{bmatrix} = 2 > 0$$

 $\Rightarrow d$ 为可行方向

$$\nabla f(x_0)^T d = [30x_1 \ 8x_2] \begin{bmatrix} 2 \\ -3 \end{bmatrix} < 0$$

 $\Rightarrow d$ 为下降方向

$$(d) \quad (x^*, \lambda^*) = (1, \frac{5}{2}, 10, 0, 0)$$

从 $\lambda_i g_i(x) = 0$ 入手假设 λ_i 不为 0 试解

$$\nabla^2 L(x^*, \lambda^*) = \begin{bmatrix} 30 & 0 & 0 \\ 0 & 8 & 0 \end{bmatrix} > 0$$

 $\Rightarrow x^*$ 为唯一严格极小值点.

定理 4.7 (极大值问题的二阶充分条件)

已知 (x^*, λ^*) 满足定理 4.6 中的 KKT 条件, 令 $\hat{I} = \{i \in I \mid \lambda_i^* > 0\}$, $\bar{I} = \{i \in I \mid \lambda_i^* = 0\}$. 定义极小值 < 0

$$D \triangleq \{d \in \mathbb{R}^n \mid \nabla g_i(x^*)^T d = 0, i \in \hat{I}; \nabla g_i(x^*)^T d \leq 0, i \in \bar{I}\}$$

$$L_1(x) \triangleq f(x) - \sum_{i \in \hat{I}} \lambda_i^* g_i(x).$$

若对任意非零 $d \in D$ 有 $d^T \nabla^2 L_1(x^*) d < 0$ 成立, 则 x^* 是严格局部极大值点.

三、凸规划问题

凸集的定义

设 S 为 n 维欧式空间 $\mathbb{R}^n$ 中的一个集合. 若对 S 中任意两点 x_1, x_2 及任意实数 $\alpha \in (0, 1)$, 都有

$$\alpha x_1 + (1 - \alpha)x_2 \in S$$

则称 S 为凸集.

即 S 中任两点的凸组合都在 S 中

凸组合的交、和、差、线性组合也是凸集

凸函数的定义

设 S 为 $\mathbb{R}^n$ 中的非空凸集, f 是定义在 S 上的实值函数. 如果对任意的 $x_1, x_2 \in S$ 及任意实数 $\alpha \in (0, 1)$, 都有

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2),$$

则称 f 为 S 上的凸函数.

严格凸函数. 凹函数.

凸函数在优化问题中的重要性在于下面的基本性质.

定理 4.9

设 S 是 $\mathbb{R}^n$ 中非空凸集, f 是定义在 S 上的凸函数, 则

(1) f 在 S 上的局部极小值点是全局极小值点;

(2) 极小值点的集合为凸集.

严格凸函数若有极小值点, 则是唯一的.

定理 4.10 (一阶判据)


设 S 是 $\mathbb{R}^n$ 中一非空开凸集, $f(x)$ 是 S 上的可微函数, 则

(1) $f(x)$ 为凸函数的充要条件是对任意两点 $x_1, x_2 \in S$, 有

$$f(x_2) \geq \underbrace{f(x_1) + \nabla f(x_1)^T (x_2 - x_1)}_{x_1 \text{ 处切线在 } x_2 \text{ 处的值}}.$$

(2) $f(x)$ 为严格凸函数的充要条件是对任意互不相同的两点 $x_1, x_2 \in S$, 有

$$f(x_2) > f(x_1) + \nabla f(x_1)^T (x_2 - x_1).$$



二阶判据

$$\nabla^2 f(x) \geq 0$$

凸规划问题: 在凸集上求凸函数的极小值或凹函数的极大值.

$$\min \quad z = f(\mathbf{x})$$

凸函数

$$\text{s. t.} \quad g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r$$

凸函数

$$g_i(\mathbf{x}) = 0, \quad i = r + 1, \dots, m.$$

仿射函数

或者

$$\max \quad z = f(\mathbf{x})$$

凹函数

$$\text{s. t.} \quad g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r$$

凸函数

$$\textcircled{g_i(\mathbf{x})} = 0, \quad i = r + 1, \dots, m.$$

仿射函数

即是凸函数又是凹函数.

↓
若为非线性的凸函数, 不为凸规划问题

凸规划问题: KKT条件是充要条件.

4.3C.2^a

$$(a) \max f(x) = x_1^3 - x_2^2 + x_1 x_3^2$$

$$\text{s. t. } x_1 + x_2^2 + x_3 = 5$$

$$5x_1^2 - x_2^2 - x_3 \geq 2$$

$$x_1, x_2, x_3 \geq 0.$$

判断是否为凸优化问题

$$\nabla^2 f(x) = \begin{bmatrix} 6x_1 & 0 & 2x_3 \\ 0 & -2 & 0 \\ 2x_3 & 0 & 2x_1 \end{bmatrix} \quad \begin{array}{l} \text{特征值依赖于 } x_1, x_3 \\ \text{非凹函数.} \end{array}$$

约束 $x_1 + x_2^2 + x_3 = 5$ 非仿射

KKT点不一定为全局极值

第五章 非线性规划算法

一、无约束规划算法

1. 一维搜索法 $\left\{ \begin{array}{l} \text{二分法} \\ \text{黄金分割法} \end{array} \right.$

问题: $\max$ 或 $\min f(\mathbf{x})$.

2. 梯度法

目标: 求解 $\nabla f(\mathbf{x}) = \mathbf{0}$.

见书例题

思想: 给定点 $\mathbf{x}^{(k)}$, 沿着梯度方向 $\nabla f(\mathbf{x}^{(k)})$ 找下一个点:

$$\mathbf{x}(r) = \begin{cases} \mathbf{x}^{(k)} + r \nabla f(\mathbf{x}^{(k)}), & \text{对极大值问题;} \\ \mathbf{x}^{(k)} - r \nabla f(\mathbf{x}^{(k)}), & \text{对极小值问题.} \end{cases}$$

本质: 多变量优化问题转换为单变量优化问题

$$\max \text{ 或 } \min h(r) = f(\mathbf{x}(r)) = f(\mathbf{x}^{(k)} \pm r \nabla f(\mathbf{x}^{(k)})).$$

迭代终止条件: $\|\nabla f(\mathbf{x}^{(k+1)})\| \approx 0$.

最优步长:
$$\gamma_k = - \frac{\nabla f(\mathbf{x}^{(k)})^\top \nabla f(\mathbf{x}^{(k)})}{\nabla f(\mathbf{x}^{(k)})^\top \nabla^2 f(\mathbf{x}^{(k)}) \nabla f(\mathbf{x}^{(k)})}$$

3. 牛顿法

问题: $\max f(\mathbf{x})$.

目标: 求解 $\nabla f(\mathbf{x}) = \mathbf{0}$.

思想: 用二次近似式的极值点近似 $f(\mathbf{x})$ 的极值点.

$$f_2(\mathbf{x}^{(k)} + \mathbf{d}) = f(\mathbf{x}^{(k)}) + \nabla f(\mathbf{x}^{(k)})^\top \mathbf{d} + \frac{1}{2} \mathbf{d}^\top \nabla^2 f(\mathbf{x}^{(k)}) \mathbf{d}.$$

令 $\nabla f_2(\mathbf{x}^{(k)} + \mathbf{d}) = \mathbf{0}$, 得到 $\mathbf{d}^{(k)} = -\nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$.

下一个迭代点选取为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)}.$$

本质: 用线性化的方法解非线性方程组.

迭代终止条件: $\|\nabla f(\mathbf{x}^{(k+1)})\| \approx 0$.

二、有约束规划算法

1. 可分离规划 目标函数与约束函数都是可分离的.

$$f(x) = f(x_1, x_2, \dots, x_n) \text{ 可写为 } f_1(x_1) + f_2(x_2) + \dots + f_n(x_n)$$

则称 $f(x)$ 可分离

可分离规划问题

$$\max \quad z = f(x)$$

$$\text{s. t.} \quad g_i(x) \leq b_i, \quad i = 1, 2, \dots, m.$$

其中

$$f(x) = f_1(x_1) + f_2(x_2) + \dots + f_n(x_n),$$

$$g_i(x) = g_{i1}(x_1) + g_{i2}(x_2) + \dots + g_{in}(x_n).$$

算法的基本思想

对未线性化的函数作近似

- ▶ 观察: 一元函数 $f(x)$ 可以用分段线性函数近似.
- ▶ 思想: 用线性规划近似可分离规划, 用线性规划的单纯形法求近似解.

线性化后的模型为

$$\begin{aligned} \max \quad & z(\mathbf{w}) = \sum_{j=1}^n \left(\sum_{k=1}^{K_j} f_j(a_{jk}) w_{jk} \right) \\ \text{s. t.} \quad & \sum_{j=1}^n \left(\sum_{k=1}^{K_j} g_{ij}(a_{jk}) w_{jk} \right) \leq b_i, \quad i = 1, 2, \dots, m \\ & \sum_{k=1}^{K_j} w_{jk} = 1, \quad j = 1, 2, \dots, n \\ & w_{jk} \geq 0, \quad k = 1, 2, \dots, K_j, \\ & \quad j = 1, 2, \dots, n. \end{aligned}$$

且 w_{jk} 需满足两个额外的条件

- (1) 最多两个 w_{jk} 是正的.
 - (2) 若 w_{jk} 为正, 则仅 $w_{j,k+1}$ 或 $w_{j,k-1}$ 可取正值.
- 限制基的单纯形法, 仅保证局部最优解. 可能给出不可行解.

$f(x)$ 不为可行解列元素值. 而是将 w^* 代入原问题

- 3 将下面的可分离规划问题近似为一个线性规划问题, 并用限制基的单纯形法求出问题的近似解. 其中 (a) 中决策变量 x_1, x_2 的间断点取 $\{0, 1, 3\}$, (b) 中决策变量的间断点取 $\{0, 0.5, 1\}$, (c) 中决策变量的间断点取 $\{0, 1, 2\}$.

$$(a) \max f(x) = e^{-x_1} + x_1 + (x_2 + 1)^2 \quad (b) \min f(x) = x_1^4 - x_1 + x_2^2$$

$$\text{s.t. } x_1^2 + x_2 \leq 3$$

$$\text{s.t. } x_1^2 - x_1 + x_2^2 \leq 4$$

$$x_1, x_2 \geq 0.$$

$$x_1, x_2 \geq 0.$$

$$(c) \min f(x) = (x_1 - 2)^2 + 4(x_2 - 6)^2$$

$$\text{s.t. } 6x_1 + 3(x_2 + 1)^2 \leq 12$$

$$x_1, x_2 \geq 0.$$

$$(a) f_1(x_1) = e^{-x_1} + x_1 \quad f_2(x_2) = (x_2 + 1)^2 \quad g_1(x_1) = x_1^2 \quad g_2(x_2) = x_2$$

k	$a_{1k} = a_{2k}$	$f_1(a_{1k})$	$g_1(a_{1k})$	$f_2(a_{2k})$	$g_2(a_{2k})$	w_{1k}	w_{2k}
1	0	1	0	1	0	w_{11}	w_{21}
2	1	$e^{-1} + 1$	1	4	1	w_{12}	w_{22}
3	3	$e^{-3} + 3$	9	16	3	w_{13}	w_{23}

$$f_1(x_1) \approx w_{11} + (e^{-1} + 1)w_{12} + (e^{-3} + 3)w_{13} \quad g_1(x_1) \approx w_{12} + 9w_{13}$$

$$f_2(x_2) \approx w_{21} + 4w_{22} + 16w_{23} \quad g_2(x_2) \approx w_{22} + 3w_{23}$$

近似问题: $\max f(x) = w_{11} + (e^{-1} + 1)w_{12} + (e^{-3} + 3)w_{13} + w_{21} + 4w_{22} + 16w_{23}$

$$\text{s.t. } w_{12} + 9w_{13} + w_{22} + 3w_{23} \leq 3$$

$$w_{1k}, w_{2k} \geq 0$$

$$w_{11} + w_{12} + w_{13} = 1 \quad w_{21} + w_{22} + w_{23} = 1$$

2. 二次规划.

二次规划模型

$$\max \quad f(\mathbf{x}) = \mathbf{c}^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \mathbf{D} \mathbf{x}$$

$$\text{s. t.} \quad \mathbf{A} \mathbf{x} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}.$$

其中 $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$, $\mathbf{c} \in \mathbb{R}^n$, $\mathbf{D} \in \mathbb{R}^{n \times n}$, 且满足 $\text{rank}(\mathbf{A}) = m$, $\mathbf{D} = \mathbf{D}^T$.

思路: 应用 KKT 条件求解问题. (定理 4.12)

► 注: 模型不唯一, 但方法适用.

KKT条件矩阵形式:

$$\begin{bmatrix} -\mathbf{D} & \mathbf{A}^T & -\mathbf{I} & \mathbf{0} \\ \mathbf{A} & \mathbf{0} & \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \boldsymbol{\lambda} \\ \boldsymbol{\mu} \\ \mathbf{s} \end{bmatrix} = \begin{bmatrix} \mathbf{c} \\ \mathbf{b} \end{bmatrix}$$

$$\boldsymbol{\lambda}, \boldsymbol{\mu}, \mathbf{x}, \mathbf{s} \geq \mathbf{0}$$

⑤ 松弛变量, 等式约束时不需要.

$\lambda_i s_i = 0$, $\mu_j x_j = 0$ 对所有的 i, j

入与约束数量相同, μ 与变量数量相同 $\rightarrow \lambda_i$ 与 s_i , μ_j 与 x_j 不同为正.

- (1) 如果 $D = D^T < 0$, 则上述条件也是充分条件.
- (2) 用限制基的两阶段法中的第一阶段求解.

$$\min \quad r = R_1 + R_2$$

若有可行解, 所有人工变量取零

求解时可先写为矩阵形式 $\Rightarrow$ 证明凸规划 $\Rightarrow$ KKT 条件 $\Rightarrow$ 求解 KKT 点

3. 机会约束规划

用于处理参数中有随机变量的情况

机会约束规划问题定义为

$$\begin{aligned} \max \quad & f(\mathbf{x}) = \sum_{j=1}^n c_j x_j \\ \text{s. t.} \quad & \Pr \left\{ \sum_{j=1}^n A_{ij} x_j \leq \frac{B_i}{B_{ij}} \right\} \geq 1 - \alpha_i, \quad i = 1, 2, \dots, m \\ & x_j \geq 0, \quad j = 1, 2, \dots, n. \end{aligned}$$

其中 x_j 是决策变量, 参数 A_{ij} 和 $\frac{B_i}{B_{ij}}$ 是随机变量, c_j 是常数.

已知 $E\{A_{ij}\}$, $\text{var}\{A_{ij}\}$

(1) A_{ij} 是随机变量, $B_i = b_i$ 是常数.

$$E\{H_i\} = \sum_{j=1}^n E\{A_{ij}\} x_j$$

$$\text{var}\{H_i\} = \sum_{j=1}^n \text{var}\{A_{ij}\} x_j^2$$

$$\Pr\left\{\sum_{j=1}^n A_{ij} x_j \leq b_i\right\} \stackrel{\text{令 } \sum_{j=1}^n A_{ij} x_j = H_i}{=} \Pr\{H_i \leq b_i\}$$

$$= \Pr\left\{\frac{H_i - E(H_i)}{\sqrt{\text{var}(H_i)}} \leq \frac{b_i - E(H_i)}{\sqrt{\text{var}(H_i)}}\right\} = \Phi\left(\frac{b_i - E(H_i)}{\sqrt{\text{var}(H_i)}}\right) \geq 1 - \alpha_i$$

$$\Leftrightarrow \frac{b_i - E(H_i)}{\sqrt{\text{var}(H_i)}} \geq K_{\alpha_i}$$

等价于 $E\{H_i\} + K_{\alpha_i} \sqrt{\text{var}\{H_i\}} \leq b_i$

$$\sum_{j=1}^n E\{A_{ij}\} x_j + K_{\alpha_i} \sqrt{\sum_{j=1}^n \text{var}\{A_{ij}\} x_j^2} \leq b_i.$$

引入一个新的决策变量

$$y_i = \sqrt{\sum_{j=1}^n \text{var}\{A_{ij}\} x_j^2}, \quad i = 1, 2, \dots, m.$$

则原机会约束等价于

$$\sum_{j=1}^n E\{A_{ij}\} x_j + K_{\alpha_i} y_i \leq b_i,$$

$$\sum_{j=1}^n \text{var}\{A_{ij}\} x_j^2 - y_i^2 = 0, \quad y_i \geq 0.$$

已知 $E\{B_i\}$, $\text{var}\{B_i\}$

(2) $A_{ij} = a_{ij}$ 是常数, B_i 是随机变量.

等价于 $\sum_{j=1}^n a_{ij} x_j \leq E\{B_i\} + K_{1-\alpha_i} \sqrt{\text{var}\{B_i\}}$

(3) A_{ij} 和 B_i 都是随机变量.

$\Pr\left\{\sum_{j=1}^n \underline{A_{ij} x_j - B_i} \leq 0\right\} \geq 1 - \alpha_i$
转化为 (1) 也服从正态分布.

4. 可行方向法.

考虑一类优化问题

$$\begin{array}{ll}\max & f(\mathbf{x}) \\ \text{s. t.} & \mathbf{Ax} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}.\end{array}$$

基本思想: 梯度法在约束问题中的应用.

- (1) 给定当前迭代点, 找到一个可行上升 (下降) 方向;
- (2) 沿可行方向作一维搜索, 确定步长, 得到下一个迭代点.

迭代步骤

第 1 步 设 $\mathbf{x}^{(k)}$ 为可行迭代点, 求线性规划子问题的最优解 $\mathbf{y}^{(k)}$:

$$\max \quad w(\mathbf{x}) = \nabla f(\mathbf{x}^{(k)})^T \mathbf{x}$$

$$\text{s. t.} \quad \mathbf{Ax} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}.$$

原问题为 min 时
构造 $\min w(\mathbf{x}) = \nabla f(\mathbf{x}^{(k)})^T \mathbf{x}$

第 2 步 若 $\min. w(\mathbf{y}^{(k)}) < w(\mathbf{x}^{(k)})$, 则 $\underline{\mathbf{d}^{(k)} \triangleq \mathbf{y}^{(k)} - \mathbf{x}^{(k)}}$ 为可行上升方向。
可行下降方向

第 3 步 进行一维搜索, 确定最优步长 r_k :

$$\max \quad h(r) \triangleq f(\mathbf{x}^{(k)} + r\mathbf{d}^{(k)})$$

$$\text{s. t.} \quad 0 \leq r \leq 1.$$

第 4 步 下一个迭代点为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + r_k \mathbf{d}^{(k)}.$$

迭代至
 $|\nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}| \approx 0$
或 $w(\mathbf{y}^{(k)}) \leq w(\mathbf{x}^{(k)})$

$$5.2 D.1 \quad (b) \quad \max f(x) = x_1^3 + x_2^3 - 3x_1x_2$$

$$\text{s.t.} \quad 3x_1 + x_2 \leq 3$$

$$5x_1 - 3x_2 \leq 5$$

$$x_1, x_2 \geq 0.$$

取初始点 $x^{(0)} = (0, 1)$.

$$\begin{aligned} \max f(x) &= x_1^3 + x_2^3 - 3x_1x_2 \\ \text{s.t.} \quad 3x_1 + x_2 &\leq 3 \quad 5x_1 - 3x_2 \leq 5 \quad x_1, x_2 \geq 0 \\ \nabla f(x) &= \begin{bmatrix} 3x_1^2 - 3x_2 \\ 3x_2^2 - 3x_1 \end{bmatrix} = 3 \begin{bmatrix} x_1^2 - x_2 \\ x_2^2 - x_1 \end{bmatrix} \end{aligned}$$

迭代 1

$$\nabla f(x^{(0)}) = \begin{bmatrix} -3 \\ 3 \end{bmatrix}$$

子问题

$$\max w = \nabla f(x^{(0)})^T x = -3x_1 + 3x_2$$

$$\text{s.t.} \quad 3x_1 + x_2 \leq 3 \quad 5x_1 - 3x_2 \leq 5 \quad x_1, x_2 \geq 0$$

图解法解 (第二个约束多余)

$$\text{解得 } y^{(0)} = (0, 3) \quad w(y^{(0)}) = 9 \quad w(x^{(0)}) = 3$$

$$w(y^{(0)}) > w(x^{(0)}) \quad d^{(0)} = (0, 2)$$

进行一维搜索:

$$\begin{aligned} \max h(r) &= (1 + 2r)^3 \\ \text{s.t.} \quad 0 &\leq r \leq 1 \end{aligned}$$

$$\text{于是 } r^{(0)} = 1 \quad x^{(1)} = (0, 3) \quad f(x^{(1)}) = 27$$

迭代 2:

$$\nabla f(x^{(1)}) = \begin{bmatrix} -9 \\ 27 \end{bmatrix}$$

子问题

$$\max w = \nabla f(x^{(1)})^T x = -9x_1 + 27x_2$$

$$\begin{aligned} \text{s.t.} \quad 3x_1 + x_2 &\leq 3 \quad 5x_1 - 3x_2 \leq 5 \quad x_1, x_2 \geq 0 \\ w(y^{(1)}) &= 81 \quad w(x^{(1)}) = 81 \end{aligned}$$

解得 $y^{(1)} = (0, 3)$

迭代结束